

SKRIPSI

**ANALISIS SPASIO-TEMPORAL INTENSITAS *UPWELLING*
DAN PREDIKSI KLOROFIL-A MENGGUNAKAN
CONVLSTM DI WPP-NRI 572**



**ANDREAS HENDRA HERWANTO
NIM. 164221064**

**PROGRAM SARJANA
TEKNOLOGI SAINS DATA
DEPARTEMEN TEKNIK
FAKULTAS TEKNOLOGI MAJU DAN MULTIDISIPLIN
UNIVERSITAS AIRLANGGA
2026**

LEMBAR PENGESAHAN

**ANALISIS SPASIO-TEMPORAL INTENSITAS UPWELLING DAN
PREDIKSI KLOOROFIL-A MENGGUNAKAN CONVLTSM DI WPP-NRI
572**

SKRIPSI

Sebagai Salah Satu Syarat untuk Memperoleh
Gelar Sarjana Sains Data
Fakultas Teknologi Maju dan Multidisiplin
Universitas Airlangga

Nama : Andreas Hendra Hervanto
NIM : 164221064
Tanggal Sidang Skripsi : 8 Juli 2026


Disetujui oleh:

Pembimbing I



Dr. Dwi Rantini, S.Si.
NIP. 199406152022033201

Pembimbing II



Dr. Septia Devi P. Yasmirullah, S.Si.
NIP. 199509042024033201

Mengetahui,
Koordinator Program Studi
SI Teknologi Sains Data



Dr. Dwi Rantini, S.Si.
NIP. 199406152022033201

PERNYATAAN ORISINALITAS SKRIPSI

Saya, Andreas Hendra Herwanto, 164221064, penulis Skripsi yang berjudul **Analisis Spasio-Temporal Intensitas *Upwelling* dan Prediksi Klorofil-a Menggunakan ConvLSTM di WPP-NRI 572** menyatakan bahwa:

1. Skripsi ini adalah asli dan benar-benar hasil karya saya sendiri, bukan hasil karya pihak lain dengan mengatasnamakan saya, bukan merupakan hasil tiruan atau jiplakan (*plagiarisme*) dari karya pihak lain, dan/atau bukan tulisan yang dibuat dengan kecerdasan buatan.
2. Skripsi ini belum pernah diajukan untuk mendapatkan gelar akademik, baik di Universitas Airlangga, maupun di perguruan tinggi lainnya.
3. Dalam Skripsi ini tidak terdapat karya atau pendapat yang telah ditulis atau dipublikasikan orang lain, kecuali secara tertulis dengan jelas dicantumkan sebagai acuan dengan disebutkan nama pengarang dan dicantumkan dalam daftar kepustakaan.

Pernyataan ini saya buat dengan sebenar-benarnya, dan apabila dikemudian hari terdapat penyimpangan dan ketidakbenaran dalam pernyataan ini, maka saya bersedia menerima sanksi akademik berupa pencabutan gelar yang telah diperoleh karena karya tulis Skripsi ini, serta sanksi-sanksi lainnya sesuai dengan norma dan peraturan yang berlaku di Universitas Airlangga.

Surabaya, Juli 2026



Andreas Hendra Herwanto

NIM. 164221064

KETENTUAN PENGGUNAAN SKRIPSI

Ketentuan hak cipta bagi skripsi yang tidak dipublikasikan, terdaftar, tersedia, serta terbuka untuk umum di Perpustakaan Universitas Airlangga, dimiliki penulis dengan mengikuti aturan HKI yang berlaku di Universitas Airlangga. Referensi kepustakaan diperkenankan dicatat, tetapi pengutipan atau peringkasan hanya dapat dilakukan dengan seizin penulis dan harus disitasi sesuai dengan kaidah ilmiah. Memperbanyak atau menerbitkan sebagian atau seluruh skripsi haruslah seizin Penulis.

Sitasi Skripsi ini dapat dituliskan sebagai berikut :

Herwanto, A. H. (2026). Analisis Spasio-Temporal Intensitas *Upwelling* dan Prediksi Klorofil-a Menggunakan ConvLSTM di WPP-NRI572. Skripsi. Surabaya: Universitas Airlangga.

Herwanto, A. H. (2026). *Spatio-Temporal Analysis of Upwelling Intensity and Chlorophyll-a Prediction Using ConvLSTM in WPP-NRI 572*. Undergraduate Thesis. Surabaya: Universitas Airlangga.

KATA PENGANTAR

Puji syukur penulis panjatkan ke hadirat Tuhan Yang Maha Esa atas rahmat dan hidayah-Nya sehingga skripsi yang berjudul “*Analisis Spasio-Temporal Intensitas Upwelling dan Prediksi Klorofil-A Menggunakan ConvLSTM di WPP-NRI 572*” dapat diselesaikan dengan baik sebagai salah satu syarat untuk memperoleh gelar Sarjana pada Program Studi Teknologi Sains Data, Universitas Airlangga. Dalam rangka penyelesaian proposal ini, penulis menyampaikan ucapan terima kasih kepada :

1. Orang tua atas doa, dukungan, dan kepercayaan yang diberikan kepada penulis.
2. Dosen Pembimbing 1, Dr. Dwi Rantini, S.Si., atas arahan dan bimbingannya selama proses penyusunan skripsi ini.
3. Dosen Pembimbing 2, Dr. Septia Devi Prihastuti Yasmirullah., S.Si., atas saran dan motivasi yang diberikan.
4. Penelitian yang dilakukan oleh Dr. Yudi Haditir, S.Kel., dkk. sebagai inspirasi dalam perumusan ide penelitian.
5. Teman-teman yang telah memberikan dukungan selama penyusunan skripsi.
6. Seluruh pihak yang turut membantu dan tidak dapat disebutkan satu per satu.

Penulis menyadari bahwa skripsi ini masih memiliki keterbatasan. Oleh karena itu, penulis mengharapkan kritik dan saran yang membangun demi penyempurnaan di masa mendatang. Semoga skripsi ini dapat memberikan manfaat bagi pengembangan ilmu pengetahuan.

Surabaya, Juli 2026

Penulis

ABSTRAK

**ANALISIS SPASIO-TEMPORAL INTENSITAS *UPWELLING* DAN
PREDIKSI KLOOROFIL-A MENGGUNAKAN CONVLSTM DI WPP-NRI
572**

Oleh

Andreas Hendra Herwanto

NIM: 164221064

Program Sarjana Teknologi Sains Data

Wilayah Pengelolaan Perikanan Negara Republik Indonesia (WPP-NRI) 572 merupakan wilayah perairan strategis yang dipengaruhi oleh dinamika oseanografi, khususnya fenomena *upwelling* yang berkaitan dengan penurunan suhu permukaan laut dan peningkatan konsentrasi klorofil-a sebagai indikator produktivitas primer. Penelitian ini bertujuan menganalisis intensitas *upwelling*, memprediksi konsentrasi klorofil-a menggunakan ConvLSTM, serta mengintegrasikan hasil deteksi *upwelling* dan prediksi klorofil-a untuk mengidentifikasi zona *fishing ground* potensial di WPP-NRI 572. Penelitian menggunakan data klorofil-a dan *Sea Surface Temperature* (SST) periode 2014–2024. Tahapan penelitian meliputi *masking* wilayah, rekonstruksi *missing value* menggunakan 3D-DINEOF, penanganan *outlier*, perhitungan *SST-Based Upwelling Index* (UISST), klasifikasi intensitas *upwelling* berbasis IQR, dan pemodelan ConvLSTM. Hasil menunjukkan bahwa kejadian *upwelling* valid lebih sering terakumulasi pada area *offshore* di sebelah barat Sumatra, terutama pada bagian tengah hingga selatan WPP-NRI 572. Kelas *weak upwelling* memiliki proporsi tertinggi sebesar 16,78%, diikuti *intermediate upwelling* sebesar 15,95% dan *strong upwelling* sebesar 10,17%. Model terbaik diperoleh pada konfigurasi *baseline* dengan *timestep* 3 dan *mask* spasial sebagai *channel* tambahan, dengan MAE sebesar 0,022973, RMSE sebesar 0,031717, R^2 sebesar 0,676935, dan korelasi sebesar 0,824106 pada area WPP-NRI 572. Integrasi hasil menunjukkan bahwa zona *fishing ground* potensial secara historis berada di bagian tengah hingga selatan WPP-NRI 572 pada September–November, sedangkan Januari 2025 menjadi periode prediktif awal yang paling menonjol. Penelitian ini menunjukkan bahwa integrasi UISST dan ConvLSTM dapat mendukung analisis spasio-temporal *upwelling* dan identifikasi zona *fishing ground* potensial berbasis parameter oseanografis.

Kata kunci: 3D-DINEOF, ConvLSTM, *fishing ground*, klorofil-a, *upwelling*.

ABSTRACT**SPATIO-TEMPORAL ANALYSIS OF UPWELLING INTENSITY AND CHLOROPHYLL-A PREDICTION USING CONVLSTM IN WPP-NRI 572**

By

Andreas Hendra Herwanto**Student ID Number: 164221064****Undergraduate Program in Data Science Technology**

The Fisheries Management Area of the Republic of Indonesia (WPP-NRI) 572 is a strategic marine region influenced by oceanographic dynamics, particularly upwelling, which is associated with decreased sea surface temperature and increased chlorophyll-a concentration as an indicator of primary productivity. This study aims to analyze upwelling intensity, predict chlorophyll-a concentration using ConvLSTM, and integrate upwelling detection and chlorophyll-a prediction to identify potential fishing ground zones in WPP-NRI 572. The study used chlorophyll-a and Sea Surface Temperature (SST) data from 2014 to 2024. The analytical stages included spatial masking, missing-value reconstruction using 3D-DINEOF, outlier handling, calculation of the SST-Based Upwelling Index (UISST), IQR-based upwelling intensity classification, and ConvLSTM modeling. The results showed that valid upwelling events were more frequently accumulated in offshore areas west of Sumatra, particularly in the central to southern parts of WPP-NRI 572. Weak upwelling had the highest proportion at 16.78%, followed by intermediate upwelling at 15.95% and strong upwelling at 10.17%. The best model was obtained from the baseline configuration with a timestep of 3 and a spatial mask as an additional channel, achieving an MAE of 0.022973, an RMSE of 0.031717, an R^2 of 0.676935, and a correlation coefficient of 0.824106 within the valid WPP-NRI 572 area. The integrated results indicated that potential fishing ground zones were historically concentrated in the central to southern parts of WPP-NRI 572 during September–December, while January 2025 was identified as the most prominent initial predictive period. These findings demonstrate that the integration of UISST and ConvLSTM can support the spatiotemporal analysis of upwelling and the identification of potential fishing ground zones based on oceanographic parameters in WPP-NRI 572.

Keywords: 3D-DINEOF, chlorophyll-a, ConvLSTM, fishing ground, upwelling.

DAFTAR ISI

HALAMAN JUDUL	i
LEMBAR PENGESAHAN	ii
PERNYATAAN ORISINALITAS SKRIPSI.....	iii
KETENTUAN PENGGUNAAN SKRIPSI.....	iv
KATA PENGANTAR.....	v
ABSTRAK	vi
ABSTRACT	vii
DAFTAR ISI.....	viii
DAFTAR TABEL	xi
DAFTAR GAMBAR.....	xii
BAB I PENDAHULUAN.....	1
1.1 Latar Belakang	1
1.2 Tujuan Penelitian.....	8
1.3 Rumusan Masalah	8
1.4 Manfaat Penelitian	9
1.4.1 Bagi Mahasiswa	9
1.4.2 Bagi Institusi Perguruan Tinggi dan Akademisi	9
1.4.3 Bagi Masyarakat	9
1.5 Batasan Masalah.....	10
BAB II TINJAUAN PUSTAKA.....	11
2.1 Penelitian Terdahulu.....	11
2.2 Wilayah Pengelolaan Perikanan Negara Republik Indonesia (WPP-NRI) 572....	17
2.3 Fenomena <i>Upwelling</i>	18
2.4 Parameter Oseanografi <i>Upwelling</i>	18
2.4.1 <i>Sea Surface Temperature</i> (SST).....	19
2.4.2 Klorofil-a	19
2.5 <i>Upwelling Index</i>	20
2.5.1 <i>SST-Based Upwelling Index</i> (UISST).....	21
2.6 <i>Ocean Grid Points</i>	21
2.7 <i>Coordinate Reference System</i> (CRS)	22
2.8 <i>Interquartile Range</i> (IQR).....	23
2.9 <i>Data Preprocessing</i>	23
2.9.1 <i>Handling Missing Value</i>	24
2.9.2 Normalisasi Data.....	27
2.10 <i>Deep Learning</i>	28
2.11 <i>ConvLSTM</i>	28
2.11.1 Fungsi Aktivasi Sigmoid	32
2.11.2 Fungsi Aktivasi Tanh.....	33
2.11.3 Fungsi Aktivasi Linear	33
2.11.4 <i>Optimizer</i>	34
2.12 <i>Hyperparameter Tuning</i>	38
2.12.1 <i>Bayesian Optimization</i>	38
2.12.2 <i>Tree-Structured Parzen Estimator</i> (TPE).....	40

2.13 Evaluasi Model.....	42
2.13.1 <i>Mean Squared Error</i> (MSE).....	42
2.13.2 <i>Root Mean Square Error</i> (RMSE)	42
2.13.3 <i>Mean Absolute Error</i> (MAE)	43
2.13.4 <i>R-squared</i> (R^2).....	43
2.13.5 Korelasi Pearson.....	44
BAB III METODE PENELITIAN	46
3.1 Lokasi dan Waktu.....	46
3.2 Bahan dan Alat	46
3.3 Data Penelitian	47
3.4 Tahapan Penelitian	47
3.4.1 Pengumpulan Data	49
3.4.2 <i>Merging</i> Data	49
3.4.3 <i>Masking</i> Data	50
3.4.4 <i>Handling Missing Value</i>	51
3.4.5 Analisis Deskriptif dan <i>Exploratory Data Analysis</i> (EDA).....	52
3.4.6 <i>Upwelling Detection</i>	53
3.4.7 <i>Binning</i> Intensitas <i>Upwelling</i>	54
3.4.8 <i>Outlier Handling</i>	55
3.4.9 <i>Bounding Box Cutting</i>	55
3.4.10 Normalisasi Data	55
3.4.11 Penanganan Area <i>Non-Valid</i>	56
3.4.12 <i>Spliting Data</i>	56
3.4.13 <i>Training Model</i> ConvLSTM	57
3.4.14 <i>Hyperparameter Tuning</i>	59
3.4.15 Evaluasi Model.....	60
3.4.16 <i>Forecasting</i>	60
3.4.17 Analisis Pemetaan <i>Fishing Ground</i> Optimal.....	61
BAB IV HASIL DAN PEMBAHASAN.....	62
4.1 Deskripsi Data.....	62
4.2 <i>Data Preprocessing</i>	63
4.2.1 <i>Merging Data</i>	63
4.2.2 <i>Masking Data</i>	64
4.2.3 <i>Handling Missing Value</i>	65
4.3 <i>Exploratory Data Analysis</i>	70
4.3.1 <i>Linechart</i> Data Klorofil-a dan SST.....	70
4.3.2 Distribusi Data Klorofil-a dan SST	71
4.3.3 <i>Scatter Plot</i>	73
4.3.4 Distribusi dan Sebaran Bulanan Klorofil-a.....	74
4.3.5 Distribusi dan Sebaran Bulanan SST	76
4.4 <i>Outlier Handling</i> pada Klorofil-a	78
4.5 <i>Upwelling Detection</i>	79
4.5.1 Penentuan Nilai SST_{max}	79
4.5.2 Perhitungan Nilai UISST	80
4.5.3 Validasi <i>Upwelling Valid</i>	81
4.5.4 <i>Binning</i> Intensitas <i>Upwelling</i>	81

4.6	Analisis Intensitas <i>Upwelling</i>	83
4.6.1	Sebaran Spasial Akumulatif <i>Upwelling Valid</i>	83
4.6.2	Variasi Temporal <i>Upwelling Valid</i> Bulanan dan Tahunan	84
4.6.3	Karakteristik Klorofil-a dan SST Berdasarkan Kelas Intensitas <i>Upwelling</i>	85
4.6.4	Variasi Temporal Kelas Intensitas <i>Upwelling</i>	85
4.7	<i>Preprocessing</i> Lanjutan	87
4.7.1	<i>Bounding Box Cutting</i>	87
4.7.2	Normalisasi Data.....	88
4.7.3	Penanganan Area <i>Non-Valid</i> pada Input Model ConvLSTM.....	88
4.8	Pembentukan <i>Sequence Data</i>	88
4.9	<i>Data Splitting</i>	89
4.10	Eksperimen Konfigurasi Awal ConvLSTM	90
4.10.1	Model <i>Baseline</i> ConvLSTM	90
4.10.2	Percobaan Variasi <i>Timestep</i>	92
4.10.3	Integrasi <i>Mask</i> Spasial sebagai <i>Channel</i> Tambahan	94
4.11	<i>Hyperparameter Tuning</i>	95
4.11.1	Ringkasan Hasil Trial dan Pemilihan Konfigurasi Terbaik.....	96
4.11.2	Dinamika <i>Training</i> pada Proses <i>Tuning</i>	97
4.11.3	Perbandingan Pengaruh <i>Optimizer</i>	98
4.12	Evaluasi <i>Best Model</i> Hasil <i>Tuning</i>	99
4.12.1	Kurva <i>Training</i> Model Terbaik.....	99
4.12.2	Evaluasi Model Terbaik pada Data <i>Testing</i>	100
4.13	<i>Forecasting</i>	101
4.14	Analisis Pemetaan <i>Fishing Ground Optimal</i>	104
4.15	Diskusi	107
BAB V KESIMPULAN DAN SARAN		112
5.1	Kesimpulan	112
5.2	Saran	113
DAFTAR PUSTAKA.....		115

DAFTAR TABEL

Tabel 2.1	Penelitian Terdahulu	11
Tabel 3.1	Variabel Penelitian	47
Tabel 3.2	Konfigurasi Parameter Proses 3D-DINEOF	52
Tabel 3.3	<i>Binning</i> Intensitas <i>Upwelling</i> Berbasis IQR.....	54
Tabel 3.4	Struktur dan Konfigurasi Model <i>Baseline</i>	58
Tabel 3.5	<i>Search Space Hyperparameter</i>	60
Tabel 4.1	Dimensi Spasial Data	62
Tabel 4.2	Deskripsi Data Asal Klorofil-a dan SST	62
Tabel 4.3	Dimensi <i>Dataset</i> setelah Proses <i>Merging</i>	64
Tabel 4.4	Hasil pemeriksaan CRS.....	64
Tabel 4.5	Hasil Pembentukan <i>Mask</i> Spasial	64
Tabel 4.6	Ringkasan <i>Missing Value</i> Klorofil-a dan SST	65
Tabel 4.7	Distribusi <i>Timestep</i> Berdasarkan Proporsi <i>Missing Value</i>	66
Tabel 4.8	Deskripsi Data setelah Rekonstruksi <i>Missing Value</i>	69
Tabel 4.9	Ringkasan Proses <i>Winsorizing</i> Klorofil-a	78
Tabel 4.10	Perbandingan Statistik Klorofil-a Sebelum dan Sesudah <i>Outlier Handling</i>	78
Tabel 4.11	Statistik Deskriptif SST _{max}	79
Tabel 4.12	Statistik Deskriptif UISST	80
Tabel 4.13	Statistik Deskriptif <i>upwelling</i> valid	82
Tabel 4.14	Karakteristik Klorofil-a dan SST Berdasarkan Kelas Intensitas <i>Upwelling</i>	85
Tabel 4.15	Perbandingan Dimensi Data Sebelum dan Sesudah <i>Bounding Box Cutting</i>	87
Tabel 4.16	Bentuk <i>Data Sequence</i>	89
Tabel 4.17	Hasil <i>Data Splitting</i>	89
Tabel 4.18	Hasil Evaluasi Model <i>Baseline ConvLSTM</i>	91
Tabel 4.19	Hasil Evaluasi Percobaan Variasi <i>Timestep</i>	93
Tabel 4.20	Hasil Evaluasi Variasi <i>Timestep</i> dengan <i>Mask</i> Spasial.....	94
Tabel 4.21	Lima <i>Trial</i> Terbaik Hasil <i>Hyperparameter Tuning</i>	96
Tabel 4.22	Perbandingan Pengaruh <i>Optimizer</i> pada Proses <i>Hyperparameter Tuning</i>	98
Tabel 4.23	Hasil Evaluasi Model Terbaik pada Data <i>Testing</i>	100
Tabel 4.24	Statistik Deskriptif Hasil <i>Forecasting</i> Klorofil-a	101

DAFTAR GAMBAR

Gambar 2.1	Wilayah Pengelolaan Perikanan (WPP-NRI) 572	17
Gambar 2.2	Sebaran <i>Ocean Grid Point</i> di WPP-NRI 572	22
Gambar 2.3	<i>Convolution</i> untuk Gambar dengan Satu Filter	30
Gambar 2.4	Sel ConvLSTM	31
Gambar 2.5	Diagram Struktur Model ConvLSTM.....	32
Gambar 3.1	<i>Flowcart</i> Tahapan Penelitian	48
Gambar 3.2	Mask/Cetakan Wilayah WPP-NRI 572 (<i>File GeoJSON</i>)	51
Gambar 3.3	<i>Flowchart Upwelling Detection</i>	54
Gambar 4.1	Hasil Sebelum dan Sesudah Proses <i>Masking</i>	65
Gambar 4.2	CV RMSE pada Setiap <i>Mode</i> EOF untuk Variabel Klorofil-a dan SST.....	67
Gambar 4.3	Perubahan RMSE per Iterasi pada <i>Mode</i> 30 3D-DINEOF untuk Klorofil-a dan SST	68
Gambar 4.4	Sampel Data Sebelum dan Sesudah Proses 3D DINEOF	70
Gambar 4.5	<i>Linechart</i> Data Klorofil-a dan SST pada 2014–2024	70
Gambar 4.6	Distribusi Data Klorofil-a dan SST	72
Gambar 4.7	<i>Scatter Plot</i> Korelasi Rata-rata SST dan Klorofil-a.....	73
Gambar 4.8	<i>Boxplot</i> Distribusi Bulanan Klorofil-a.....	74
Gambar 4.9	<i>Heatmap</i> Sebaran Bulanan Klorofil-a.....	75
Gambar 4.10	<i>Boxplot</i> Distribusi Bulanan SST	76
Gambar 4.11	<i>Heatmap</i> Sebaran Bulanan SST.....	77
Gambar 4.12	<i>Barplot</i> Persentase <i>Upwelling Valid</i> dan <i>non-Valid</i>	81
Gambar 4.13	<i>Barplot</i> Persentase Kelas <i>Upwelling Intensity</i>	82
Gambar 4.14	Sebaran Spasial Akumulatif <i>Upwelling Valid</i> Tahun 2014-2024.....	83
Gambar 4.15	<i>Barplot Upwelling Valid</i> Bulanan dan Tahunan	84
Gambar 4.16	<i>Barplot</i> Intensitas <i>Upwelling</i> Bulanan dan Tahunan	86
Gambar 4.17	Sampel <i>Data Training</i> setelah Penanganan Area <i>Non-Valid</i>	88
Gambar 4.18	Kurva <i>Training</i> dan <i>Validation Loss</i> serta MAE Model <i>Baseline</i> ConvLSTM	90
Gambar 4.19	Plot ACF dan PACF Klorofil-a	92
Gambar 4.20	Visualisasi <i>Channel</i> Klorofil-a dan <i>Channel Mask</i> Spasial WPP-NRI 572	94
Gambar 4.21	Perbandingan <i>Train Loss</i> dan <i>Validation Loss</i> pada Setiap <i>Trial</i>	97
Gambar 4.22	Kurva <i>Training</i> dan <i>Validation Loss</i> serta MAE pada Model Terbaik pada <i>Tuning</i>	99
Gambar 4.23	<i>Linechart</i> Rata-rata Prediksi Klorofil-a Bulanan.....	102
Gambar 4.24	Sebaran Spasial Prediksi Klorofil-a Bulanan	103

BAB I PENDAHULUAN

1.1 Latar Belakang

Indonesia merupakan negara kepulauan (*archipelago state*) terbesar di dunia yang terdiri atas 5 pulau besar dan sekitar 17.504 pulau yang tersebar di seluruh wilayah nusantara. Secara geografis, luas wilayah perairan Indonesia adalah 65% dari total luas wilayah Indonesia dengan garis pantai sepanjang 81.000 km (Anugrah & Alfarizi, 2021). Selain itu, Indonesia memiliki Zona Ekonomi Eksklusif (ZEE) seluas kurang lebih 2,7 juta km², yang memberikan hak berdaulat dalam pemanfaatan dan pengelolaan sumber daya laut. Kondisi geografis tersebut menjadikan Indonesia memiliki potensi sumber daya kelautan yang sangat besar, khususnya pada sektor perikanan tangkap dan budidaya (Rosari & Yasniwati, 2023).

Sebagai negara kepulauan dengan cakupan wilayah perairan yang luas, tidak dapat dipungkiri bahwa Indonesia memiliki peran penting dalam sektor perikanan global. Dari sisi sumber daya perikanan, berdasarkan Keputusan Menteri Kelautan dan Perikanan Nomor 19 Tahun 2022 tentang Estimasi Potensi, Jumlah Tangkapan yang Diperbolehkan, dan Tingkat Pemanfaatan Sumber Daya Ikan, tercatat bahwa potensi lestari sumber daya ikan di Indonesia secara nasional mencapai sekitar 12.011.125 ton per tahun (Anugrah & Alfarizi, 2021). Hal ini menjadikan Indonesia menempati peringkat kedua secara global setelah China berdasarkan laporan Food and Agriculture Organization (FAO) tahun 2022 mengenai tingkat produksi ikan (Rokhman dkk., 2025).

Potensi sumber daya perikanan yang besar di Indonesia, tentunya membutuhkan perhatian khusus dalam proses pengelolaan. Untuk memastikan pengelolaan sumber daya tersebut berjalan efektif, pemerintah membagi wilayah perairan Indonesia berdasarkan karakteristik ekologis, tipe habitat, dan tingkat keanekaragaman hayati (Anugrah & Alfarizi, 2021). Pembagian ini ditetapkan melalui Peraturan Menteri Kelautan dan Perikanan Nomor 18 Tahun 2014, yang menetapkan Wilayah Pengelolaan Perikanan Negara Republik Indonesia (WPP-NRI) menjadi 11 wilayah pengelolaan perikanan, salah satunya adalah WPP-NRI

572 yang mencakup perairan Samudra Hindia di sebelah barat Sumatra hingga Selat Sunda.

Sebagai salah satu wilayah perairan strategis, WPP-NRI 572 memiliki kontribusi penting terhadap perikanan nasional. Berdasarkan Keputusan Menteri Kelautan dan Perikanan Nomor 19 Tahun 2022, wilayah ini memiliki potensi sumber daya ikan mencapai sekitar 1.229.950 ton per tahun, dengan Jumlah Tangkapan yang Diperbolehkan (JTB) sebesar 860.808 ton, atau masing-masing sekitar 10% dari total potensi dan total JTB nasional (Kementerian Kelautan dan Perikanan Republik Indonesia, 2025). Selain potensinya yang besar, perairan ini juga berbatasan langsung dengan perairan internasional yang merupakan perairan laut dalam. Bagian utara, barat dan selatan WPPNRI 572, secara umum mempunyai batas terluar yang mencakup Zona Ekonomi Eksklusif (ZEE) Indonesia hingga Samudra Hindia dan sebelah timur yang mencakup pantai barat pulau Sumatra. Kondisi geografis tersebut membuat WPP-NRI 572 menjadi kawasan yang sering terjadi berbagai fenomena oseanografi (Koeshendrajana dkk. 2019; Sari dkk., 2022) .

Tingginya tingkat produksi ikan suatu wilayah sangat berkaitan erat dengan salah satu fenomena oseanografi, yaitu *upwelling* (Simanjuntak & Lin, 2022; Utama dkk., 2024). *Upwelling* adalah suatu peristiwa naiknya air laut bermassa jenis lebih besar dengan suhu yang lebih rendah bergerak dari dasar laut menuju permukaan akibat adanya pergerakan angin di atasnya, sehingga memuat massa air dengan kekayaan nutrisi meningkatkan produktivitas dan kesuburan perairan permukaan (Utama dkk., 2024). Fenomena *upwelling* ditandai dengan terjadinya penurunan *Sea Surface Temperature* (SST) dan meningkatnya konsentrasi klorofil-a (Nababan dkk., 2023). Klorofil-a merupakan pigmen utama pada fitoplankton yang digunakan sebagai indikator biomassa fitoplankton di perairan, di mana fitoplankton sendiri berperan sebagai dasar dari rantai makanan di ekosistem laut (Huynh dkk., 2020a).

Pada penelitian yang dilakukan oleh Utama dkk. (2024) di Kepulauan Karimata menemukan bahwa intensitas *upwelling* yang kuat di Kepulauan Karimata ditandai dengan peningkatan konsentrasi klorofil-a dan rendahnya suhu di

sekitar permukaan perairan. Kemudian, penelitian oleh Sari dkk. (2022) di wilayah perairan barat Sumatra (WPP-NRI 572) menunjukkan bahwa dinamika konsentrasi klorofil-a dan SST mengikuti pola kecepatan angin musiman, sehingga memicu terjadinya *upwelling* yang mendorong tingginya klorofil-a serta turunnya SST di wilayah tersebut. Temuan kedua penelitian tersebut menegaskan bahwa *upwelling* secara konsisten menghasilkan pola khas berupa meningkatnya produktivitas primer (klorofil-a) dan menurunnya SST.

Konsentrasi klorofil-a dan SST sangat dipengaruhi oleh dinamika atmosfer di Indonesia. Dinamika laut Indonesia, khususnya di WPP-NRI 572, sangat dipengaruhi oleh angin musiman atau angin monsun (Sari dkk., 2022; Simanjuntak & Lin, 2022; Supriyadi & Hidayat, 2020). Angin monsun merupakan sistem angin musiman yang terdiri atas monsun tenggara dan monsun barat laut, yang berubah arah setiap setengah tahun akibat perbedaan tekanan udara antara benua Asia dan Australia (Muskananfolo dkk., 2021). Pada penelitian Sari dkk. (2022), ditemukan bahwa ketika terjadi monsun tenggara (Juni–Agustus), wilayah selatan Sumatra menunjukkan konsentrasi klorofil-a yang tinggi akibat penguatan angin tenggara yang memicu *upwelling* di sepanjang pantai barat Sumatra bagian selatan. Sebaliknya, pada monsun barat laut (Desember–Februari), peningkatan klorofil-a justru terjadi di wilayah utara perairan Sumatra.

Selain angin monsun, variabilitas konsentrasi klorofil-a dan SST di wilayah WPP-NRI 572 juga dipengaruhi oleh fenomena El Nino Southern Oscillation (ENSO) dan Indian Ocean Dipole (IOD) (Sari dkk., 2022; Simanjuntak & Lin, 2022; Supriyadi & Hidayat, 2020). ENSO adalah fenomena interaksi laut dan atmosfer di Samudra Pasifik tropis yang dicirikan oleh peningkatan SST di wilayah ekuator tengah dan timur, yang terdiri atas dua fase utama, yaitu El Nino dan La Nina. Di sisi lain, IOD yang memiliki dua fase, IOD positif dan IOD negatif, merupakan fenomena laut dan atmosfer yang terjadi di Samudra Hindia dan ditandai oleh perbedaan SST antara Samudra Hindia bagian timur dan barat (Nababan dkk., 2023). Di WPP-NRI 572 sendiri, peningkatan konsentrasi klorofil-a dan penurunan SST cenderung terjadi ketika fase El Nino dan IOD Positif (Millenia & Helmi, 2022).

Fenomena angin musiman dan anomali angin akibat ENSO dan IOD tidak hanya memengaruhi pola arus permukaan saja, tetapi juga menggerakkan dinamika Ekman yang berperan penting dalam pembentukan *upwelling*. Tiupan angin yang melewati wilayah perairan menyebabkan terjadinya Ekman *transport*, yaitu pergerakan massa air permukaan menjauhi garis pantai akibat hembusan angin, yang menciptakan kekosongan massa air di lapisan atas. Kekosongan ini kemudian diisi oleh air dari lapisan lebih dalam melalui proses Ekman *pumping*, yaitu gerakan naiknya massa air dari lapisan Ekman (*Ekman layer*) bagian bawah yang dipicu oleh divergensi massa air di permukaan akibat *wind stress curl* dan komponen angin meridional (Fang dkk., 2025). Kedua mekanisme ini pada akhirnya memicu terjadinya *upwelling* yang ditandai oleh turunnya suhu permukaan laut dan meningkatnya konsentrasi klorofil-a di area tersebut. Hal ini diperkuat oleh temuan Bernades dkk. (2021) di Laut Arafura, yang menunjukkan bahwa Ekman *Mass Transport* (EMT) dan Ekman *Pumping Velocity* (EPV) memiliki pengaruh yang kuat terhadap SST, dimana semakin besar nilai EMT dan EPV negatif, semakin rendah nilai SST.

Penentuan suatu wilayah mengalami *upwelling* atau tidak merupakan proses yang sangat kompleks dikarenakan fenomena *upwelling* bersifat dinamis dan sangat dipengaruhi oleh variasi kondisi topografi serta karakteristik oseanografi lokal (Benazzouz dkk., 2014; García-Seoane dkk., 2023). Secara umum, kejadian *upwelling* dapat diidentifikasi melalui *Upwelling Index* (UI), yaitu suatu indikator kuantitatif yang digunakan untuk mengukur intensitas dan keberadaan proses *upwelling* di suatu wilayah. Perhitungan UI sendiri memiliki berbagai pendekatan metodologis, yang berbeda-beda tergantung pada parameter oseanografi yang digunakan. Beberapa penelitian, seperti oleh Benazzouz dkk. (2014), Naulita dkk. (2020), dan Tükenmez & Altıok (2022), menggunakan metode *SST Upwelling Index* (UISST) dan *Cross-Shore Ekman Transport* (CSET), yang diturunkan dari parameter Suhu Permukaan Laut (SST) dan *Ekman Mass Transport* (EMT). Sementara itu, Abrahams dkk. (2021) menggunakan parameter kecepatan angin (*wind speed*) yang dibandingkan dengan variabilitas SST untuk mendeteksi potensi *upwelling*. Pemanfaatan citra satelit seperti MODIS dan VIIRS juga telah banyak

digunakan untuk memetakan lokasi dan intensitas *upwelling* secara berkala (Utama dkk., 2024). Selain itu, pendekatan berbasis *unsupervised* dan *semi-supervised learning*, seperti *fuzzy c-means* (FCM), *k-means clustering*, serta integrasi K-means–SVM, telah diterapkan untuk mendeteksi *upwelling* berdasarkan parameter seperti klorofil-a dan SST (Hammond dkk., 2022; Kawada dkk., 2024; Ulhaq dkk., 2024). Beragamnya metode ini menunjukkan bahwa pendekatan untuk menentukan kejadian *upwelling* sangat dinamis dan memerlukan analisis yang lebih komprehensif.

Pendekatan berbasis konvensional, umumnya hanya mempertimbangkan pola spasial dan belum secara eksplisit mempertimbangkan urutan waktu (temporal) dari data, yang merupakan aspek penting dalam fenomena *upwelling*. Perubahan suhu permukaan laut, kecepatan angin, dan transport Ekman tidak terjadi secara instan, melainkan berkembang dalam rentang waktu tertentu yang memengaruhi munculnya serta intensitas *upwelling*. Ketidakmampuan metode konvensional untuk menangkap keterkaitan antarwaktu ini berpotensi menghasilkan deteksi yang kurang akurat, terutama pada wilayah dengan variabilitas oseanografi yang tinggi. Oleh karena itu, penelitian ini mengintegrasikan pendekatan berbasis interval waktu dengan konsep *time window* untuk mengekstraksi informasi temporal secara lebih komprehensif, sehingga dapat mengidentifikasi kejadian *upwelling* secara lebih tepat (Madriyanti, 2025; Xiao dkk., 2019).

Selain mengidentifikasi area yang dominan mengalami *upwelling*, kemampuan untuk memprediksi kejadian *upwelling* dan konsentrasi klorofil-a pada periode mendatang merupakan aspek krusial dalam penentuan *fishing ground* yang optimal, sehingga dapat meningkatkan produktivitas perikanan di WPP-NRI 572 (Kawada dkk., 2024; Simanjuntak & Lin, 2022). Prediksi tersebut penting karena distribusi sumber daya ikan sangat dipengaruhi oleh dinamika produktivitas primer yang bersifat dinamis, sehingga membutuhkan model yang mampu menangkap pola jangka panjang secara adaptif. Meskipun model fisik konvensional dapat merepresentasikan proses oseanografi melalui formulasi matematis, pendekatan ini memiliki sejumlah keterbatasan, seperti waktu komputasi yang tinggi, konfigurasi yang kompleks, serta performa prediksi yang kurang memadai untuk

memperkirakan tren jangka panjang klorofil-a (Chen dkk., 2024). Oleh karena itu, pendekatan berbasis *machine learning*, khususnya *deep learning*, menjadi semakin relevan karena mampu memodelkan hubungan nonlinier dan dinamika spasio-temporal yang kompleks secara lebih efektif. Kemampuan ini memungkinkan peningkatan akurasi prediksi kejadian *upwelling* dan variabilitas klorofil-a, yang pada akhirnya mendukung pengelolaan perikanan yang lebih adaptif, responsif, dan berkelanjutan Click or tap here to enter text.(Barzegar dkk., 2020).

Berdasarkan penelitian terdahulu, pendekatan *deep learning* telah menunjukkan kinerja unggul dalam memprediksi konsentrasi klorofil-a pada perairan dengan dinamika spasio-temporal yang kompleks. Penelitian yang dilakukan Liu dkk. (2022) di Laut China Selatan menunjukkan bahwa model CNN-LSTM mampu mempertahankan performa prediksi klorofil-a yang baik dalam jangka panjang dan lebih stabil dibandingkan LSTM dan SARIMA. Selanjutnya, Yao dkk. (2023) melakukan studi di Yellow Sea dan Bohai Sea dengan membandingkan beberapa arsitektur *deep learning*, termasuk ConvLSTM, CNN-LSTM, E3D-LSTM, dan SA-ConvLSTM, dan menemukan bahwa model berbasis ConvLSTM paling efektif dalam menangkap pola spasio-temporal klorofil-a serta menekan kesalahan *overestimation* dan *underestimation*. Temuan tersebut diperkuat oleh Kim & Cho (2025) yang menunjukkan bahwa ConvLSTM secara konsisten mengungguli CNN dan LSTM dalam memprediksi konsentrasi klorofil-a dan *harmful algal blooms* (HABs) di perairan Republik Korea, dengan nilai R^2 yang lebih tinggi dan galat prediksi yang lebih rendah. Pada konteks lokal, Madriyanti (2025) melakukan penelitian di WPP-NRI 572 menggunakan model LSTM untuk prediksi klorofil-a dan SST, yang mampu merepresentasikan pola musiman, namun masih memiliki keterbatasan dalam menangkap lonjakan ekstrem klorofil-a. Secara keseluruhan, studi-studi tersebut menegaskan bahwa model *deep learning*, khususnya model *hybrid* yang mengintegrasikan ekstraksi fitur spasial dan pemodelan temporal, seperti ConvLSTM, merupakan pendekatan yang paling efektif dan prospektif untuk prediksi klorofil-a berbasis data penginderaan jauh.

Berdasarkan penelitian terdahulu, berbagai pendekatan berbasis *deep learning* telah menunjukkan performa unggul dalam memprediksi konsentrasi

klorofil-a di perairan yang dinamis. Penelitian Chen dkk. (2024) di Danau Taihu mengembangkan model CNN-BiLSTM yang terbukti lebih akurat dibanding LSTM dan BiLSTM dalam memprediksi tren jangka panjang klorofil-a. Di perairan laut China Selatan, Liu dkk. (2022) menunjukkan bahwa model CNN-LSTM mampu mempertahankan hasil prediksi klorofil-a yang baik hingga beberapa tahun ke depan dibandingkan LSTM dan SARIMA, sementara Barzegar dkk. (2020) membuktikan keunggulan CNN-LSTM dalam menangkap fluktuasi rendah hingga tinggi klorofil-a secara lebih stabil. Pada konteks lokal, Madriyanti (2025) melakukan penelitian di WPP-NRI 572 menggunakan LSTM untuk prediksi klorofil-a dan SST yang mampu merepresentasikan pola musiman namun masih terbatas dalam menangkap lonjakan ekstrem. Secara keseluruhan, studi-studi tersebut menunjukkan bahwa model hibrida yang menggabungkan kemampuan ekstraksi fitur spasial dan temporal, seperti CNN-LSTM dan ConvLSTM, merupakan pendekatan yang paling efektif dan prospektif untuk prediksi klorofil-a.

Berdasarkan berbagai uraian di atas, dapat disimpulkan bahwa *upwelling* merupakan fenomena oseanografi yang dinamis baik secara spasial dan temporal (Benazzouz dkk., 2014; García-Seoane dkk., 2023). Analisis *upwelling* memiliki peran signifikan dalam penentuan *fishing ground* optimal dan membantu pengelolaan wilayah perairan (Kawada dkk., 2024; Simanjuntak & Lin, 2022). Namun, kompleksitas dinamika fisik dan atmosfer yang memengaruhi kejadian *upwelling*, khususnya di WPP-NRI 572, menunjukkan perlunya pendekatan yang lebih komprehensif dalam mendeteksi dan memprediksi fenomena tersebut. Oleh karena itu, penelitian ini dilakukan untuk menganalisis intensitas *upwelling* di WPP-NRI 572 dengan menggunakan *SST-Based Upwelling Index* serta memprediksi konsentrasi klorofil-a menggunakan pendekatan ConvLSTM, sebagai model *deep learning* yang mampu merepresentasikan keterkaitan spasio-temporal secara simultan.

Kebaruan penelitian ini terletak pada penerapan model ConvLSTM secara spesifik di wilayah WPP-NRI 572, yang hingga saat ini belum banyak dilakukan, mengingat penelitian terdahulu umumnya hanya berfokus pada analisis variabilitas klorofil-a tanpa pemodelan prediktif yang eksplisit atau masih terbatas pada

penggunaan LSTM berbasis temporal saja (Madriyanti, 2025; Sari dkk., 2022). Selain itu, penelitian ini memanfaatkan data terbaru selama sepuluh tahun terakhir (2014–2024) dari MODIS Ocean Color, sehingga diharapkan mampu memberikan gambaran yang lebih aktual dan representatif terhadap dinamika oseanografi wilayah tersebut. Penelitian ini juga selaras dengan tujuan pembangunan berkelanjutan, khususnya *Sustainable Development Goals* (SDGs) nomor 14, *Life Below Water*, yang menekankan pentingnya pengelolaan dan pemanfaatan sumber daya laut secara berkelanjutan. Dengan demikian, diharapkan hasil penelitian ini dapat menjadi dasar ilmiah yang kuat dalam mendukung penentuan *fishing ground* yang optimal, meningkatkan efisiensi pemanfaatan sumber daya perikanan, serta berkontribusi pada pengelolaan perikanan yang adaptif dan berkelanjutan di WPP-NRI 572.

1.2 Tujuan Penelitian

Tujuan dari penelitian ini adalah sebagai berikut :

- a. Menganalisis intensitas *upwelling* di wilayah WPP-NRI 572 berdasarkan data oseanografi periode 2014–2024.
- b. Memprediksi konsentrasi klorofil-a di WPP-NRI 572 menggunakan model ConvLSTM yang mampu menangkap pola spasio-temporal secara komprehensif.
- c. Menentukan lokasi *fishing ground* yang optimal berdasarkan hasil integrasi antara intensitas *upwelling* dan prediksi konsentrasi klorofil-a.

1.3 Rumusan Masalah

Berdasarkan latar belakang yang telah diuraikan, rumusan masalah dalam penelitian ini yaitu :

- a. Bagaimana intensitas *upwelling* di wilayah WPP-NRI 572 berdasarkan data oseanografi periode 2014–2024?
- b. Bagaimana kemampuan model ConvLSTM dalam memprediksi konsentrasi klorofil-a di WPP-NRI 572 dengan mempertimbangkan dinamika spasio-temporal data?

- c. Bagaimana hasil integrasi deteksi intensitas *upwelling* dan prediksi klorofil-a dapat digunakan untuk menentukan *fishing ground* yang optimal di WPP-NRI 572?

1.4 Manfaat Penelitian

Manfaat dari penelitian ini dapat dilihat dari berbagai perspektif, baik bagi mahasiswa, bagi institusi perguruan tinggi, maupun bagi masyarakat.

1.4.1 Bagi Mahasiswa

Penelitian ini diharapkan memberikan manfaat bagi mahasiswa, yaitu :

- a. Menambah pemahaman terkait analisis spasial dan temporal fenomena *upwelling* serta keterkaitannya dengan variabilitas klorofil-a di wilayah WPP-NRI 572.
- b. Menjadi referensi metodologis dalam penerapan model *deep learning*, khususnya ConvLSTM, untuk kajian oseanografi dan perikanan berbasis data spasio-temporal.
- c. Mendukung pengembangan keterampilan analisis data penginderaan jauh dan pemodelan prediktif dalam penelitian kelautan.

1.4.2 Bagi Institusi Perguruan Tinggi dan Akademisi

Penelitian ini diharapkan memberikan manfaat bagi perguruan tinggi dan akademisi, yaitu :

- a. Menyediakan kontribusi ilmiah dalam pengembangan kajian deteksi dan prediksi *upwelling* berbasis *deep learning* pada wilayah perairan tropis yang dinamis.
- b. Menjadi rujukan bagi penelitian lanjutan terkait pemodelan klorofil-a dan fenomena oseanografi menggunakan pendekatan ConvLSTM pada skala spasio-temporal.
- c. Memperkaya literatur akademik di bidang oseanografi fisik, penginderaan jauh kelautan, dan pemanfaatan teknologi kecerdasan buatan untuk riset perikanan.

1.4.3 Bagi Masyarakat

Penelitian ini diharapkan memberikan manfaat bagi masyarakat, yaitu :

- a. Mendukung penyusunan strategi pengelolaan sumber daya perikanan yang lebih adaptif dan berbasis data ilmiah di wilayah WPP-NRI 572.
- b. Menyediakan informasi yang lebih akurat mengenai lokasi dan waktu potensial *fishing ground* yang optimal sebagai dasar pengambilan keputusan operasional perikanan.
- c. Mendorong praktik pemanfaatan sumber daya laut yang lebih efisien, berkelanjutan, dan selaras dengan prinsip pembangunan berkelanjutan.

1.5 Batasan Masalah

Untuk memperjelas ruang lingkup penelitian, ditetapkan beberapa batasan masalah sebagai berikut :

- a. Penelitian hanya dilakukan pada wilayah Wilayah Pengelolaan Perikanan Negara Republik Indonesia (WPP-NRI) 572.
- b. Data yang digunakan dibatasi pada data *Sea Surface Temperature* (SST) dan konsentrasi klorofil-a pada periode 2014–2024 yang bersumber dari MODIS Ocean Color.
- c. Deteksi kejadian *upwelling* dilakukan berdasarkan parameter SST, sedangkan prediksi konsentrasi klorofil-a dilakukan menggunakan model ConvLSTM.

BAB II

TINJAUAN PUSTAKA

2.1 Penelitian Terdahulu

Penelitian mengenai fenomena *upwelling* dan dinamika klorofil-a telah berkembang pesat seiring meningkatnya ketersediaan data satelit dan penerapan metode pemodelan berbasis kecerdasan buatan. Secara umum, studi terdahulu terbagi ke dalam dua pendekatan utama, yaitu pendekatan prediksi berbasis *deep learning* untuk klorofil-a menggunakan arsitektur ConvLSTM, serta pendekatan fisik untuk mendeteksi intensitas *upwelling* berbasis perbedaan suhu permukaan laut (*SST-based Upwelling Index*). Kedua pendekatan ini memberikan kerangka ilmiah yang saling melengkapi untuk memahami variabilitas spasio-temporal produktivitas perairan, khususnya di wilayah pesisir dengan dinamika oseanografi yang kompleks seperti WPP-NRI 572.

Tabel 2.1 Penelitian Terdahulu

No.	Peneliti	Judul	Metode	Resolusi Temporal Data	Kesimpulan
1.	Madriyanti, 2025)	Analisis Intensitas <i>Upwelling</i> dan Prediksi SST & Klorofil-a di WPP-NRI 572	LSTM untuk prediksi SST & klorofil-a, dilanjutkan klasifikasi intensitas <i>upwelling</i> dengan IQR <i>method</i>	<i>Daily</i> kemudian diagregasi menjadi <i>weekly</i> (2007–2017)	Model LSTM mampu mengikuti pola musiman klorofil-a dan menunjukkan peningkatan signifikan saat musim timur, namun kurang optimal pada puncak ekstrem. Prediksi klorofil-a efektif digunakan sebagai indikator zona <i>upwelling</i> dan produktivitas primer tinggi di wilayah barat Sumatra.
2.	(Chen dkk., 2024)	<i>Long-term trend forecast of chlorophyll-a concentration over eutrophic lakes based on time series decomposition and deep</i>	CNN-BiLSTM dibandingkan dengan LSTM dan BiLSTM	<i>Monthly</i> (1999–2018)	Pendekatan CNN-BiLSTM memberikan performa terbaik dengan R^2 tertinggi dan RMSE terendah. Tren klorofil-a meningkat secara umum dengan

No.	Peneliti	Judul	Metode	Resolusi Temporal Data	Kesimpulan
		<i>learning algorithm</i>			respon cepat terhadap TP dan respon tertunda terhadap suhu air, menegaskan efektivitas model hibrida untuk prediksi jangka panjang.
3.	(Nadkk., 2022)	<i>Long-term prediction of sea surface chlorophyll- A concentration based on the combination of spatio-temporal features</i>	CNN-LSTM dibandingkan dengan LSTM dan SARIMA	<i>semi-monthly</i> (Januari 2002–Juni 2020)	CNN-LSTM unggul dalam prediksi klorofil-a jangka panjang dengan korelasi masih baik hingga 3 tahun ($r \approx 0,5$). Akurasi menurun setelah periode tersebut, namun model terbukti efektif menangkap dinamika spasio-temporal di laut terbuka.
4.	(Barzegar dkk., 2020)	<i>Short-term water quality variable prediction using a hybrid CNN–LSTM deep learning model</i>	Model CNN–CNN-LSTM dibandingkan CNN, LSTM, SVR, dan Decision Tree	<i>15 minutes intervals</i> (Juni 2012–Mei 2013)	Model CNN-LSTM memberikan performa terbaik untuk prediksi Klorofil-a jangka pendek, dengan galat lebih rendah dan korelasi lebih tinggi. Mampu menangkap fluktuasi rendah hingga tinggi dengan lebih stabil dibanding model tunggal.
5.	(Yao dkk., 2023a)	<i>Prediction of Sea Surface Chlorophyll-a Concentrations Based on Deep Learning and Time-Series Remote Sensing Data</i>	Perbandingan 4 model <i>deep learning</i> : ConvLSTM, CNN-LSTM, E3D-LSTM, dan SA-ConvLSTM dengan input 14 variabel lingkungan dari MODIS & ERA5	<i>Monthly</i> (2003–2021)	Model SA-ConvLSTM menunjukkan performa terbaik dalam memprediksi klorofil-a dengan koefisien korelasi tertinggi ($r = 0,887$) dan RMSE terendah dibanding model lain. SA-ConvLSTM lebih mampu menangkap pola spasio-temporal dan

No.	Peneliti	Judul	Metode	Resolusi Temporal Data	Kesimpulan
					mengurangi kesalahan <i>over/underestimation</i> yang terjadi pada ConvLSTM standar
6.	(Ruan dkk., 2025)	<i>Prediction of Sea Surface Chlorophyll-a Concentrations by Remote Sensing and Deep Learning</i>	Model ChlaPM berbasis ConvLSTM dengan modul <i>noise area filtering</i> dan <i>periodic feature extraction</i> , dibandingkan dengan RSTFE dan RSTFE+PFE	Monthly (1998–2023)	ChlaPM menunjukkan akurasi dan stabilitas terbaik untuk prediksi jangka pendek dan panjang, terutama di wilayah pesisir yang kompleks dan ber- <i>noise</i> . Model ini lebih mampu menangkap fluktuasi musiman dan mengurangi <i>underestimation</i> pada konsentrasi klorofil-a tinggi dibanding model RSTFE, sehingga lebih andal untuk pemantauan kualitas perairan dan peringatan dini bloom alga.
7.	(Kim & Cho, 2025)	<i>Enhancing environmental monitoring of harmful algal blooms with ConvLSTM image prediction</i>	ConvLSTM untuk prediksi citra spasio-temporal, lalu dibandingkan dengan CNN dan LSTM	Monthly (2006–2024)	Model ConvLSTM menunjukkan performa terbaik dalam memprediksi konsentrasi HABs/Klorofil-a dengan $R^2 = 0,83$ dan RMSE total 0,1360, lebih unggul dibanding CNN dan LSTM. Integrasi <i>kriging</i> meningkatkan akurasi peta prediksi spasial, dan ConvLSTM efektif menangkap dinamika musiman serta distribusi spasial HABs, sehingga mendukung pemantauan dini dan

No.	Peneliti	Judul	Metode	Resolusi Temporal Data	Kesimpulan
					strategi mitigasi <i>blooming</i> alga secara lebih andal.
8.	(S. Zhou dkk., 2021)	<i>ConvLSTM-Based Wave Forecasts in the South and East China Seas</i>	ConvLSTM	<i>Hourly</i> (2011–2019)	ConvLSTM mampu memprediksi SWH dua-dimensi dengan akurasi tinggi dan efisiensi komputasi yang baik. Kinerja sangat baik untuk prediksi jangka pendek (1–12 jam), sementara akurasi menurun pada horizon 24 jam. Model yang dilatih khusus dengan data badai (typhoon) memberikan hasil lebih akurat pada kondisi ekstrem dibanding model umum.
9.	(G. Zhou dkk., 2024a)	<i>A spatiotemporal attention-augmented ConvLSTM model for ocean remote sensing reflectance prediction</i>	STA-ConvLSTM (ConvLSTM dengan spatiotemporal attention / AACnv)	<i>Daily</i> (2010–2021)	Model STA-ConvLSTM mampu memprediksi <i>Remote Sensing Reflectance</i> (Rrs) secara spatiotemporal dengan akurasi tinggi hingga 7 hari ke depan. Performa terbaik dicapai pada band 443, 488, dan 555 nm ($RMSE < 3.2 \times 10^{-4} \text{ sr}^{-1}$ & $MAPE < 5.5\%$).
10.	(Benazzouz dkk., 2014)	<i>An improved coastal upwelling index from sea surface temperature using satellite-based approach - The case of the Canary Current upwelling system</i>	Mengembangkan indeks <i>upwelling</i> berbasis SST (CUIST) dengan perhitungan selesih antara $SST_{offshore}$ dan $SST_{coastal}$	<i>Weekly</i> (Juli 1987 – Desember 2011)	Indeks SST yang diusulkan mampu merepresentasikan variabilitas spasio-temporal <i>upwelling</i> secara lebih akurat dibanding metode SST konvensional maupun indeks berbasis angin. Metode ini efektif menggambarkan intensitas <i>upwelling</i> di Canary Current dan dapat diterapkan

No.	Peneliti	Judul	Metode	Resolusi Temporal Data	Kesimpulan
					secara universal pada sistem <i>upwelling</i> pesisir lainnya.
11.	(Tükenmez & Altıok, 2022a)	<i>Upwelling Index Calculations in the Aegean Sea</i>	Menggunakan UI(SST) berbasis selisih suhu antara SST_{max} dan SST_{min} pada transek tegak lurus garis pantai, dengan data SST dari ECMWF Reanalysis (1979–2018).	<i>Monthly</i> (1979–2018)	Indeks SST dapat digunakan sebagai indikator kasar fenomena <i>upwelling</i> di Laut Aegea, namun kurang presisi karena dinamika wilayah yang kompleks. Ditekankan perlunya pengembangan indeks SST yang lebih spesifik dan adaptif terhadap karakteristik regional.
12.	(Budiman dkk., 2022)	<i>A Comparison of the Three Upwelling Indices in the South Java Sea Shelf</i>	<i>SST-based Upwelling Index</i> (UISST) berdasarkan selisih suhu antara titik pesisir dan <i>offshore</i> pada bujur yang sama, dengan ambang batas anomali suhu $-0,48^{\circ}\text{C}$	<i>Daily</i> (2002–2017)	Hasil menunjukkan bahwa UISST memiliki korelasi paling kuat dengan klorofil-a dan waktu respon yang lebih cepat dibanding UI berbasis angin, sehingga metode SSTbased dinilai paling representatif untuk mendeteksi <i>upwelling</i> di Shelf Laut Selatan Jawa, khususnya wilayah timur.
13.	(Naulita dkk., 2020)	<i>Upwelling index along the South Coast of Java from satellite imagery of wind stress and sea surface temperature</i>	Menggunakan <i>SST-based Upwelling Index</i> berupa gradien suhu: SST_{max} (<i>offshore</i>) – SST_{min} (<i>coastal</i>)	<i>Weekly</i> (2006–2017)	<i>SST- based Upwelling Index</i> menunjukkan <i>upwelling</i> lebih intens dan persisten di pesisir timur Jawa, bahkan ketika UI berbasis Ekman menunjukkan nilai rendah. Disimpulkan bahwa <i>SST-based UI</i> lebih representatif pada wilayah dengan pengaruh angin tidak dominan dan mampu menangkap

No.	Peneliti	Judul	Metode	Resolusi Temporal Data	Kesimpulan
					dinamika <i>upwelling</i> lebih akurat.
14.	(Kunarso dkk., 2020a)	<i>The classification of upwelling indicators base on sea surface temperature, chlorophyll-a and upwelling index, the case study in Southern Java to Timor Waters</i>	Mengembangkan <i>Thermal Upwelling Index</i> (TUI) berbasis selisih SST antara zona pesisir dan offshore menggunakan nilai minimum TUI	<i>Monthly</i> (1997–2011)	Metode TUI yang dimodifikasi menghasilkan estimasi variabilitas musiman dan tren jangka panjang yang lebih signifikan dan stabil. Ditemukan peningkatan intensitas <i>upwelling</i> selama ± 35 tahun terakhir, menunjukkan keunggulan metode SST-based ini dalam analisis iklim <i>upwelling</i> .


Berdasarkan penelitian terdahulu pada Tabel 2.1, kelompok studi ConvLSTM dan model hibrida berbasis *deep learning* (penelitian ke-1 hingga 9) secara konsisten menunjukkan kemampuan unggul dalam menangkap pola spasio-temporal klorofil-a, baik untuk prediksi jangka pendek maupun panjang, dengan kinerja yang lebih stabil pada kondisi perairan kompleks dan memiliki tingkat *noise* yang tinggi. Sementara itu, kelompok studi deteksi *upwelling* berbasis SST (penelitian ke-10 hingga 14) menunjukkan bahwa metode *SST-based Upwelling Index* terbukti efektif dalam mendeteksi intensitas *upwelling* melalui perbedaan suhu *offshore* dan suhu *coastal*, serta menunjukkan korelasi yang kuat dengan dinamika klorofil-a sebagai indikator produktivitas primer.

Pada penelitian ini, penelitian terdahulu yang dilakukan oleh Madriyanti (2025), penelitian ke-1, dijadikan acuan utama karena kesamaan lokasi di WPP-NRI 572, namun terdapat perbedaan mendasar pada metode dan rentang waktu data. Penelitian Madriyanti (2025) menggunakan LSTM konvensional untuk regresi dan klasifikasi intensitas *upwelling* dengan periode data 2007–2017, sedangkan pada penelitian ini mengadopsi model ConvLSTM untuk prediksi klorofil-a yang lebih adaptif terhadap pola spasio-temporal serta analisis intensitas *upwelling* berbasis SST dengan rentang data 2014–2024 (Na dkk., 2022). Perbedaan ini diharapkan

menghasilkan estimasi yang lebih akurat dan representatif terhadap variabilitas oseanografi jangka panjang di WPP-NRI 572.

2.2 Wilayah Pengelolaan Perikanan Negara Republik Indonesia (WPP-NRI) 572

Wilayah Pengelolaan Perikanan Negara Republik Indonesia (WPP-NRI) 572 merupakan salah satu kawasan perairan strategis yang mencakup perairan Samudra Hindia bagian barat Sumatra hingga Selat Sunda. Pada Gambar 2.1, dapat dilihat WPP-NRI 572 berbatasan langsung dengan perairan internasional dan laut dalam melalui Zona Ekonomi Eksklusif (ZEE) Indonesia di bagian utara, barat, dan selatan, serta pantai barat Pulau Sumatra di bagian timur yang dapat dilihat (Koeshendrajana dkk. 2019). Kondisi geografis tersebut membuat WPP-NRI 572 menjadi kawasan yang sering terjadi berbagai fenomena oseanografi.



Gambar 2.1 Wilayah Pengelolaan Perikanan (WPP-NRI) 572
(Sumber : Kementerian Kelautan dan Perikanan Republik Indonesia, 2014)

Berdasarkan Keputusan Menteri Kelautan dan Perikanan Nomor 19 Tahun 2022, wilayah ini memiliki potensi sumber daya ikan sekitar 1.229.950 ton per tahun dengan Jumlah Tangkapan yang Diperbolehkan (JTB) sebesar 860.808 ton, atau masing-masing sekitar 10% dari total potensi dan JTB nasional, Komoditas utama yang mendominasi wilayah ini meliputi ikan pelagis kecil seperti tembang, teri, dan selar, serta ikan pelagis besar seperti tuna, tongkol, dan cakalang, disertai

sumber daya bernilai ekonomi lainnya seperti udang dan cumi-cumi. Hal ini menjadikannya sebagai pusat perikanan yang berkontribusi signifikan terhadap produksi nasional (Kementerian Kelautan dan Perikanan Republik Indonesia, 2025).

2.3 Fenomena *Upwelling*

Fenomena *upwelling* merupakan proses oseanografi yang ditandai oleh naiknya massa air laut dari lapisan bawah yang bersuhu lebih rendah dan bermassa jenis lebih besar menuju permukaan akibat dorongan pergerakan angin di atasnya. Proses ini menyebabkan suplai nutrisi dalam jumlah tinggi ke lapisan permukaan, sehingga memicu peningkatan produktivitas primer yang ditunjukkan oleh kenaikan konsentrasi klorofil-a serta penurunan suhu permukaan laut (SST) (Utama dkk., 2024). Secara ekologis, *upwelling* berperan penting dalam meningkatkan kesuburan perairan dan mendukung keberadaan fitoplankton sebagai dasar rantai makanan laut, yang pada akhirnya berdampak langsung terhadap kelimpahan sumber daya ikan di wilayah tersebut (Simanjuntak & Lin, 2022.)

Di WPP-NRI 572, fenomena *upwelling* sangat dipengaruhi oleh dinamika angin musiman (monsun) dan variabilitas iklim skala besar seperti ENSO dan IOD. Pada periode monsun tenggara (Juni–Agustus), penguatan angin memicu proses *upwelling* di sepanjang pantai barat Sumatra bagian selatan yang ditandai oleh peningkatan signifikan konsentrasi klorofil-a, sementara pada monsun barat laut (Desember-Februari) pola peningkatan klorofil-a cenderung bergeser ke wilayah utara perairan Sumatra. Kondisi El Nino dan IOD positif juga berkontribusi dalam memperkuat intensitas *upwelling* yang ditandai dengan penurunan SST dan peningkatan klorofil-a secara spasial maupun temporal. Interaksi kompleks antara pola angin musiman, fluktuasi SST, serta pengaruh ENSO dan IOD membentuk karakteristik oseanografi yang produktif di WPP-NRI 572, sehingga pemantauan dan prediksi kejadian *upwelling* menjadi aspek penting dalam penentuan zona penangkapan ikan (*fishing ground*) yang optimal untuk mendukung pengelolaan perikanan berkelanjutan (Sari dkk., Nababan dkk., 2023; Kawada dkk., 2024).

2.4 Parameter Oseanografi *Upwelling*

Fenomena *upwelling* merupakan proses oseanografi yang sangat dipengaruhi oleh interaksi antara parameter fisik dan biologis perairan, terutama

SST dan konsentrasi klorofil-a (Nababan dkk., 2023). SST berperan sebagai indikator utama perubahan massa air yang mencerminkan naiknya air laut yang lebih dingin dari lapisan bawah ke permukaan, sedangkan klorofil-a merepresentasikan respons biologis perairan terhadap peningkatan suplai nutrisi akibat proses tersebut. Kombinasi kedua parameter ini digunakan secara luas untuk mengidentifikasi, memetakan, serta mengevaluasi intensitas dan dinamika *upwelling*, karena mampu menggambarkan hubungan langsung antara proses fisik oseanografi dan produktivitas primer perairan (Kunarso dkk., 2020).

2.4.1 *Sea Surface Temperature (SST)*

Sea Surface Temperature (SST) atau suhu permukaan laut merupakan salah satu parameter kunci dalam kajian oseanografi fisik yang secara luas dimanfaatkan untuk mengidentifikasi kejadian *upwelling*. Fenomena ini umumnya ditandai oleh penurunan SST yang relatif signifikan sebagai akibat dari naiknya massa air yang lebih dingin dari lapisan bawah menuju permukaan melalui proses Ekman (Fang dkk., 2025). Oleh karena itu, pemantauan SST berperan penting dalam memahami dinamika perairan serta dalam mengestimasi tingkat kesuburan dan produktivitas perikanan suatu wilayah.

SST memainkan peran penting sebagai variabel utama dalam analisis deteksi *upwelling* karena mampu merepresentasikan perubahan kondisi termal yang berkaitan langsung dengan proses sirkulasi massa air (Kunarso dkk., 2020). Selain itu, SST juga merupakan faktor oseanografi yang memengaruhi distribusi dan ketersediaan sumber daya ikan. Dalam konteks penentuan daerah penangkapan ikan potensial, penelitian Paillin dkk. (2020) menyatakan bahwa kisaran suhu optimal berada pada rentang 29-30 °C sebagai indikator perairan yang potensial, sedangkan suhu di bawah 29°C dikategorikan sebagai kurang potensial. Rentang suhu ini relevan untuk wilayah tropis, termasuk WPP-NRI 572, yang secara umum dicirikan oleh kondisi SST yang relatif hangat.

2.4.2 *Klorofil-a*

Klorofil-a merupakan pigmen utama pada fitoplankton yang digunakan sebagai indikator biomassa fitoplankton di perairan, di mana fitoplankton sendiri berperan sebagai dasar dari rantai makanan di ekosistem laut (Huynh dkk., 2020a).

Konsentrasi klorofil-a biasanya dimanfaatkan sebagai parameter untuk merepresentasikan produktivitas primer perairan karena menggambarkan tingkat kelimpahan fitoplankton pada suatu kawasan laut tertentu. Sebagai organisme produsen, fitoplankton memegang peranan fundamental dalam menopang keberlangsungan rantai makanan laut, sehingga pola sebaran klorofil-a dapat mencerminkan tingkat kesuburan perairan secara langsung (Ningrum & Zainuri, 2022). Di wilayah pesisir, tingginya konsentrasi klorofil-a juga kerap berkorelasi dengan masuknya pasokan nutrisi dari daratan yang terbawa melalui aliran sungai-sungai besar (Astuti dkk., 2024).

Selain merepresentasikan tingkat produktivitas perairan, klorofil-a juga berfungsi sebagai indikator penting dalam pendeteksian fenomena *upwelling*. Proses naiknya massa air yang kaya nutrisi dari lapisan bawah menuju permukaan mendorong peningkatan kadar klorofil-a secara signifikan. Variasi konsentrasinya turut dipengaruhi oleh intensitas cahaya matahari, di mana ketersediaan unsur hara yang memadai serta kondisi pencahayaan yang optimal akan meningkatkan laju pertumbuhan fitoplankton dan memperkuat kesuburan perairan. Informasi mengenai distribusi klorofil-a juga memiliki peran strategis dalam mengestimasi potensi sumber daya ikan, mengingat fitoplankton merupakan sumber pakan utama bagi zooplankton dan ikan pelagis kecil. Oleh sebab itu, nilai klorofil-a kerap digunakan sebagai salah satu indikator dalam penentuan wilayah penangkapan ikan potensial (*fishing ground*), di mana konsentrasi yang tinggi umumnya menunjukkan peluang keberadaan ikan yang lebih besar di suatu perairan (Febryanti, 2023).

2.5 Upwelling Index

Upwelling index (UI) merupakan parameter kuantitatif yang digunakan untuk menggambarkan intensitas proses *upwelling* melalui pendekatan fisik maupun termal. Secara fisik, indeks ini dihitung berdasarkan transpor massa air lintang pantai yang diinduksi oleh gaya Coriolis melalui mekanisme Ekman, sehingga UI berbasis angin merepresentasikan fluks air yang secara teoritis terdorong menjauhi pantai akibat stres angin di permukaan laut. Selain itu, pendekatan berbasis suhu permukaan laut (SST) juga banyak digunakan, di mana perbedaan suhu antara perairan pesisir yang lebih dingin dan perairan lepas yang

lebih hangat pada lintang yang sama dimanfaatkan sebagai representasi intensitas *upwelling*, karena pendinginan permukaan mencerminkan naiknya massa air dingin kaya nutrisi dari lapisan bawah (Benazzouz dkk., 2014; Tükenmez & Altıok, 2022a). Dalam penelitian ini, pendekatan yang digunakan adalah UI berbasis SST (UISST) sebagai indikator utama, mengingat parameter ini mampu menggambarkan respons termal aktual di permukaan laut secara lebih langsung dan relevan terhadap karakteristik dinamika lokal perairan yang dikaji.

2.5.1 *SST-Based Upwelling Index (UISST)*

Indeks *upwelling* berbasis suhu permukaan laut atau *SST-Based Upwelling Index* (UISST) digunakan untuk merepresentasikan intensitas *upwelling* melalui perbedaan suhu antara perairan pesisir dan perairan lepas pada lintang yang sama. Secara konseptual, UISST dihitung sebagai selisih antara suhu permukaan laut di wilayah lepas (*SST offshore* atau SST_{max}) dan suhu di wilayah pesisir (*SST coastal* atau SST_{min}), yang secara matematis dinyatakan pada Persamaan (2.1).


$$UISST = SST_{max} - SST_{min} \quad (2.1)$$

Dalam konteks ini, SST_{max} merepresentasikan suhu perairan lepas yang relatif lebih hangat dan tidak terpengaruh langsung oleh proses *upwelling*, sementara SST_{min} menggambarkan suhu minimum di wilayah pesisir sebagai respons langsung dari pendinginan permukaan akibat suplai air dingin dari bawah. Perbedaan kedua parameter tersebut menjadi indikator termal yang efektif untuk menangkap intensitas *upwelling* secara spasial dan temporal, serta dinilai lebih mampu merepresentasikan respons aktual proses *upwelling* dibanding indeks berbasis angin, khususnya di wilayah laut yang memiliki kompleksitas dinamika oseanografi tinggi seperti WPP-NRI 572 (Benazzouz dkk., 2014; Tükenmez & Altıok, 2022a).

2.6 *Ocean Grid Points*

Ocean grid points merupakan representasi spasial berupa kumpulan titik *grid* yang tersusun secara teratur berdasarkan sistem koordinat lintang dan bujur, yang digunakan untuk merepresentasikan kondisi oseanografi pada luasan wilayah tertentu. Setiap *grid point* mewakili nilai parameter laut hasil observasi satelit atau hasil interpolasi data pada resolusi spasial tertentu dan pada interval waktu tertentu

(Muskananfola dkk., 2021). Penggunaan *ocean grid points* memungkinkan data satelit yang awalnya memiliki sebaran spasial yang tidak merata, diubah menjadi data berpola *grid* yang seragam, sehingga setiap lokasi memiliki deret waktu yang konsisten dan dapat dianalisis secara spasio-temporal. Dengan demikian, *ocean grid point* berfungsi sebagai unit analisis spasial dasar dalam kajian oseanografi, khususnya untuk analisis spasio-temporal, pemetaan fenomena laut, serta pemodelan numerik dan pembelajaran mesin (Dash dkk., 2025). Berikut gambaran *grid ocean points* yang digunakan dalam analisis ditunjukkan pada Gambar 2.2.



Gambar 2.2 Sebaran *Ocean Grid Point* di WPP-NRI 572 (Sumber : Madriyanti, 2025)

Dalam penelitian ini, *ocean grid points* disusun dengan resolusi spasial sebesar $0,05^{\circ} \times 0,05^{\circ}$ pada wilayah WPP-NRI 572, yang mencakup perairan Samudra Hindia bagian barat Sumatra hingga selatan Jawa. Pemilihan resolusi ini didasarkan pada resolusi asli dataset satelit yang bersumber dari MODIS Ocean Color. Setiap *grid point* merepresentasikan kondisi rata-rata parameter oseanografi pada luasan grid tersebut dan membentuk deret waktu yang kontinu. *Ocean grid points* ini digunakan sebagai dasar analisis intensitas *upwelling* dan prediksi klorofil-a di WPP-NRI 572.

2.7 *Coordinate Reference System (CRS)*

Coordinate Reference System (CRS) merupakan sistem acuan koordinat yang digunakan untuk mendefinisikan posisi suatu objek atau lokasi di permukaan bumi secara konsisten. Dalam data geospasial, CRS berperan penting karena menjadi dasar dalam penyelarasan, visualisasi, dan analisis data yang berasal dari

berbagai sumber. Penggunaan data geografis yang tepat membutuhkan CRS yang benar, karena CRS berfungsi sebagai penghubung utama dalam integrasi data geospasial serta mendukung interoperabilitas antardata dan antarpengguna. Apabila CRS tidak sesuai, salah, atau tidak terdefinisi, maka data spasial dapat mengalami kesalahan posisi ketika digabungkan dengan data lain, sehingga berpotensi memengaruhi hasil analisis (Stal dkk., 2022).

2.8 *Interquartile Range (IQR)*

Interquartile Range (IQR) merupakan ukuran statistik deskriptif yang digunakan untuk menggambarkan tingkat sebaran data berdasarkan rentang antara kuartil pertama (Q_1) dan kuartil ketiga (Q_3). IQR merepresentasikan variasi data pada bagian tengah distribusi, sehingga relatif tidak dipengaruhi oleh nilai ekstrem (*outlier*) (Ahmad, 2012). Secara matematis, IQR didefinisikan sebagai selisih antara Q_3 dan Q_1 , yang masing-masing merepresentasikan persentil ke-75 dan persentil ke-25 dari suatu distribusi data. Selain digunakan sebagai ukuran dispersi, IQR juga dapat dimanfaatkan sebagai pendekatan binning statistik untuk mengelompokkan data kontinu ke dalam beberapa kategori berdasarkan karakteristik distribusinya (Madriyanti, 2025). Perhitungan IQR dinyatakan pada Persamaan (2.2).

$$IQR = Q_3 - Q_1 \quad (2.2)$$

Keterangan :

IQR : Interquartile Range,

Q_1 : Kuartil pertama (persentil ke-25),

Q_3 : Kuartil ketiga (persentil ke-75).

2.9 *Data Preprocessing*

Tahap *preprocessing* data merupakan langkah awal yang bertujuan untuk meningkatkan kualitas data sebelum dilakukan analisis oseanografi dan pemodelan lebih lanjut. Proses ini diperlukan untuk memastikan data yang digunakan bersih, konsisten, dan berada pada skala yang sesuai, sehingga mampu merepresentasikan kondisi perairan secara akurat dan mengurangi potensi bias dalam hasil analisis (Madriyanti, 2025). Pada penelitian ini, *preprocessing* difokuskan pada penanganan

missing value dan normalisasi data sebagai upaya untuk menjaga validitas dan stabilitas model yang dikembangkan.

2.9.1 Handling Missing Value

Handling missing value adalah proses memperlakukan data yang hilang agar dataset tetap representatif dan tidak menyebabkan bias pada model (Ulhaq dkk., 2024). Secara umum, *missing value* merupakan kondisi di mana data tidak tersedia atau tidak terdefinisi pada beberapa titik pengamatan, yang dapat disebabkan oleh keterbatasan sensor, tutupan awan (*cloud cover*), efek *sun glint*, serta berbagai kondisi pengamatan lain yang tidak mendukung (G. Zhou dkk., 2024a). Keberadaan *missing value* berpotensi menurunkan akurasi analisis dan mengganggu stabilitas proses pelatihan model, sehingga perlu ditangani secara tepat.

Dalam penelitian ini, *missing value* dibedakan berdasarkan lokasi spasialnya. *Missing value* yang berada di luar batas perairan WPP-NRI 572, yang umumnya merepresentasikan wilayah daratan atau area perairan di luar cakupan analisis, diperlakukan sebagai nilai 0, sehingga area tersebut secara eksplisit dikecualikan dari analisis oseanografi. Sementara itu, *missing value* yang berada di dalam WPP-NRI 572 diimputasi dengan menggunakan metode *3D-Data Interpolating Empirical Orthogonal Functions* (DINEOF) sebagai teknik rekonstruksi data hilang berbasis pola dominan variabilitas spasial dan temporal.

2.9.1.1 Data Interpolating Empirical Orthogonal Functions (DINEOF)

Empirical Orthogonal Functions (EOF) merupakan metode dekomposisi statistik yang digunakan untuk mengekstraksi pola dominan variabilitas spasial dan temporal dalam dataset geofisika dengan memecah data spasio-temporal menjadi sejumlah mode ortogonal yang saling independen, di mana setiap mode merepresentasikan kontribusi variansi tertentu dari keseluruhan data (Neha & Pasari, 2022). Dalam kajian oseanografi, EOF banyak diterapkan untuk menganalisis dinamika parameter laut seperti SST dan klorofil-a karena kemampuannya mereduksi dimensi data berdimensi tinggi tanpa menghilangkan informasi utama. *Data Interpolating Empirical Orthogonal Functions* (DINEOF) merupakan pengembangan dari EOF yang dirancang untuk merekonstruksi data

yang memiliki *missing value* tanpa memerlukan informasi tambahan (*no prior information*), dengan memanfaatkan mode EOF dominan melalui proses dekomposisi iteratif, sehingga mampu mengisi *missing value* secara konsisten berdasarkan pola spasio-temporal (Li dkk., 2022; Yang dkk., 2021a).

Keunggulan utama metode DINEOF dibandingkan interpolasi konvensional terletak pada kemampuannya mempertahankan struktur fisik dan dinamika alami data oseanografi tanpa bergantung pada asumsi linearitas lokal maupun parameter eksternal. Pendekatan ini memungkinkan rekonstruksi data yang lebih stabil dan realistis, terutama pada dataset dengan tingkat *missing value* yang tinggi (Li dkk., 2022). Penelitian Yang dkk. (2021) menunjukkan bahwa DINEOF efektif digunakan untuk merekonstruksi SST, klorofil-a, dan parameter oseanografi lainnya, serta mampu meningkatkan kualitas analisis variabilitas spasio-temporal dan pemodelan lanjutan berbasis data satelit.

Secara matematis, metode DINEOF diawali dengan menyusun data oseanografi ke dalam sebuah matriks spasio-temporal X berukuran $m \times n$, dimana m mempresentasikan *ocean grid points* dan n mempresentasikan jumlah waktu pengamatan. Matriks X kemudian didekomposisi menggunakan *Singular Value Decomposition* (SVD), sebagaimana ditunjukkan pada Persamaan (2.3).

$$X = USV^T \quad (2.3)$$

Selanjutnya, rekonstruksi data dilakukan dengan menggunakan sejumlah k mode EOF sebagaimana ditunjukkan pada Persamaan (2.4).

$$X_{ij}^{re} = \sum_{p=1}^k S_p U_{ip} V_{jp} \quad (2.4)$$

Keterangan :

- X : matriks data spasio-temporal berukuran $m \times n$,
- U : matriks EOF spasial,
- S : matriks nilai singular,
- V : matriks EOF temporal ,
- V^T : *transpose* dari matriks V ,
- X_{ij}^{re} : nilai hasil rekonstruksi pada grid ke- i dan waktu ke- j ,

- k : jumlah total *mode* EOF,
 p : indeks penomoran mode EOF,
 S_p : nilai singular *mode* ke- p ,
 U_{ip} : komponen EOF spasial pada *grid* ke- i mode ke- p ,
 V_{jp} : komponen EOF temporal pada waktu ke- j mode ke- p .

Proses rekonstruksi dilakukan secara iteratif hingga mencapai kondisi konvergensi, dengan jumlah mode EOF optimal ditentukan berdasarkan minimisasi galat rekonstruksi menggunakan *Root Mean Square Error* (RMSE), yang dirumuskan pada Persamaan (2.31) (Li dkk., 2022).

2.9.1.2 3D-DINEOF

Metode 3D-DINEOF merupakan pengembangan dari metode DINEOF yang memperluas arah dekomposisi data dari pendekatan dua dimensi menjadi pendekatan multidimensi. Metode ini dirancang untuk merekonstruksi *missing value* pada data oseanografi yang berbentuk tiga dimensi, yaitu *longitude*, *latitude*, dan *time*. Berbeda dengan DINEOF konvensional yang umumnya membentuk data spasio-temporal menjadi satu matriks dua dimensi, 3D-DINEOF melakukan proses dekomposisi EOF secara bergantian pada tiga arah utama tersebut. Kelebihan utama pendekatan ini adalah kemampuannya memanfaatkan korelasi multidimensi yang tidak sepenuhnya tertangkap oleh DINEOF klasik, sehingga informasi pada bidang *longitude-time*, *latitude-time*, dan *latitude-longitude* dapat digunakan secara lebih menyeluruh dalam proses rekonstruksi (M. Yu dkk., 2026). Penelitian M. Yu dkk. (2026) menjelaskan bahwa 3D-DINEOF mampu mengurangi keterbatasan DINEOF klasik yang cenderung kehilangan detail spasial, mengalami penurunan stabilitas pada *missing rate* tinggi, dan lebih rentan menghasilkan rekonstruksi yang terlalu halus.

Secara konseptual, data oseanografi pada 3D-DINEOF dapat dipandang sebagai tensor tiga dimensi $D \in \mathbb{R}^{T \times I \times J}$, dengan D merepresentasikan kumpulan data variabel oseanografi dalam bentuk tensor tiga dimensi, sedangkan setiap elemennya menunjukkan nilai variabel pada kombinasi waktu, posisi *latitude*, dan posisi *longitude* tertentu. Selanjutnya, T menunjukkan jumlah waktu pengamatan, I menunjukkan jumlah grid *latitude*, dan J menunjukkan jumlah grid *longitude*. Lalu

pada setiap arah dekomposisi, tensor tersebut dibentuk ulang menjadi matriks dua dimensi $X^{(a)}$, kemudian didekomposisi menggunakan *Singular Value Decomposition* (SVD), sebagaimana ditunjukkan pada Persamaan (2.3). Lalu rekonstruksi *missing value* dilakukan dengan menggunakan sejumlah *mode* EOF dominan. Nilai hasil rekonstruksi pada setiap arah dekomposisi dirumuskan dengan menggunakan Persamaan (2.4).

Secara teknis, perbedaan 3D-DINEOF dan DINEOF konvensional terletak pada skema pembentukan matriks, arah dekomposisi, dan proses iterasinya. Pada DINEOF konvensional, data tiga dimensi umumnya diringkas menjadi satu matriks dua dimensi sehingga proses SVD dan rekonstruksi EOF hanya dilakukan pada satu susunan spasio-temporal. Sebaliknya, 3D-DINEOF tetap memandang data sebagai struktur tiga dimensi, kemudian membentuk ulang data secara bergantian sesuai arah *longitude*, *latitude*, dan *time*. Pada setiap arah, prosedur DINEOF standar tetap digunakan, tetapi hasil rekonstruksi dari satu arah dijadikan masukan untuk dekomposisi arah berikutnya. Selain itu, 3D-DINEOF juga membedakan proses konvergensi menjadi konvergensi internal pada tiap arah dekomposisi dan konvergensi keseluruhan setelah satu siklus rekonstruksi tiga arah selesai dilakukan. Dengan mekanisme tersebut, 3D-DINEOF tidak mengubah rumus dasar DINEOF, tetapi memperluas cara penerapannya agar informasi spasial dan temporal dari beberapa orientasi data dapat dimanfaatkan secara lebih optimal (M. Yu dkk., 2026).

2.9.2 Normalisasi Data

Normalisasi data merupakan proses transformasi nilai data ke dalam skala tertentu agar setiap variabel memiliki rentang nilai yang sebanding dan tidak saling mendominasi dalam proses analisis maupun pemodelan. Proses ini bertujuan untuk meningkatkan stabilitas numerik, mempercepat konvergensi model, serta mencegah bias yang disebabkan oleh perbedaan skala antarvariabel (Xiao dkk., 2019). Dalam penelitian, metode normalisasi data yang digunakan adalah *Min-Max Scalling*.

Min-Max Scalling merupakan metode normalisasi yang digunakan untuk mentransformasikan data ke dalam rentang tertentu, umumnya antara 0 hingga 1, tanpa mengubah pola distribusi aslinya. Teknik ini bertujuan untuk menyamakan

skala antar variabel sehingga tidak ada variabel yang mendominasi proses pembelajaran model akibat perbedaan rentang nilai (Na dkk., 2022). Normalisasi *Min-Max* dirumuskan pada Persamaan (2.5).

$$X' = \frac{X - X_{min}}{X_{max} - X_{min}} \quad (2.5)$$

Keterangan :

X' : nilai hasil normalisasi,

X : nilai asli,

X_{min} : nilai minimum pada data,

X_{max} : nilai maksimum pada data.

2.10 *Deep Learning*

Deep Learning merupakan cabang dari *Machine Learning* yang menggunakan arsitektur jaringan saraf tiruan (*Artificial Neural Networks*) dengan banyak lapisan tersembunyi (*multiple hidden layers*) untuk meniru cara kerja otak manusia dalam memproses dan memahami data. Setiap lapisan pada jaringan ini melakukan transformasi nonlinear terhadap input data dan mengekstraksi representasi fitur yang semakin kompleks di setiap lapisan berikutnya (Vargas dkk., 2017). Secara umum, *deep learning* bekerja dengan prinsip hierarki pembelajaran, di mana sistem belajar mengenali pola dari data mentah seperti gambar, suara, atau teks tanpa perlu intervensi manusia untuk menentukan fitur secara manual. Teknik ini telah memberikan kemajuan besar dalam berbagai bidang seperti pengenalan wajah, pengenalan suara, *natural language processing*, *time series analysis*, dan sistem rekomendasi (Harthik & Raju, 2021).

2.11 *ConvLSTM*

ConvLSTM merupakan arsitektur *deep learning* inovatif yang diperkenalkan oleh Shi dkk. (2015) sebagai solusi untuk memodelkan data yang memiliki ketergantungan spasial dan temporal secara simultan. Novelti utama *ConvLSTM* terletak pada penggabungan operasi konvolusi khas *Convolutional Neural Network* (CNN) dengan mekanisme memori *Long Short-Term Memory* (LSTM) dalam satu kerangka terpadu, sehingga mampu mempertahankan struktur spasial citra sekaligus mempelajari dinamika temporalnya. Berbeda dengan LSTM

konvensional yang menggunakan operasi *fully connected* sehingga mengabaikan hubungan spasial antar piksel, ConvLSTM mengganti operasi perkalian matriks dengan operasi konvolusi pada transisi *input-ke-state* dan *state-ke-state*. Pendekatan ini memungkinkan model memahami bagaimana pola spasial pada suatu waktu berubah secara berurutan, dan menjadikannya sangat relevan untuk memodelkan fenomena kelautan seperti distribusi klorofil-a yang dipengaruhi proses fisik seperti *upwelling*, arus laut, dan variabilitas musiman (Ruan dkk., 2025).

Secara matematis, mekanisme ConvLSTM mempertahankan struktur dasar LSTM yang terdiri atas *forget gate*, *input gate*, *output gate*, dan *cell state*, namun seluruh operasi dilakukan dalam domain spasial menggunakan konvolusi (Kim & Cho, 2025). Formulasi matematis ConvLSTM dinyatakan pada Persamaan (2.6) hingga Persamaan (2.11).

$$i_t = \sigma(W_{xi} * X_t + W_{hi} * H_{t-1} + W_{ci} \circ H_{t-1} + b_i) \quad (2.6)$$

$$f_t = \sigma(W_{xf} * X_t + W_{hf} * H_{t-1} + W_{cf} \circ H_{t-1} + b_f) \quad (2.7)$$

$$\tilde{C}_t = \tan h(W_{xc} * X_t + W_{hc} * H_{t-1} + b_c) \quad (2.8)$$

$$C(t) = f_t \circ C_{t-1} + i_t \circ \tilde{C}_t \quad (2.9)$$

$$o_t = \sigma(W_{xo} * X_t + W_{ho} * H_{t-1} + W_{co} \circ C_t + b_o) \quad (2.10)$$

$$H_t = o_t \circ \tanh(C_t) \quad (2.11)$$

Keterangan :

X_t : *input* pada waktu ke- t ,

H_t : *hidden state* pada waktu ke- t ,

C_t : *cell state* (memori jangka panjang),

i_t, f_t, o_t : *input gate, forget gate, output gate*,

W : kernel konvolusi,

W_x, W_h, W_c : kernel konvolusi input saat ini, kernel konvolusi *hidden state* sebelumnya, dan bobot *peephole* dari *cell state*,


$*$: operator konvolusi,

$\circ$: perkalian elemen (*Hadamard product*),

σ : fungsi aktivasi sigmoid,


$\tanh$: fungsi aktivasi hiperbolik.

Konsep dasar konvolusi yang menjadi fondasi ConvLSTM dapat dipahami melalui ilustrasi pada Gambar 2.3, di mana sebuah filter (3×3) digeser di atas citra sumber. Setiap nilai piksel keluaran dihitung dari operasi perkalian elemen antara matriks filter dan area lokal pada citra, kemudian dijumlahkan untuk menghasilkan satu nilai baru pada citra tujuan. Proses ini memungkinkan model mengekstraksi fitur lokal seperti tepi, gradien, atau pola tertentu. Dalam konteks data kelautan, proses konvolusi ini berfungsi untuk mengenali distribusi spasial klorofil-a, seperti area dengan konsentrasi tinggi yang menunjukkan potensi daerah produktif atau zona *upwelling* aktif (Fredyan, 2020).




Gambar 2.3 *Convolution* untuk Gambar dengan Satu Filter (Sumber : Fredyan, 2020)

Struktur internal sel ConvLSTM yang ditunjukkan pada Gambar 2.4 yang menggambarkan bagaimana operasi konvolusi digabungkan dengan mekanisme memori LSTM. Input X_t dan hidden state sebelumnya H_{t-1} diproses melalui kernel konvolusi untuk menghitung nilai pada setiap gate (*input*, *forget*, dan *output*), kemudian dikombinasikan dengan *cell state* C_{t-1} untuk menghasilkan *cell state* baru C_t dan *hidden state* H_t . Adanya *peephole connection* dan *batch normalization* pada diagram tersebut berfungsi meningkatkan stabilitas pembelajaran dan efektivitas propagasi gradien, sehingga model lebih robust dalam mempelajari pola jangka panjang pada data spasio-temporal (Shi dkk., 2015).



Gambar 2.4 Sel ConvLSTM (Sumber : Fredyan, 2020)

Selanjutnya, struktur model yang ditunjukkan pada Gambar 2.5 merepresentasikan arsitektur Convolutional Long Short-Term Memory (ConvLSTM) yang digunakan dalam penelitian ini untuk memodelkan dinamika spasio-temporal klorofil-a. Data *input* berupa citra klorofil-a pada beberapa *timesteps* ($t-3$, $t-2$, dan $t-1$) diproses secara berurutan oleh tiga lapisan ConvLSTM yang disusun secara bertingkat. Setiap lapisan ConvLSTM berperan secara simultan dalam mengekstraksi fitur spasial melalui operasi konvolusi dan memodelkan dependensi temporal melalui mekanisme memori LSTM, sehingga mampu menangkap evolusi pola klorofil-a dari waktu ke waktu. Informasi spasio-temporal yang dihasilkan dari lapisan ConvLSTM terakhir selanjutnya diteruskan ke satu lapisan Conv2D sebagai *output layer* untuk menghasilkan prediksi distribusi klorofil-a pada waktu ke- t . Dengan arsitektur ini, proses pemodelan dilakukan secara *end-to-end* tanpa pemisahan eksplisit antara ekstraksi fitur spasial dan temporal, sehingga model lebih efektif dalam merepresentasikan karakteristik data oseanografi (S. Zhou dkk., 2021).



Gambar 2.5 Diagram Struktur Model ConvLSTM (Sumber : S. Zhou dkk., 2021)

Secara keseluruhan, berbagai kajian terdahulu telah menunjukkan bahwa arsitektur ConvLSTM memiliki keunggulan signifikan dalam memodelkan fenomena lingkungan yang bersifat spasio-temporal kompleks. Penelitian oleh Kim & Cho (2025) menunjukkan bahwa model ConvLSTM mampu memberikan performa terbaik dalam memprediksi klorofil-a dibandingkan model deret waktu konvensional maupun jaringan saraf yang hanya mempertimbangkan dimensi temporal atau spasial secara terpisah. Keunggulan tersebut terutama disebabkan oleh kemampuan ConvLSTM dalam menangkap keterkaitan dinamis antara pola distribusi spasial dan evolusi temporal parameter oseanografi. Oleh karena itu, penggunaan ConvLSTM dalam penelitian ini dinilai tepat dan relevan untuk memodelkan serta memprediksi variabilitas klorofil-a yang dipengaruhi oleh proses fisik laut seperti *upwelling*, sehingga dapat mendukung analisis oseanografi dan aplikasi perikanan secara lebih akurat.

2.11.1 Fungsi Aktivasi Sigmoid

Fungsi aktivasi Sigmoid (*Logistic Sigmoid*) merupakan fungsi nonlinear klasik yang memetakan nilai input ke dalam rentang 0 hingga 1, sehingga sering digunakan untuk merepresentasikan probabilitas. Secara matematis, fungsi Sigmoid dirumuskan pada Persamaan (2.12).

$$f(x) = \frac{1}{1 + e^{-x}} \quad (2.12)$$

Fungsi ini menghasilkan kurva berbentuk S (*S-shaped*) dan mampu memperkenalkan nonlinearitas ke dalam jaringan saraf, namun memiliki kelemahan berupa saturasi pada nilai input yang sangat besar atau sangat kecil yang dapat menyebabkan masalah *vanishing gradient* saat proses pelatihan model (Dubey dkk., 2022).

2.11.2 Fungsi Aktivasi Tanh

Fungsi aktivasi Tanh (*Hyperbolic Tangent*) merupakan pengembangan dari Sigmoid yang memiliki sifat *zero-centered*, dengan rentang keluaran antara -1 hingga 1. Fungsi ini dinyatakan dengan Persamaan (2.13).

$$f(x) = \tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}} \quad (2.13)$$

Dibandingkan Sigmoid, Tanh lebih efektif dalam mempercepat konvergensi karena outputnya simetris terhadap nol, sehingga membantu stabilitas pembelajaran. Namun, seperti Sigmoid, fungsi ini juga dapat mengalami *vanishing gradient* pada nilai input ekstrem akibat sifat saturasinya (Dubey dkk., 2022).

2.11.3 Fungsi Aktivasi Linear

Fungsi aktivasi linear merupakan bentuk paling sederhana dari *activation function* yang menghasilkan keluaran berupa hubungan linear langsung terhadap nilai input. Fungsi ini tidak menambahkan unsur nonlinearitas ke dalam jaringan saraf, sehingga sering disebut juga sebagai *identity function*. Secara matematis, fungsi aktivasi linear dirumuskan pada Persamaan (2.14).

$$f(x) = c \cdot x \quad (2.14)$$

di mana x sebagai input dan c sebagai konstanta.

Pada kasus paling umum, nilai c biasanya selalu sama dengan 1 ($c = 1$), sehingga persamaan menjadi $f(x) = x$. Meskipun sederhana, penggunaan fungsi linear pada seluruh lapisan jaringan menyebabkan model hanya mampu mempelajari hubungan linear sehingga kurang efektif untuk memodelkan pola data

yang kompleks dan nonlinear. Oleh karena itu, fungsi aktivasi linear umumnya diterapkan hanya pada lapisan *output* untuk permasalahan regresi, ketika diperlukan prediksi nilai kontinu tanpa pembatasan rentang tertentu (Dubey dkk., 2022).

2.11.4 Optimizer

Optimizer merupakan algoritma yang digunakan dalam *deep learning* untuk memperbarui bobot (*weights*) dan bias model selama proses pelatihan dengan meminimalkan nilai fungsi kerugian (*loss function*). *Optimizer* berperan penting dalam menentukan kecepatan konvergensi, stabilitas pelatihan, serta kemampuan model dalam mencapai solusi optimal, terutama pada model dengan struktur kompleks seperti jaringan saraf dalam (Nurdiati dkk., 2022a). Dalam konteks pemodelan deret waktu berbasis *deep learning*, penelitian yang dilakukan oleh (Singh & Rawat, 2023) pada model CNN untuk data *time series* menunjukkan bahwa Adam, Adamax, dan Nadam merupakan tiga *optimizer* dengan kinerja terbaik dibandingkan *optimizer* lainnya, sehingga ketiga *optimizer* tersebut digunakan dalam penelitian ini.

2.11.4.1 Adam

Adam (*Adaptive Moment Estimation*) merupakan algoritma optimisasi berbasis *stochastic gradient descent* yang dirancang untuk meningkatkan efisiensi dan stabilitas proses pelatihan model melalui estimasi adaptif momen pertama dan momen kedua dari gradien. Adam memanfaatkan rata-rata bergerak eksponensial dari gradien (m_t) dan kuadrat gradien (v_t) untuk menyesuaikan laju pembelajaran secara individual pada setiap parameter, sehingga mampu menangani masalah dengan gradien *noisy*, *sparsity* tinggi, serta fungsi objektif nonstasioner (Kingma & Ba, 2015). Secara matematis, Adam memperbarui parameter menggunakan Persamaan (2.15) dan Persamaan (2.16).

$$m_t = \beta_1 m_{t-1} + (1 - \beta_1) g_t \quad (2.15)$$

$$v_t = \beta_2 v_{t-1} + (1 - \beta_2) g_t^2 \quad (2.16)$$

dengan nilai koreksi bias yang dihitung dengan Persamaan (2.17).

$$\hat{m}_t = \frac{m_t}{1 - \beta_1^t}, \hat{v}_t = \frac{v_t}{1 - \beta_2^t} \quad (2.17)$$

dan parameter diperbarui dengan Persamaan (2.18).

$$\theta_t = \theta_{t-1} - \alpha \frac{\hat{m}_t}{\sqrt{\hat{v}_t} + \varepsilon} \quad (2.18)$$

Keterangan :

- θ_t : parameter model pada iterasi ke- t ,
- θ_{t-1} : parameter model pada iterasi sebelumnya,
- g_t : gradien fungsi loss terhadap parameter pada iterasi ke- t ,
- m_t : estimasi momen pertama (rata-rata gradien),
- v_t : estimasi momen kedua (rata-rata kuadrat gradien),
- $\hat{m}_t$: momen pertama setelah koreksi bias,
- $\hat{v}_t$: momen kedua setelah koreksi bias,
- α : *learning rate* atau laju pembelajaran,
- β_1 : koefisien peluruhan untuk momen pertama (umumnya 0,9),
- β_2 : koefisien peluruhan untuk momen kedua (umumnya 0,999),
- ε : konstanta kecil untuk mencegah pembagian dengan nol.

Struktur pembaruan ini memungkinkan Adam menyesuaikan laju pembelajaran secara individual untuk setiap parameter, sehingga mampu mengatasi masalah gradien yang tidak stabil, bersifat *noisy*, maupun memiliki variasi skala yang tinggi. Hal ini menjadikan Adam sangat efektif digunakan dalam pelatihan model *deep learning* kompleks seperti ConvLSTM pada data spasio-temporal, karena mampu mempercepat konvergensi sekaligus menjaga kestabilan proses optimisasi (Kingma & Ba, 2015; Na dkk., 2022a).

2.11.4.2 Adamax

Adamax merupakan varian dari algoritma Adam yang dikembangkan dengan mengganti norma Euclidean (norma L_2) pada estimasi momen kedua gradien menjadi norma tak hingga (norma L_∞). Pendekatan ini bertujuan untuk meningkatkan stabilitas numerik pada kondisi gradien yang sangat jarang (*highly sparse*) atau memiliki nilai ekstrem, yang sering dijumpai pada model pembelajaran mendalam berskala besar. Dengan menggunakan norma maksimum dari gradien historis, Adamax menghasilkan batas langkah pembaruan parameter yang lebih sederhana dan terkontrol dibandingkan Adam konvensional (Llusi dkk., 2021; Nurdianti dkk., 2022).

Secara matematis, perhitungan momen pertama gradien pada Adamax dilakukan sama seperti pada Adam sebagaimana ditunjukkan pada Persamaan (2.15), dengan koreksi bias momen pertama mengacu pada Persamaan (2.17). Perbedaan utama Adamax terletak pada perhitungan momen kedua, yang digantikan oleh norma tak hingga gradien yang dirumuskan pada Persamaan (2.19)

$$u_t = \max(\beta_2 u_{t-1}, |g_t|) \quad (2.19)$$

Selanjutnya parameter model diperbarui menggunakan Persamaan (2.20).

$$\theta_t = \theta_{t-1} - \frac{\alpha}{u_t} \hat{m}_t \quad (2.20)$$

Keterangan :

Keterangan pada parameter pada Adamax sama seperti yang telah dijelaskan pada subbab 2.11.4.1, dengan tambahan :

u_t : estimasi norma tak hingga (*infinity norm*) dari gradien pada iterasi ke- t .

Penggunaan norma tak hingga pada Adamax mampu menjaga stabilitas pembaruan parameter pada kondisi gradien yang tidak menentu atau berskala besar. Keunggulan ini menjadikan Adamax efektif untuk model *deep learning* yang kompleks dan sensitif terhadap perubahan gradien, serta dapat memberikan konvergensi yang lebih stabil dibandingkan Adam pada kondisi tertentu (Llugsi dkk., 2021).

2.11.4.3 *Nesterov-Accelerated Adaptive Momentum Estimation (Nadam)*

Nadam atau *Nesterov-accelerated Adaptive Moment Estimation* merupakan algoritma optimisasi adaptif yang menggabungkan mekanisme Adam dengan prinsip *Nesterov Accelerated Gradient* atau NAG. Secara umum, Nadam tetap mempertahankan keunggulan Adam dalam memanfaatkan estimasi momen pertama dan momen kedua dari gradien, tetapi memodifikasi komponen momentum dengan pendekatan Nesterov. Melalui pendekatan tersebut, arah pembaruan parameter tidak hanya bergantung pada estimasi momentum saat ini, tetapi juga mempertimbangkan arah gradien yang bersifat lebih antisipatif. Dengan demikian, Nadam dirancang untuk menghasilkan proses pembaruan parameter yang lebih responsif terhadap perubahan arah gradien selama proses pelatihan model deep learning (Reyad dkk., 2023).

Nadam merupakan pengembangan dari Adam, dimana perhitungan estimasi momen pertama, estimasi momen kedua, serta koreksi bias tetap mengikuti persamaan Adam yang telah dijelaskan sebelumnya, yaitu pada Persamaan (2.15), hingga Persamaan (2.17). Dengan demikian, pembentukan nilai m_t , v_t , $\hat{m}_t$ dan $\hat{v}_t$ pada Nadam dapat dinyatakan sama seperti pada Adam. Perbedaan utama Nadam terletak pada tahap pembaruan parameter, yaitu dengan memasukkan komponen momentum Nesterov ke dalam rumus pembaruan Adam. Secara matematis, pembaruan parameter pada Nadam dirumuskan pada Persamaan (2.21) (Reyad dkk., 2023).

$$\theta_t = \theta_{t-1} - \alpha \frac{\beta_1 \hat{m}_t + \frac{(1-\beta_1)g_t}{1-\beta_1^t}}{\sqrt{\hat{v}_t} + \varepsilon} \quad (2.21)$$

Keterangan :

- θ_t : parameter model pada iterasi ke- t ,
- θ_{t-1} : parameter model pada iterasi sebelumnya,
- g_t : gradien fungsi loss terhadap parameter pada iterasi ke- t ,
- m_t : estimasi momen pertama (rata-rata gradien),
- v_t : estimasi momen kedua (rata-rata kuadrat gradien),
- $\hat{m}_t$: momen pertama setelah koreksi bias,
- $\hat{v}_t$: momen kedua setelah koreksi bias,
- α : *learning rate* atau laju pembelajaran,
- β_1 : koefisien peluruhan untuk momen pertama (umumnya 0,9),
- β_2 : koefisien peluruhan untuk momen kedua (umumnya 0,999),
- ε : konstanta kecil untuk mencegah pembagian dengan nol.

Pada Persamaan (2.21), komponen $\beta_1 \hat{m}_t + \frac{(1-\beta_1)g_t}{1-\beta_1^t}$ menunjukkan adanya modifikasi terhadap ekspresi momentum pada Adam. Jika Adam menggunakan $\hat{m}_t$ secara langsung dalam proses pembaruan parameter, Nadam menambahkan komponen gradien saat ini yang telah dikoreksi terhadap bias, sehingga pembaruan parameter menjadi lebih dipengaruhi oleh arah gradien yang sedang berlangsung. Secara analitis, mekanisme ini membuat Nadam lebih adaptif dibandingkan Adam

standar karena mengombinasikan estimasi momentum adaptif dengan karakteristik antisipatif dari NAG. Dengan struktur tersebut, Nadam dapat digunakan sebagai alternatif optimizer dalam pelatihan model *deep learning* karena tetap mempertahankan efisiensi Adam, tetapi menambahkan mekanisme Nesterov untuk memperbaiki arah pembaruan parameter. Dalam konteks model seperti ConvLSTM yang melibatkan pola spasio-temporal dan jumlah parameter yang relatif kompleks, Nadam berpotensi membantu proses optimisasi agar pembaruan bobot berlangsung lebih stabil dan responsif terhadap dinamika gradien selama pelatihan (Nurdiati dkk., 2022).

2.12 *Hyperparameter Tuning*

Hyperparameter tuning merupakan proses penentuan kombinasi parameter pengaturan model yang optimal untuk meningkatkan kinerja dan kemampuan generalisasi model pembelajaran mesin. Berbeda dengan parameter model yang dipelajari selama proses pelatihan, *hyperparameter* ditetapkan sebelum pelatihan dan berperan penting dalam mengendalikan struktur serta proses pembelajaran model, seperti *learning rate*, *batch size*, jumlah *filter*, ukuran kernel, dan jumlah *epoch* (Ilemobayo dkk., 2024a). Pemilihan *hyperparameter* yang tidak tepat dapat menyebabkan model mengalami *underfitting* atau *overfitting*, sedangkan penentuan yang optimal mampu meningkatkan stabilitas pelatihan dan akurasi prediksi. Pada penelitian ini, digunakan metode *bayesian optimization* dengan algoritma *Tree-Structured Parzen Estimator* (TPE) sebagai pendekatan *hyperparameter tuning* untuk memperoleh kombinasi *hyperparameter* optimal secara efisien.

2.12.1 *Bayesian Optimization*

Bayesian Optimization merupakan metode optimisasi yang digunakan untuk mencari konfigurasi hyperparameter terbaik pada fungsi objektif yang biaya evaluasinya relatif mahal. Dalam konteks *hyperparameter optimization*, fungsi objektif umumnya berupa metrik kesalahan pada data validasi, misalnya *validation loss*, RMSE, atau MAE, yang diperoleh setelah model dilatih menggunakan konfigurasi hyperparameter tertentu. Metode ini bekerja pada ruang *surrogate* dengan memanfaatkan sekumpulan hasil observasi sebelumnya, kemudian membangun model prediktif $p(f|x, D)$ untuk menentukan konfigurasi berikutnya

melalui fungsi akuisisi (*acquisition function*). Dengan mekanisme tersebut, *Bayesian Optimization* tidak mengevaluasi seluruh kombinasi *hyperparameter* seperti *grid search*, tetapi memilih kandidat yang lebih menjanjikan berdasarkan informasi dari evaluasi sebelumnya (Du dkk., 2022).

Secara matematis, permasalahan optimisasi *hyperparameter* dapat dirumuskan sebagai proses minimisasi fungsi objektif $f(x)$, sebagaimana ditunjukkan pada Persamaan (2.22).

$$x_{opt} \in \arg \min_{x \in X} f(x) \quad (2.22)$$

Pada Persamaan (2.22), x menyatakan konfigurasi *hyperparameter*, X merupakan ruang pencarian *hyperparameter*, dan $f(x)$ merupakan fungsi objektif yang akan diminimalkan. Dalam proses optimisasi, setiap konfigurasi yang telah dievaluasi disimpan sebagai himpunan observasi D , sebagaimana dirumuskan pada Persamaan (2.23).

$$D = \{(x_n, f_n)\}_{n=1}^N \quad (2.23)$$

Pada Persamaan (2.23), x_n merupakan konfigurasi *hyperparameter* ke- n , sedangkan f_n merupakan nilai fungsi objektif yang diperoleh dari konfigurasi tersebut. Berdasarkan himpunan observasi tersebut, *bayesian optimization* membangun model prediktif dan menggunakan fungsi akuisisi untuk menentukan kandidat berikutnya. Salah satu fungsi akuisisi yang umum digunakan adalah *Expected Improvement* (EI), sebagaimana ditunjukkan pada Persamaan (2.24).

$$EI_{f^*}(x|D) = \int_{-\infty}^{f^*} (f^* - f)p(f|x, D) df \quad (2.24)$$

Keterangan :

- x : konfigurasi *hyperparameter* yang dievaluasi,
- X : ruang pencarian *hyperparameter*,
- x_{opt} : konfigurasi *hyperparameter* optimal,
- $f(x)$: fungsi objektif yang diminimalkan,
- D : himpunan observasi hasil evaluasi *hyperparameter*,
- x_n : konfigurasi *hyperparameter* ke- n ,
- f_n : nilai fungsi objektif dari konfigurasi ke- n ,

$p(f|x, D)$: model prediktif terhadap nilai fungsi objektif berdasarkan konfigurasi x dan observasi D ,

f^* : nilai acuan atau ambang fungsi objektif yang digunakan dalam perhitungan *Expected Improvement*.

Berdasarkan mekanisme tersebut, *bayesian optimization* dapat digunakan untuk mempercepat proses pencarian *hyperparameter* karena evaluasi diarahkan pada konfigurasi yang secara probabilistik lebih menjanjikan (Du dkk., 2022; Ilemobayo dkk., 2024; Watanabe & Hutter, 2023).

2.12.2 *Tree-Structured Parzen Estimator (TPE)*

Tree-Structured Parzen Estimator atau TPE merupakan salah satu varian dari Bayesian Optimization yang digunakan secara luas dalam optimisasi *hyperparameter*. Berbeda dari Bayesian Optimization berbasis Gaussian Process yang memodelkan $p(f|x, D)$, TPE membalik arah pemodelan dengan membangun distribusi $p(x|f, D)$. Penelitian oleh Watanabe & Hutter (2023) menjelaskan bahwa TPE menggunakan rasio kepadatan dari dua kelompok observasi, yaitu kelompok konfigurasi dengan hasil objektif yang baik dan kelompok konfigurasi dengan hasil objektif yang kurang baik. Paper tersebut juga menyebutkan bahwa perangkat lunak optimisasi *hyperparameter* seperti Optuna, Hyperopt, dan Ray menggunakan TPE sebagai salah satu algoritma utama untuk optimisasi *hyperparameter*, khususnya pada permasalahan model yang mahal secara komputasi (Watanabe & Hutter, 2023).

Pada TPE, hasil observasi dibagi berdasarkan nilai kuantil tertentu f^γ . Konfigurasi dengan nilai fungsi objektif yang lebih baik dari ambang kuantil dimasukkan ke dalam kelompok $D^{(l)}$, sedangkan konfigurasi lainnya dimasukkan ke dalam kelompok $D^{(g)}$. Hubungan probabilistik tersebut dirumuskan pada Persamaan (2.25).

$$p(x|f, D) = \begin{cases} p(x|D^{(l)}), & f \leq f^\gamma \\ p(x|D^{(g)}), & f > f^\gamma \end{cases} \quad (2.25)$$

Pada Persamaan (2.25), $D^{(l)}$ merupakan kelompok observasi dengan nilai fungsi objektif terbaik, sedangkan $D^{(g)}$ merupakan kelompok observasi lainnya. Kedua kelompok tersebut kemudian digunakan untuk membangun model

kepadatan menggunakan *kernel density estimator*. Fungsi akuisisi pada TPE dihitung berdasarkan rasio antara kepadatan konfigurasi pada kelompok terbaik dan kelompok lainnya, sebagaimana ditunjukkan pada Persamaan (2.26).

$$r(x|D) = \frac{p(x|D^{(l)})}{p(x|D^{(g)})} \quad (2.26)$$

Konfigurasi *hyperparameter* berikutnya dipilih dengan memaksimalkan rasio kepadatan tersebut. Artinya, TPE akan lebih memprioritaskan konfigurasi yang memiliki peluang tinggi berada pada kelompok hasil terbaik, tetapi memiliki peluang rendah berada pada kelompok hasil yang kurang baik. Proses pemilihan konfigurasi berikutnya dapat dirumuskan pada Persamaan (2.27).

$$x_{t+1} = \arg \max_{x \in X} r(x|D_t) \quad (2.27)$$

Keterangan :

- $D^{(l)}$: kelompok observasi dengan nilai fungsi objektif terbaik,
- $D^{(g)}$: kelompok observasi selain kelompok terbaik,
- f^γ : nilai fungsi objektif pada kuantil γ ,
- $p(x|D^{(l)})$: model kepadatan konfigurasi *hyperparameter* pada kelompok terbaik,
- $p(x|D^{(g)})$: model kepadatan konfigurasi *hyperparameter* pada kelompok lainnya,
- $r(x|D)$: rasio kepadatan yang digunakan sebagai dasar fungsi akuisisi TPE,
- D_t : himpunan observasi hingga iterasi ke- t ,
- x_{t+1} : konfigurasi *hyperparameter* yang dipilih untuk dievaluasi pada iterasi berikutnya.

Dalam penelitian ini, TPE diimplementasikan menggunakan Optuna untuk mengoptimasi *hyperparameter* model ConvLSTM. *Hyperparameter* yang dioptimasi meliputi *timesteps*, *filter size*, *kernel size*, *learning rate*, serta jenis *optimizer*. Dengan menggunakan TPE, proses pencarian *hyperparameter* dapat dilakukan secara lebih terarah karena pemilihan kandidat tidak dilakukan secara acak sepenuhnya, tetapi berdasarkan pola konfigurasi yang sebelumnya menghasilkan performa validasi lebih baik (Watanabe & Hutter, 2023; Zarei, 2026).

2.13 Evaluasi Model

Evaluasi model merupakan tahapan penting untuk menilai tingkat akurasi dan keandalan model dalam merepresentasikan fenomena yang diprediksi, khususnya dalam memodelkan dinamika konsentrasi klorofil-a yang bersifat kompleks dan fluktuatif. Melalui proses evaluasi, dapat diketahui sejauh mana hasil prediksi mendekati nilai observasi serta bagaimana performa model dalam menangkap pola spasio-temporal data secara konsisten. Dalam penelitian ini, evaluasi dilakukan dengan menggunakan rumus statistic *Mean Squared Error* (MSE), *Root Mean Square Error* (RMSE), *Mean Absolute Error* (MAE), *R-squared* (R^2), dan Korelasi Pearson (Na dkk., 2022; Yang dkk., 2021; Yao dkk., 2023; Z. Yu dkk., 2020).

2.13.1 *Mean Squared Error* (MSE)

Mean Squared Error (MSE) merupakan metrik evaluasi yang digunakan untuk mengukur rata-rata kuadrat selisih antara nilai prediksi model dengan nilai aktual. MSE memberikan penalti lebih besar terhadap kesalahan yang bernilai besar karena proses pengkuadratan, sehingga sensitif terhadap *outlier*. Dalam penelitian ini, MSE digunakan sebagai fungsi *loss* untuk mengoptimalkan proses pelatihan model. Secara matematis, MSE dirumuskan pada Persamaan (2.28).

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 \quad (2.28)$$

Keterangan :

y_i : nilai aktual untuk observasi ke- i ,

$\hat{y}_i$: nilai prediksi untuk observasi ke- i ,

n : jumlah total observasi.

2.13.2 *Root Mean Square Error* (RMSE)

Root Mean Square Error (RMSE) merupakan metrik evaluasi yang digunakan untuk mengukur tingkat kesalahan prediksi dengan mengambil akar dari nilai MSE, sehingga satuannya kembali sama dengan data asli. RMSE mengukur rata-rata dari kuadrat *error* antara nilai aktual dan nilai hasil prediksi model, kemudian diakarkan untuk mempermudah interpretasi dalam konteks variabel yang diamati (Z. Yu dkk., 2020). Dalam penelitian ini, RMSE digunakan sebagai salah

satu indikator utama untuk mengevaluasi tingkat kesalahan pada proses rekonstruksi data menggunakan metode DINEOF sekaligus untuk menilai performa prediksi model ConvLSTM. RMSE dapat dirumuskan pada Persamaan (2.29).

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (2.29)$$

Keterangan :

y_i : nilai aktual untuk observasi ke- i ,

$\hat{y}_i$: nilai prediksi untuk observasi ke- i ,

n : jumlah total observasi.

2.13.3 Mean Absolute Error (MAE)

Mean Absolute Error (MAE) adalah metrik evaluasi yang mengukur rata-rata dari nilai absolut selisih antara nilai prediksi dan nilai aktual. Berbeda dengan RMSE, MAE tidak memberikan penalti berlebih pada *error* besar karena tidak melibatkan pengkuadratan, sehingga lebih stabil dan mudah diinterpretasikan (Z. Yu dkk., 2020). Dalam penelitian ini, MAE digunakan untuk mengevaluasi kinerja model akhir. MAE dirumuskan pada Persamaan (2.30).

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (2.30)$$

Keterangan :

y_i : nilai aktual untuk observasi ke- i ,

$\hat{y}_i$: nilai prediksi untuk observasi ke- i .

n : jumlah total observasi.

2.13.4 R-squared (R^2)

R-squared (R^2) atau koefisien determinasi merupakan ukuran statistik yang digunakan untuk menilai sejauh mana variabel independen dalam suatu model regresi mampu menjelaskan variasi pada variabel dependen. Nilai R^2 menunjukkan proporsi variabilitas total data observasi yang dapat diterangkan oleh model regresi yang dibangun, sehingga sering digunakan sebagai indikator *goodness-of-fit*. Semakin tinggi nilai R^2 , semakin besar kemampuan model dalam menjelaskan pola

hubungan antara variabel independen dan variabel dependen (Chicco dkk., 2021; Yao dkk., 2023b). Pada penelitian ini R^2 digunakan sebagai salah satu untuk indicator untuk mengevaluasi kinerja model. Berikut rumus statistik R^2 yang disajikan pada Persamaan (2.31) hingga Persamaan (2.33).

$$R^2 = 1 - \frac{SS_{res}}{SS_{tot}} \quad (2.31)$$

$$SS_{res} = \sum_{i=1}^n (y_i - \hat{y}_i)^2 \quad (2.32)$$

$$SS_{tot} = \sum_{i=1}^n (y_i - \bar{y})^2 \quad (2.33)$$

Keterangan :

SS_{res} : jumlah kuadrat residual,

SS_{tot} : total variasi dari rata-rata,

y_i : nilai aktual untuk observasi ke- i ,

$\hat{y}_i$: nilai prediksi untuk observasi ke- i ,

$\bar{y}$: rata-rata nilai aktual.

2.13.5 Korelasi Pearson

Korelasi Pearson merupakan metode statistik yang digunakan untuk mengukur tingkat dan arah hubungan linear antara dua variabel numerik. Nilai koefisien korelasi Pearson berada pada rentang -1 hingga 1, dengan nilai positif menunjukkan hubungan searah, nilai negatif menunjukkan hubungan berlawanan arah, dan nilai mendekati nol menunjukkan bahwa hubungan linear antara kedua variabel relatif lemah atau tidak terlihat secara linear (Na dkk., 2022; Yao dkk., 2023). Secara matematis, koefisien korelasi Pearson dirumuskan pada Persamaan (2.34).

$$r_{xy} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}} \quad (2.34)$$

Keterangan :

r_{xy} : koefisien korelasi Pearson antara variabel x dan variabel y ,

x_i : nilai observasi ke- i pada variabel x ,

y_i : nilai observasi ke- i pada variabel y ,
 $\bar{x}$: nilai rata-rata dari variabel x ,
 $\bar{y}$: nilai rata-rata dari variabel y ,
 n : jumlah observasi.

BAB III

METODE PENELITIAN

3.1 Lokasi dan Waktu

Penelitian ini dilaksanakan di Universitas Airlangga sebagai lokasi pengolahan dan analisis data. Waktu pelaksanaan penelitian dimulai pada bulan November 2025 hingga Juni 2026, yang meliputi tahap pengumpulan data, pengolahan, analisis, pemodelan, serta interpretasi hasil.

3.2 Bahan dan Alat

Penelitian ini menggunakan perangkat keras, perangkat lunak dan server komputasi dengan detail sebagai berikut :

- a. Perangkat keras berupa laptop MSI Katana 17 dengan spesifikasi :

CPU : Intel Core i7 12th Gen,

RAM : 16 GB,

SSD : 512 GB.

- b. Perangkat lunak yang digunakan :

Microsoft Windows 10,

Microsoft Excel,

Jupyter Notebook,

Python.

- c. Server Kaggle dengan spesifikasi :

CPU : 30 GB,

GPU : NVIDIA Tesla T4 $\times$ 2 (15 GB),

Storage dataset : 50 GB.

- d. *Packages/Library* Python yang digunakan :

Library pandas,

Library geopandas,

Library numpy,

Library xarray,

Library shapely.geometry,

Library matplotlib.pyplot,

Library sklearn,

Library tensorflow.

3.3 Data Penelitian

Penelitian ini menggunakan dua parameter utama, yaitu *Sea Surface Temperature* (SST) dalam satuan derajat Celsius ($^{\circ}\text{C}$) dan konsentrasi klorofil-a (Klorofil-a) dalam satuan mg/m^3 . Data bersumber dari MODIS Ocean Color dengan rentang waktu tahun 2014–2024, serta memiliki resolusi temporal 8-Day dan *Monthly*. Lalu, untuk data peta diperoleh dari KSP *Service* yang berisi berbagai koordinat spesifik batas WPP-NRI 572. Seluruh data yang diperoleh selanjutnya disimpan dan dikelola pada server Kaggle untuk memudahkan proses pengolahan, analisis, serta *modelling*. Detail variabel dalam penelitian ini disajikan pada Tabel 3.1.


Tabel 3.1 Variabel Penelitian

Variabel	Satuan	Tipe	Keterangan
<i>Date</i>	8-Day dan <i>Monthly</i>	Temporal	Waktu pengamatan data oseanografi dalam resolusi harian yang merepresentasikan urutan kronologis kejadian.
<i>chlor_a</i> (dependen)	mg/m^3	Numerik	Konsentrasi klorofil-a sebagai indikator produktivitas primer perairan yang digunakan sebagai variabel target prediksi.
SST	$^{\circ}\text{C}$	Numerik	Suhu Permukaan Laut yang merepresentasikan kondisi termal perairan dan digunakan sebagai parameter deteksi <i>upwelling</i> .
<i>Longitude</i>	Derajat ($^{\circ}$)	Spasial (koordinat X)	Koordinat bujur yang menunjukkan posisi geografis titik pengamatan pada arah timur–barat.
<i>Latitude</i>	Derajat ($^{\circ}$)	Spasial (koordinat Y)	Koordinat lintang yang menunjukkan posisi geografis titik pengamatan pada arah utara–selatan.

3.4 Tahapan Penelitian

Penelitian ini diawali dengan pengumpulan data SST dan konsentrasi klorofil-a pada resolusi temporal 8-day dan bulanan, kemudian dilanjutkan dengan proses *merging* dan *masking*, penanganan *missing value*, serta analisis deskriptif dan *exploratory data analysis* (EDA). Setelah tahap EDA, alur penelitian dibagi menjadi dua, yaitu analisis UISST untuk mendeteksi, mengelompokkan, dan menganalisis intensitas *upwelling*, lalu pemodelan ConvLSTM untuk memprediksi klorofil-a berdasarkan pola spasial-temporal data. Tahap pemodelan mencakup

penanganan *outlier*, *scaling*, *bounding box cutting*, *preprocessing area non-valid*, *splitting* data, pelatihan model, *hyperparameter tuning*, evaluasi, dan *forecasting*. Hasil dari kedua jalur tersebut selanjutnya digunakan untuk memetakan wilayah *fishing ground* optimal di WPP-NRI 572. Alur lengkap tahapan penelitian ditunjukkan pada Gambar 3.1.



Gambar 3.1 Flowcart Tahapan Penelitian

3.4.1 Pengumpulan Data

Data dalam penelitian ini diperoleh dari platform MODIS Ocean Color dengan mengambil data oseanografi level 3 berupa konsentrasi klorofil-a dan *Sea Surface Temperature* (SST) pada periode 2014–2024. Data MODIS Ocean Color pada dasarnya mencakup wilayah global, sehingga pada tahap pengambilan data dilakukan pembatasan wilayah kajian pada koordinat 90°BT–110°BT dan 10°LS–7°LU. Rentang koordinat tersebut digunakan karena mencakup wilayah WPP-NRI 572, yang meliputi perairan Samudra Hindia di barat Sumatra hingga sekitar Selat Sunda. Setelah batas wilayah dan variabel data ditentukan, data kemudian diekstraksi dan diunduh dalam format NetCDF (.nc). Data yang diambil terdiri atas data berinterval *8-Day* dan *Monthly*, sesuai dengan kebutuhan analisis spasio-temporal dalam penelitian. Pada tahap ini, jumlah data berinterval *8-Day* yang berhasil dikumpulkan adalah sebanyak 505 *file* NetCDF, sedangkan data *monthly* berjumlah 132 *file* NetCDF selama periode penelitian. Selain itu, data batas wilayah WPP-NRI 572 diperoleh dari KSP Service dalam bentuk file GeoJSON yang berisi koordinat spesifik batas administratif wilayah pengelolaan perikanan. Seluruh data yang telah diperoleh kemudian diunggah ke *server* Kaggle untuk memudahkan proses pengolahan dan pemodelan lebih lanjut.


3.4.2 Merging Data

Merging data merupakan proses penggabungan beberapa *file* data menjadi satu *file* terpadu agar data lebih mudah diolah, dianalisis, dan digunakan pada tahap pemodelan. Pada penelitian ini, proses *merging* difokuskan pada data berinterval *8-Day* yang berjumlah 505 *file* NetCDF, karena data tersebut digunakan sebagai data utama dalam proses *modeling* dan analisis UISST. Sementara itu, data *monthly* tidak digunakan pada tahap pemodelan, melainkan hanya dimanfaatkan untuk keperluan EDA. Pada tahap ini, seluruh data *8-Day* terlebih dahulu digabungkan menjadi satu *dataset* NetCDF terpadu, kemudian ditambahkan dimensi waktu (*time*) agar setiap data memiliki urutan temporal yang konsisten berdasarkan tanggal awal masing-masing periode komposit. Sebagai contoh, urutan waktu dimulai dari 1 Januari 2014, kemudian dilanjutkan ke 9 Januari 2014, 17 Januari 2014, dan seterusnya hingga seluruh periode penelitian tersusun secara berurutan.

3.4.3 *Masking Data*

Masking merupakan proses pembatasan data agar cakupan analisis hanya berfokus pada wilayah yang berada di dalam WPP-NRI 572. Tahap ini dilakukan dengan menggunakan data batas wilayah WPP-NRI 572 yang diperoleh dari KSP Service dalam format GeoJSON. Data batas wilayah tersebut digunakan sebagai acuan untuk melakukan *masking* terhadap data SST dan klorofil-a berdasarkan *polygon* wilayah WPP-NRI 572. Proses ini dijalankan menggunakan Python dengan bantuan *library* geospasial GeoPandas. Melalui tahapan ini, hanya titik-titik koordinat yang berada di dalam wilayah WPP-NRI 572 yang dipertahankan untuk analisis, sedangkan titik koordinat di luar wilayah tersebut (*area non-valid*) diisi nilai kosong atau *NaN*, sehingga tidak ikut diperhitungkan sebagai wilayah kajian oseanografi.

Secara teknis, proses *masking* diawali dengan pemeriksaan sistem koordinat atau *Coordinate Reference System* (CRS) antara data batas wilayah dalam format GeoJSON dan data oseanografi dalam format NetCDF. Pemeriksaan ini dilakukan untuk memastikan bahwa kedua data berada pada sistem koordinat yang sama. Apabila sistem koordinat belum sesuai, maka dilakukan penyesuaian CRS agar batas wilayah WPP-NRI 572 dapat disejajarkan dengan grid *longitude* dan *latitude* pada data NetCDF. Setelah itu, setiap pasangan koordinat *longitude* dan *latitude* pada data oseanografi diperiksa posisinya terhadap *polygon* batas WPP-NRI 572. Hasil pemeriksaan tersebut membentuk *mask* atau cetakan spasial yang berisi nilai logika, yaitu *True* (1) untuk titik yang berada di dalam wilayah WPP-NRI 572, serta *False* (0) untuk titik yang berada di luar wilayah tersebut. *Mask* inilah yang kemudian digunakan untuk mempertahankan data di dalam wilayah kajian dan mengecualikan data di luar wilayah WPP-NRI 572. Visualisasi batas wilayah yang digunakan sebagai dasar pembentukan *mask* ditunjukkan pada Gambar 3.2.



Gambar 3.2 Mask/Cetakan Wilayah WPP-NRI 572 (File GeoJSON)

Pada Gambar 3.2, visualisasi sebelah kiri menunjukkan batas wilayah WPP-NRI 572 dalam bentuk garis luar yang berasal dari data GeoJSON, sedangkan visualisasi sebelah kanan menunjukkan cakupan wilayah WPP-NRI 572 yang telah membentuk area *mask* spasial. Area berwarna merah merepresentasikan wilayah perairan yang termasuk dalam cakupan WPP-NRI 572, sementara bagian kosong di dalam area tersebut menunjukkan daratan atau pulau-pulau kecil yang tidak termasuk sebagai area valid analisis. Dengan demikian, proses *masking* tidak hanya membatasi data berdasarkan batas luar WPP-NRI 572, tetapi juga mengecualikan area daratan dan area *non-valid* lainnya, sehingga data yang dipertahankan hanya merepresentasikan titik *grid* perairan yang relevan untuk analisis oseanografi.

3.4.4 Handling Missing Value

Pada tahap ini, penanganan *missing value* dilakukan pada data berinterval 8-Day dengan membedakan data berdasarkan posisi spasialnya terhadap batas WPP-NRI 572. Nilai kosong yang berada di luar wilayah WPP-NRI 572 tidak diimputasi karena area tersebut tidak termasuk dalam cakupan analisis oseanografi pada penelitian ini. Sementara itu, *missing value* yang berada di dalam wilayah perairan WPP-NRI 572 diperlakukan sebagai data hilang yang masih termasuk dalam area penelitian, sehingga perlu direkonstruksi. Proses imputasi pada wilayah ini dilakukan menggunakan metode 3D *Data Interpolating Empirical Orthogonal Functions* (3D-DINEOF), yaitu metode rekonstruksi berbasis EOF yang memanfaatkan pola dominan variabilitas spasial dan temporal. Secara matematis,

proses rekonstruksi tetap mengacu pada formulasi SVD dan rekonstruksi EOF sebagaimana ditunjukkan pada Persamaan (2.3) dan Persamaan (2.4).

Secara teknis, proses 3D-DINEOF diawali dengan penentuan titik *cross-validation*, yaitu sebagian data valid yang sengaja dihilangkan sementara untuk mengukur *error* rekonstruksi. Setelah itu, *missing value* diinisialisasi dengan nilai awal 0, kemudian proses rekonstruksi dimulai dari jumlah EOF *mode* awal, yaitu *mode* 1. Pada setiap *mode*, data didekomposisi menggunakan *Singular Value Decomposition* (SVD), kemudian nilai hilang direkonstruksi menggunakan EOF *mode* yang sedang diuji. Hasil rekonstruksi selanjutnya dievaluasi melalui perhitungan *error cross-validation* menggunakan *Root Mean Square Error* (RMSE). Proses ini dilakukan secara iteratif hingga mencapai kondisi konvergen atau sampai batas maksimum iterasi terpenuhi. Setelah satu jumlah EOF *mode* selesai diuji, proses dilanjutkan pada jumlah EOF *mode* berikutnya hingga mencapai batas maksimum *mode* yang ditentukan. EOF *mode* optimal kemudian dipilih berdasarkan nilai RMSE *cross-validation* terendah, lalu digunakan untuk melakukan rekonstruksi akhir pada seluruh *dataset*. Konfigurasi parameter proses 3D-DINEOF ditunjukkan pada Tabel 3.2 (G. Zhou dkk., 2024).

Tabel 3.2 Konfigurasi Parameter Proses 3D-DINEOF

Parameter	Nilai	Keterangan
Data <i>cross-validation</i>	3%	Data valid yang sengaja dihilangkan sementara untuk mengukur galat rekonstruksi.
Maksimum EOF <i>mode</i>	30	Batas maksimum jumlah EOF <i>mode</i> yang diuji.
Maksimum iterasi	30	Batas maksimum iterasi pada setiap proses rekonstruksi.
<i>Convergence threshold</i>	10^{-5}	Ambang perubahan relatif galat untuk menentukan kondisi konvergen.
<i>Patience</i>	5	Batas penghentian apabila tidak terjadi perbaikan <i>error</i> secara berturut-turut.

3.4.5 Analisis Deskriptif dan *Exploratory Data Analysis* (EDA)

Pada tahap ini dilakukan analisis deskriptif dan *Exploratory Data Analysis* (EDA) untuk mengkaji karakteristik serta pola spasio-temporal data oseanografi di wilayah WPP-NRI 572. EDA dilakukan menggunakan dua jenis data, yaitu data berinterval *8-Day* yang telah melalui proses rekonstruksi *missing value* dan data *monthly* hasil pengunduhan dari MODIS Ocean Color. Data *8-Day* digunakan untuk mendukung analisis yang berkaitan dengan pemodelan dan dinamika temporal yang

lebih rinci, sedangkan data *monthly* digunakan untuk mengamati karakteristik umum SST dan konsentrasi klorofil-a pada skala bulanan. Visualisasi EDA disajikan dalam bentuk *line chart*, *histogram*, *boxplot*, *scatterplot*, *barplot*, serta peta distribusi bulanan untuk melihat pola perubahan nilai, sebaran data, hubungan antarvariabel, dan variasi spasial setiap bulan.


Selain dilakukan pada tahap awal deskripsi data, EDA juga dilakukan setelah proses *binning* intensitas *upwelling*. Analisis lanjutan ini bertujuan untuk mengevaluasi distribusi dan dominasi setiap kategori intensitas *upwelling*, serta memahami karakteristik SST dan klorofil-a pada masing-masing kelas. Dengan demikian, EDA tidak hanya digunakan untuk menggambarkan kondisi umum data, tetapi juga untuk mendukung interpretasi hubungan antara intensitas *upwelling* dan dinamika oseanografi di wilayah WPP-NRI 572.

3.4.6 *Upwelling Detection*

Deteksi *upwelling* dilakukan dengan menggunakan variabel SST untuk menghitung *SST-Based Upwelling Index* (UISST) yang telah dijelaskan pada Persamaan (2.1). Perhitungan UISST dilakukan pada *ocean grid points* yang telah melalui proses *masking* sesuai batas perairan WPP-NRI 572. Tahap ini dilakukan dengan pengamatan berdasarkan arah lintang (*latitude*) untuk membandingkan nilai SST pada area *offshore* sebagai SST_{max} dengan nilai SST pada titik-titik lain di sisi timurnya (SST_{min}) pada lintang dan waktu pengamatan yang sama. Berdasarkan pendekatan Benazzouz dkk. (2014) serta Tükenmez dan Altiok (2022), nilai SST referensi ditentukan dari area *offshore* yang berada pada jarak paling jauh di sisi barat pada setiap lintang dan mengarah ke laut lepas (*offshore*). Selanjutnya, nilai SST pada titik-titik di sebelah timur dibandingkan dengan nilai referensi tersebut untuk menghitung nilai UISST.

Apabila suhu permukaan laut pada suatu titik di sisi timur (SST_{min}) lebih rendah dibandingkan suhu referensi di area *offshore*, maka nilai UISST yang dihasilkan bernilai positif. Nilai UISST lebih besar dari nol menunjukkan adanya penurunan SST terhadap suhu referensi, sehingga titik tersebut diidentifikasi sebagai indikasi. Sebaliknya, nilai UISST kurang dari atau sama dengan nol menunjukkan kondisi *non-upwelling* atau *downwelling* (García-Peña dkk., 2021;

Tükenmez & Altiok, 2022). Proses ini dilakukan pada seluruh titik *grid* di dalam WPP-NRI 572 untuk setiap waktu pengamatan, sehingga menghasilkan informasi spasial dan temporal mengenai lokasi terjadinya *upwelling*. Alur proses *upwelling detection* disajikan secara sistematis pada Gambar 3.3.



Gambar 3.3 Flowchart Upwelling Detection

3.4.7 Binning Intensitas Upwelling

Penentuan intensitas *upwelling* dalam penelitian ini dilakukan melalui proses *binning* statistik terhadap nilai indeks *upwelling* yang diperoleh dari analisis sebaran UISST serta variabilitas konsentrasi klorofil-a di wilayah WPP-NRI 572. Pendekatan *binning* digunakan untuk membagi data kontinu intensitas *upwelling* ke dalam beberapa interval kategori berdasarkan karakteristik distribusi data. Metode *Interquartile Range* (IQR) pada Persamaan (2.2) diterapkan untuk menentukan batas kategori intensitas *upwelling*, di mana data dibagi ke dalam tiga tingkat, yaitu *low*, *medium*, dan *high*, berdasarkan posisi nilai terhadap kuartil pertama (Q1) dan kuartil ketiga (Q3) (Kunarso dkk., 2020c; Madriyanti, 2025). Berikut adalah tabel *binning* intensitas *upwelling* dengan pendekatan IQR yang disajikan pada Tabel 3.3.

Tabel 3.3 Binning Intensitas Upwelling Berbasis IQR

Rentang Nilai Indeks	Kategori
< 0	Non-upwelling
0 - Q1 (persentil 25)	Low upwelling
Q1 - Q3 (persentil 25-75)	Intermediate upwelling
> Q3 (persentil 75)	Strong upwelling

3.4.8 *Outlier Handling*

Tahap *outlier handling* dilakukan khusus pada data berinterval *8-Day* untuk variabel klorofil-a, karena variabel ini digunakan sebagai masukan utama dalam proses pemodelan. Penanganan *outlier* dilakukan untuk mengurangi pengaruh nilai ekstrem yang terlalu tinggi, sehingga distribusi data menjadi lebih stabil dan tidak mendominasi proses pelatihan model. Metode yang digunakan adalah *winsorization*, yaitu teknik pembatasan nilai ekstrem dengan mengganti nilai yang melebihi batas tertentu menggunakan nilai ambang yang telah ditentukan. Pada penelitian ini, batas atas ditetapkan berdasarkan persentil 99,5%, sehingga nilai klorofil-a yang berada di atas ambang tersebut diganti dengan nilai pada persentil 99,5%. Dengan pendekatan ini, nilai ekstrem tidak dihapus dari dataset, tetapi dibatasi agar tetap berada dalam rentang yang lebih representatif untuk proses analisis dan pemodelan.

3.4.9 *Bounding Box Cutting*

Tahap *bounding box cutting* dilakukan untuk memotong area spasial yang tidak diperlukan dalam proses pemodelan. Secara sistematis, proses ini dilakukan dengan menentukan batas wilayah terluar dari WPP-NRI 572, kemudian membentuk area pemotongan berdasarkan rentang minimum dan maksimum koordinat *latitude* serta *longitude* yang masih mencakup wilayah valid tersebut. Area *non-valid* di luar batas terluar WPP-NRI 572 kemudian dipotong, sehingga hanya area spasial yang relevan dengan wilayah kajian yang dipertahankan. Tahapan ini tidak mengubah bentuk utama wilayah WPP-NRI 572 yang telah diperoleh melalui proses *masking*, tetapi hanya mengurangi ukuran data dengan membuang bagian luar yang tidak digunakan. Dengan demikian, dimensi spasial data menjadi lebih ringkas, penggunaan memori dapat dikurangi, dan proses *training* model ConvLSTM dapat dilakukan secara lebih efisien.

3.4.10 *Normalisasi Data*

Pada tahap ini, proses normalisasi hanya diterapkan pada variabel konsentrasi klorofil-a, sebagai data *input* dalam model ConvLSTM. Normalisasi klorofil-a dilakukan menggunakan metode *Min-Max Scaler* sesuai dengan formulasi matematis yang disajikan pada Persamaan (2.5). Penerapan *scaling* ini

bertujuan untuk menyesuaikan skala data klorofil-a sehingga lebih stabil secara numerik dan kompatibel dengan kebutuhan pemodelan berbasis *deep learning*, khususnya ConvLSTM. Dengan melakukan *scaling* pada variabel target, proses pelatihan model diharapkan menjadi lebih efisien dan konvergen, tanpa mengubah pola relatif serta karakteristik spasio-temporal klorofil-a yang menjadi fokus analisis dalam penelitian ini.

3.4.11 Penanganan Area *Non-Valid*

Pada proses *masking* yang dijelaskan pada subbab 3.4.3, area di luar batas WPP-NRI 572 ditetapkan sebagai nilai kosong atau *NaN* karena tidak termasuk dalam wilayah analisis. Setelah proses normalisasi dilakukan, nilai *NaN* pada area nonvalid tersebut masih perlu ditangani sebelum data dimasukkan ke dalam model ConvLSTM. Hal ini disebabkan karena model tidak dapat memproses data masukan yang mengandung nilai kosong dan dapat menyebabkan *error* pada proses *training*. Oleh karena itu, area di luar WPP-NRI 572 diisi dengan nilai 0 sebagai penanda area *non-valid*. Nilai 0 pada tahap ini tidak merepresentasikan nilai klorofil-a sebenarnya, melainkan hanya digunakan sebagai *spatial mask* agar model dapat menerima input dalam bentuk numerik yang lengkap tanpa mengubah cakupan wilayah analisis utama.

3.4.12 *Splitting Data*

Setelah tahap normalisasi, *dataset* terlebih dahulu dibentuk menjadi *sequence* sesuai jumlah *timestep* yang digunakan pada model ConvLSTM. Pembentukan *sequence* dilakukan agar setiap sampel masukan memuat informasi temporal dari beberapa periode sebelumnya, sedangkan target prediksi merepresentasikan nilai klorofil-a pada periode berikutnya. Setelah struktur *sequence* terbentuk, data kemudian dibagi menggunakan pendekatan *time-ordered splitting* dengan tetap mempertahankan urutan kronologis waktu.

Data berinterval *8-Day* memiliki total 505 waktu pengamatan selama periode 2014–2024. Pembagian data dilakukan secara sekuensial menjadi tiga bagian, yaitu data latih (*training set*), data evaluasi (*evaluation set*), dan data uji (*testing set*). Data latih mencakup periode 2014–2023 sebanyak 455 data, data evaluasi mencakup periode Januari 2024 hingga Juni 2024 sebanyak 23 data, dan

data uji mencakup periode Juli 2024 hingga Desember 2024 sebanyak 23 data. Rasio pembagian data ini adalah sekitar 90:5:5. Pendekatan tersebut digunakan untuk menjaga kontinuitas temporal, mencegah terjadinya *data leakage*, serta menyediakan porsi data latih yang lebih besar karena klorofil-a dianalisis sebagai variabel spasio-temporal yang sangat dipengaruhi oleh pola waktu. Dengan demikian, proses pelatihan, evaluasi, dan pengujian model dapat merepresentasikan skenario prediksi deret waktu secara lebih realistis (Huynh dkk., 2020; Madriyanti, 2025).

3.4.13 *Training Model ConvLSTM*

Pada tahap ini dilakukan *training* model awal sebagai *baseline* sebelum proses *hyperparameter tuning*. Data input yang digunakan berasal dari data latih (*training set*) hasil *time-ordered splitting* yang telah dibentuk menjadi *sequence*. Panjang *timestep* awal ditetapkan sebesar 3 dengan mengacu pada penelitian Madriyanti (2025) sebagai konfigurasi dasar awal. Sebelum masuk ke model, data telah melalui tahap *bounding box cutting* sebagaimana dijelaskan pada subbab (3.4.9), sehingga dimensi spasial data menjadi 367 titik *latitude* dan 346 titik *longitude*. Dengan demikian, bentuk input model adalah (3, 367, 346,1), yang merepresentasikan 3 urutan waktu, 367 grid *latitude*, 346 grid *longitude*, dan 1 *channel* berisi nilai variabel klorofil-a.

Arsitektur awal ConvLSTM dibangun menggunakan 3 *layers* ConvLSTM yang disusun secara bertingkat untuk menangkap pola spasio-temporal secara lebih hierarkis. Pemilihan 3 *layers* ini mengacu pada rujukan Rashid Durrani dkk. (2023), sedangkan penentuan *kernel size* dan *filter size* awal dipilih berdasarkan rujukan penelitian Zarei (2026). Pada konfigurasi awal ini, model dilatih menggunakan *batch size* sebesar 2 dan jumlah *epoch* sebanyak 50. Seluruh parameter tersebut digunakan sebagai percobaan awal untuk membentuk model *baseline*, sehingga belum merepresentasikan konfigurasi terbaik karena proses pencarian *hyperparameter* optimal dilakukan pada tahap berikutnya. Rincian struktur dan konfigurasi awal model ConvLSTM disajikan pada Tabel 3.4.

Tabel 3.4 Struktur dan Konfigurasi Model *Baseline*

Layer Model	Konfigurasi
<i>Input Layer</i>	Bentuk <i>input</i> : (3, 367, 346,1) <i>timesteps</i> : 3, <i>height (latitude)</i> : 367, <i>width (longitude)</i> : 346, <i>channel</i> : 1
ConvLSTM Layer 1	<i>Filter</i> : 64 <i>Kernel</i> : 3×3 <i>Padding</i> : same <i>Activation</i> : tanh <i>Return sequences</i> : True
<i>Batch Normalization</i>	-
ConvLSTM Layer 2	<i>Filter</i> : 32 <i>Kernel</i> : 3×3 <i>Padding</i> : same <i>Activation</i> : tanh <i>Return sequences</i> : True
<i>Batch Normalization</i>	-
ConvLSTM Layer 3	<i>Filter</i> : 16 <i>Kernel</i> : 3×3 <i>Padding</i> : same <i>Activation</i> : tanh <i>Return sequences</i> : False
<i>Batch Normalization</i>	-
Conv2D Output Layer	<i>Filter</i> : 1 <i>Kernel</i> : 3×3 <i>Padding</i> : same <i>Activation</i> : linear
<i>Epochs</i>	50
<i>Batch Size</i>	2
<i>Optimizer</i>	Adam (<i>learning rate</i> = 0.001)
<i>Loss Function</i>	Mean Squared Error (MSE)
<i>Metrics</i>	Mean Absolute Error (MAE)
<i>Training Strategy</i>	Early Stopping, Model Checkpoint, ReduceLROnPlateau

3.4.13.1 Percobaan *Timestep* dan Penambahan *Channel*

Sebelum dilakukan proses *hyperparameter tuning*, penelitian ini terlebih dahulu melakukan percobaan awal untuk menentukan konfigurasi *timestep* dan struktur *channel* masukan yang paling sesuai. Penentuan kandidat *timestep* dilakukan dengan mempertimbangkan pola autokorelasi temporal berdasarkan plot ACF dan PACF, sehingga panjang urutan waktu yang digunakan dapat merepresentasikan hubungan data klorofil-a dengan periode sebelumnya (Orabi Helmi dkk., 2022; Workneh & Jha, 2025). Selain itu, pada tahap ini juga dilakukan

percobaan penambahan *channel* baru dengan memanfaatkan *mask* atau cetakan wilayah WPP-NRI 572 sebagaimana ditunjukkan pada Gambar 3.2. *Mask* tersebut berisi nilai biner, yaitu nilai 1 untuk area valid di dalam wilayah kajian dan nilai 0 untuk area nonvalid di luar wilayah kajian. Penambahan *channel mask* bertujuan agar model ConvLSTM tidak hanya menerima informasi nilai klorofil-a, tetapi juga memperoleh informasi spasial mengenai area yang termasuk wilayah analisis dan area yang dikecualikan. Dengan demikian, struktur masukan model pada percobaan ini terdiri atas dua *channel*, yaitu *channel* pertama berupa data klorofil-a dan *channel* kedua berupa *mask* wilayah WPP-NRI 572.

3.4.14 *Hyperparameter Tuning*

Setelah percobaan awal model ConvLSTM dilakukan, tahap selanjutnya adalah *hyperparameter tuning* untuk memperoleh kombinasi parameter yang lebih optimal. Pada penelitian ini, proses *hyperparameter tuning* dilakukan menggunakan metode *Tree-structured Parzen Estimator* (TPE) sebagaimana dijelaskan pada Persamaan (2.25) hingga Persamaan (2.27). Metode TPE digunakan untuk mengevaluasi kombinasi *hyperparameter* secara lebih terarah berdasarkan hasil percobaan sebelumnya, sehingga proses pencarian tidak dilakukan secara acak sepenuhnya. *Hyperparameter* yang dioptimasi meliputi jumlah *filter* pada setiap lapisan ConvLSTM, ukuran *kernel*, *learning rate*, dan jenis *optimizer*. Proses pencarian dilakukan sebanyak 50 *trial*, dengan setiap *trial* dilatih maksimum 50 *epoch*. Selain itu, digunakan *patience* sebesar 5 untuk menghentikan proses pelatihan lebih awal apabila nilai galat pada data evaluasi tidak mengalami perbaikan dalam beberapa *epoch* berturut-turut (Rashid Durrani dkk., 2023; Vrskova dkk., 2021; Zarei, 2026).

Tujuan utama dari proses *hyperparameter tuning* adalah memperoleh konfigurasi model yang mampu menghasilkan galat prediksi klorofil-a paling rendah pada data evaluasi. Pada setiap *trial*, TPE memilih satu kombinasi *hyperparameter* dari ruang pencarian yang telah ditentukan, kemudian model ConvLSTM dilatih dan dievaluasi menggunakan nilai *loss* pada data evaluasi sebagai fungsi objektif. Kombinasi *hyperparameter* dengan nilai galat evaluasi terendah dipilih sebagai konfigurasi terbaik untuk digunakan pada tahap pemodelan

selanjutnya (Watanabe & Hutter, 2023; Zarei, 2026). Ruang pencarian *hyperparameter* yang digunakan dalam penelitian ini disajikan pada Tabel 3.5

Tabel 3.5 *Search Space Hyperparameter*

<i>Hyperparameter</i>	<i>Search Space</i>
<i>Number of Filters Layer 1</i>	32, 48, 64,
<i>Number of Filters Layer 2</i>	16, 32, 48
<i>Number of Filters Layer 3</i>	8, 16, 24
<i>Kernel Size</i>	(3×3), (5×5)
<i>Learning Rate</i>	0,0001- 0,00001
<i>Optimizer</i>	Adam, Adamax, Nadam

3.4.15 Evaluasi Model

Setelah proses *hyperparameter tuning* dan pelatihan model terbaik (*best model*) selesai, tahap selanjutnya adalah melakukan evaluasi kinerja model menggunakan data uji (*testing set*). Evaluasi ini bertujuan untuk menilai kemampuan generalisasi model ConvLSTM dalam memprediksi konsentrasi klorofil-a pada periode waktu yang tidak terlibat dalam proses pelatihan maupun *hyperparameter tuning*. Kinerja model dievaluasi menggunakan beberapa metrik evaluasi, yaitu *Mean Absolute Error* (MAE), *Root Mean Square Error* (RMSE), koefisien determinasi (*R-squared*), dan koefisien korelasi Pearson, yang masing-masing dirumuskan pada Persamaan (2.28) hingga Persamaan (2.34). Penggunaan keempat metrik ini memberikan evaluasi menyeluruh terhadap akurasi prediksi dan kemampuan model dalam menjelaskan variabilitas data.

3.4.16 Forecasting

Setelah kombinasi *hyperparameter* optimal diperoleh dan model ConvLSTM terbaik dievaluasi, tahap selanjutnya adalah melakukan pelatihan ulang atau *refit* menggunakan seluruh data historis periode 2014–2024. Pada tahap ini, data latih (*training set*), data evaluasi (*evaluation set*), dan data uji (*testing set*) digunakan secara bersamaan agar model dapat memanfaatkan informasi historis secara lebih lengkap sebelum digunakan untuk proses *forecasting*. Setelah proses *refit* selesai, model ConvLSTM digunakan untuk melakukan *forecasting* konsentrasi klorofil-a selama satu tahun ke depan, yaitu periode Januari–Desember 2025. Proses peramalan dilakukan secara berurutan melalui pendekatan *recursive forecasting*, yaitu hasil prediksi pada waktu sebelumnya digunakan kembali sebagai

masukannya untuk memprediksi periode berikutnya sesuai interval data *8-Day*. Hasil *forecasting* berupa distribusi spasio-temporal konsentrasi klorofil-a pada periode mendatang, yang selanjutnya digunakan sebagai dasar dalam analisis lanjutan untuk pemetaan *fishing ground* optimal di WPP-NRI 572.

3.4.17 Analisis Pemetaan *Fishing Ground* Optimal

Analisis pemetaan *fishing ground* optimal dilakukan dengan mengintegrasikan tiga hasil utama, yaitu EDA data bulanan, hasil *binning* intensitas *upwelling*, dan hasil *forecasting* konsentrasi klorofil-a menggunakan model ConvLSTM. Integrasi ketiga tahap tersebut digunakan untuk merangkum wilayah dan periode waktu yang memiliki kondisi oseanografi paling mendukung sebagai area potensial penangkapan ikan. Lokasi yang dikategorikan optimal ditentukan berdasarkan kesesuaian beberapa indikator, yaitu dominasi intensitas *upwelling* pada kelas *medium* hingga *high*, peningkatan atau konsistensi nilai klorofil-a, serta pola spasio-temporal yang berulang pada hasil analisis bulanan dan hasil prediksi. Dengan demikian, analisis ini tidak hanya melihat kondisi klorofil-a secara tunggal, tetapi juga mempertimbangkan keterkaitannya dengan dinamika *upwelling* dan kecenderungan temporal pada periode mendatang. Hasil rangkuman ini kemudian digunakan untuk menentukan wilayah yang paling potensial sebagai *fishing ground* optimal di WPP-NRI 572 berdasarkan lokasi dan waktu kemunculannya.

BAB IV

HASIL DAN PEMBAHASAN

4.1 Deskripsi Data

Deskripsi data dilakukan untuk memberikan gambaran awal mengenai karakteristik data oseanografi yang digunakan dalam penelitian, yaitu konsentrasi klorofil-a dan suhu permukaan laut atau *Sea Surface Temperature* (SST). Klorofil-a digunakan sebagai variabel utama dalam pemodelan prediksi menggunakan ConvLSTM, sedangkan SST digunakan sebagai parameter dalam perhitungan *SST-Based Upwelling Index* (UISST). Data tersebut diperoleh berdasarkan batas koordinat wilayah penelitian sehingga membentuk dimensi spasial sebagaimana disajikan pada Tabel 4.1.

Tabel 4.1 Dimensi Spasial Data

Keterangan	Nilai
Jumlah <i>latitude</i>	408
Jumlah <i>longitude</i>	432
Total <i>grid</i> spasial per <i>timestep</i>	176.256
Selisih antar- <i>grid</i> koordinat	0,04°
Jarak antar- <i>grid</i>	±4,4 km

Berdasarkan Tabel 4.1, data memiliki dimensi spasial sebesar 404 titik *latitude* dan 432 titik *longitude*, dengan resolusi koordinat sebesar 0,04° atau sekitar 4,4 km antar-*grid*. Dimensi tersebut diperoleh dari proses pembatasan wilayah kajian pada koordinat 90°BT–110°BT dan 10°LS–7°LU saat proses pengumpulan data. Selanjutnya, statistik deskriptif data asal klorofil-a dan SST disajikan pada Tabel 4.2.

Tabel 4.2 Deskripsi Data Asal Klorofil-a dan SST

Statistik	chlor_a (mg/m ³)	sst (°C)
<i>Count</i>	13.267.313	17.340.091
Rata-rata	0,216	29,886
Std Deviasi	0,637	1,307
<i>Min</i>	0,013	19,525
25% (Q1)	0,086	29,185
<i>Median</i>	0,117	30,010
75% (Q3)	0,177	30,765
<i>Max</i>	85,862	37,445
<i>Range</i>	85,848	17,920
<i>Skewness</i>	33,331	-0,716

Berdasarkan Tabel 4.2, nilai *count* antara klorofil-a dan SST menunjukkan perbedaan jumlah data, yaitu 13.267.313 untuk klorofil-a dan 17.340.091 untuk SST, yang mengindikasikan adanya *missing value* pada kedua variabel. Pada klorofil-a, nilai rata-rata sebesar 0,216 dan median sebesar 0,117 menunjukkan bahwa sebagian besar data berada pada nilai rendah, namun terdapat nilai maksimum yang sangat tinggi yaitu 85,862. Hal ini diperkuat oleh nilai *skewness* sebesar 33,331 yang menunjukkan distribusi sangat menceng ke kanan, sehingga terdapat sejumlah kecil data dengan nilai ekstrem yang jauh lebih tinggi dibandingkan mayoritas data. Secara umum, karakteristik ini menunjukkan bahwa distribusi klorofil-a tidak merata dan didominasi oleh nilai rendah dengan keberadaan *outlier* yang signifikan.

Sementara itu, pada SST, nilai rata-rata sebesar 29,886 dan median sebesar 30,010 menunjukkan distribusi data yang relatif stabil di sekitar nilai tengah, dengan nilai maksimum sebesar 37,445 yang masih berada dalam rentang yang wajar. Nilai *skewness* sebesar -0,716 menunjukkan distribusi sedikit menceng ke kiri, yang berarti sebagian besar data terkonsentrasi pada suhu yang relatif tinggi dengan sedikit nilai yang lebih rendah. Perbedaan jumlah data akibat *missing value* serta karakteristik distribusi yang lebih seimbang pada SST menunjukkan bahwa variabel ini memiliki variasi yang lebih terkendali dibandingkan klorofil-a. Secara umum, SST memiliki distribusi yang lebih simetris dan tidak terlalu dipengaruhi oleh nilai ekstrem dibandingkan klorofil-a.

4.2 Data Preprocessing

Tahap *preprocessing* data dilakukan untuk menyiapkan dataset agar lebih rapi, konsisten, dan siap digunakan dalam analisis. Pada penelitian ini, *preprocessing* awal mencakup tiga tahap utama, yaitu *merging data*, *masking data*, dan *handling missing value*.

4.2.1 Merging Data

Data awal yang digunakan dalam penelitian ini diperoleh dari MODIS NASA Ocean Color Level 3 dalam format NetCDF (.nc) yang terdiri atas 505 *file* observasi klorofil-a dan SST dengan periode komposit 8 harian (*8-Day Composite*). Pada tahap ini, seluruh dataset terlebih dahulu digabungkan menjadi satu *file*

NetCDF terpadu, kemudian ditambahkan dimensi waktu (*time*) agar setiap data memiliki urutan temporal yang konsisten berdasarkan tanggal awal masing-masing periode komposit. Struktur dimensi dataset setelah proses *merging* disajikan pada Tabel 4.3.

Tabel 4.3 Dimensi *Dataset* setelah Proses *Merging*

Dimensi	Ukuran
<i>time</i>	505
<i>lat</i>	408
<i>lon</i>	432

4.2.2 *Masking Data*

Setelah proses *merging*, tahap selanjutnya adalah *masking* data untuk membatasi cakupan analisis hanya pada wilayah WPP-NRI 572. Proses ini menggunakan data batas wilayah WPP-NRI 572 sebagaimana ditampilkan pada Gambar 3.2. Sebelum *masking* dilakukan, sistem koordinat CRS pada data NetCDF dan GeoJSON diperiksa untuk memastikan kesesuaian referensi spasial. Hasil pemeriksaan CRS disajikan pada Tabel 4.4.

Tabel 4.4 Hasil pemeriksaan CRS

Data	CRS
Data klorofil-a dan SST (NetCDF)	EPSG:4326
Data batas wilayah WPP-NRI 572 (GeoJSON)	EPSG:4326


Berdasarkan Tabel 4.4, data NetCDF klorofil-a dan SST serta data GeoJSON batas WPP-NRI 572 menggunakan CRS yang sama, yaitu EPSG:4326. Kesesuaian tersebut memungkinkan proses pencocokan koordinat dilakukan tanpa transformasi sistem koordinat. Selanjutnya, batas wilayah WPP-NRI 572 digunakan untuk membentuk *mask* spasial berupa nilai logika *True* (1) untuk piksel yang berada di dalam wilayah penelitian dan *False* (0) untuk piksel yang berada di luar wilayah penelitian. Hasil pembentukan *mask* spasial disajikan pada Tabel 4.5.

Tabel 4.5 Hasil Pembentukan *Mask* Spasial

Keterangan	Jumlah Piksel
<i>TRUE</i>	44.054
<i>FALSE</i>	132.202
Total piksel	176.256

Berdasarkan Tabel 4.5, data awal memiliki dimensi spasial sebesar 408×432 atau sebanyak 176.256 piksel untuk satu *timestep*. Setelah proses *masking*,

sebanyak 44.054 piksel yang berada di dalam wilayah WPP-NRI 572 dipertahankan sebagai area valid, sedangkan 132.202 piksel di luar wilayah penelitian ditetapkan sebagai nilai kosong atau *NaN*. Hasil *masking* ini kemudian digunakan sebagai dasar dalam tahap pengolahan berikutnya, termasuk penanganan *missing value*, perhitungan UISST, dan persiapan data untuk pemodelan ConvLSTM. Visualisasi hasil *masking* ditampilkan pada Gambar 4.1.



Gambar 4.1 Hasil Sebelum dan Sesudah Proses *Masking*

4.2.3 Handling Missing Value

Tahap *handling missing value* dilakukan untuk menangani nilai kosong pada data klorofil-a dan SST di area valid setelah proses *masking* wilayah WPP-NRI 572. Nilai kosong pada area valid perlu direkonstruksi agar data tetap memiliki struktur spasial dan temporal yang konsisten untuk analisis lanjutan.

4.2.3.1 Identifikasi Proporsi Missing Value

Sebelum dilakukan rekonstruksi data, terlebih dahulu dilakukan identifikasi proporsi *missing value* pada variabel klorofil-a dan SST. Identifikasi ini bertujuan untuk mengetahui tingkat kelengkapan data pada area valid WPP-NRI 572 serta menjadi dasar dalam menentukan kebutuhan rekonstruksi data. Ringkasan proporsi *missing value* pada kedua variabel disajikan pada Tabel 4.6.

Tabel 4.6 Ringkasan *Missing Value* Klorofil-a dan SST

Statistik	Klorofil-a	SST
Total observasi	22.247.270	22.247.270
Total valid	13.267.313	17.340.091
Total <i>missing</i>	8.979.957	4.510.693
Persentase <i>missing</i>	40,36%	20,64%

Selain berdasarkan jumlah keseluruhan observasi, proporsi *missing value* juga dianalisis pada setiap *timestep* untuk mengidentifikasi periode pengamatan dengan tingkat kehilangan data yang tinggi. Hasil identifikasi tersebut disajikan pada Tabel 4.7.

Tabel 4.7 Distribusi *Timestep* Berdasarkan Proporsi *Missing Value*


Ambang <i>Missing Value</i>	Klorofil-a	SST
<i>Missing</i> > 50%	175 <i>timestep</i> (34,65%)	60 <i>timestep</i> (12,10%)
<i>Missing</i> > 75%	62 <i>timestep</i> (12,28%)	14 <i>timestep</i> (2,82%)
<i>Missing</i> > 95%	7 <i>timestep</i> (1,39%)	1 <i>timestep</i> (0,20%)

Berdasarkan Tabel 4.7, klorofil-a memiliki 8.979.957 observasi *missing* atau sebesar 40,36% dari total 22.247.270 observasi. Berdasarkan Tabel 4.7, terdapat 175 *timestep* dengan proporsi *missing value* lebih dari 50%, 62 *timestep* lebih dari 75%, dan 7 *timestep* lebih dari 95%. Hasil tersebut menunjukkan bahwa data klorofil-a memiliki tingkat kehilangan data yang cukup tinggi pada sejumlah periode pengamatan.

Sementara itu, SST memiliki 4.510.693 observasi *missing* atau sebesar 20,28%. Jumlah *timestep* dengan tingkat kehilangan data yang tinggi juga lebih sedikit, yaitu 60 *timestep* dengan *missing value* lebih dari 50%, 14 *timestep* lebih dari 75%, dan 1 *timestep* lebih dari 95%. Meskipun memiliki tingkat kelengkapan yang lebih baik, data SST tetap memerlukan rekonstruksi agar dapat digunakan secara konsisten dalam perhitungan UISST dan analisis intensitas *upwelling*.


4.2.3.2 Performa 3D DINEOF

Pada tahap ini, metode 3D-DINEOF diterapkan untuk merekonstruksi nilai hilang pada dua variabel utama, yaitu klorofil-a dan SST. Evaluasi performa dilakukan melalui pendekatan *cross-validation* (CV), yaitu dengan menyembunyikan 3% dari total data valid, kemudian membandingkan hasil rekonstruksi terhadap nilai aslinya. Jumlah *mode* EOF diuji dari *mode* 1 hingga *mode* 30, dan *mode* terbaik ditentukan berdasarkan nilai RMSE terendah. Hasil evaluasi perubahan RMSE pada setiap *mode* untuk variabel klorofil-a dan SST ditampilkan pada Gambar 4.2.



Gambar 4.2 CV RMSE pada Setiap *Mode* EOF untuk Variabel Klorofil-a dan SST

Berdasarkan Gambar 4.2, nilai CV RMSE pada kedua variabel menunjukkan pola penurunan seiring bertambahnya jumlah *mode* EOF. Penurunan paling besar terjadi pada *mode* awal, kemudian semakin melandai pada *mode-mode* berikutnya. Pada variabel klorofil-a, *mode* terbaik diperoleh pada *mode* ke-30 dengan nilai CV RMSE sebesar 0,106601, sedangkan pada variabel SST *mode* terbaik juga diperoleh pada *mode* ke-30 dengan nilai CV RMSE sebesar 0,508096. Hal ini menunjukkan bahwa dalam rentang pengujian 1 hingga 30 *mode*, penambahan *mode* masih mampu memperbaiki hasil rekonstruksi, meskipun laju perbaikannya semakin kecil. Setelah *mode* terbaik diperoleh, kestabilan proses rekonstruksi pada *mode* ke-30 diamati melalui perubahan RMSE per iterasi sebagaimana ditampilkan pada Gambar 4.3.



Gambar 4.3 Perubahan RMSE per Iterasi pada *Mode 30* 3D-DINEOF untuk Klorofil-a dan SST

Berdasarkan Gambar 4.3 di atas, perubahan RMSE pada *mode 30* menunjukkan pola penurunan pada tiga tahap rekonstruksi, yaitu berdasarkan sumbu *longitude*, *latitude*, dan *time*. Pada masing-masing tahap, nilai RMSE change relatif tinggi pada iterasi awal, kemudian menurun secara bertahap hingga mendekati nilai yang lebih kecil. Pola ini menunjukkan bahwa pembaruan nilai hasil rekonstruksi semakin stabil seiring bertambahnya iterasi. Variabel SST memiliki nilai perubahan RMSE yang lebih besar dibandingkan klorofil-a, terutama pada awal setiap tahap rekonstruksi, yang mengindikasikan bahwa proses penyesuaian nilai pada SST berlangsung dengan skala perubahan yang lebih besar. Namun, kedua variabel tetap menunjukkan kecenderungan yang sama, yaitu perubahan rekonstruksi semakin kecil pada akhir iterasi, sehingga hasil pengisian *missing value* menjadi lebih stabil setelah melalui pembaruan pada ketiga dimensi tersebut.

4.2.3.3 Hasil Rekonstruksi Data Menggunakan 3D DINEOF

Setelah proses identifikasi *missing value* dan evaluasi performa 3D DINEOF dilakukan, data klorofil-a dan SST direkonstruksi untuk mengisi nilai

kosong pada area valid WPP-NRI 572. Hasil rekonstruksi ini kemudian dianalisis secara deskriptif untuk melihat perubahan karakteristik data setelah proses pengisian *missing value*. Ringkasan statistik data setelah proses rekonstruksi menggunakan 3D DINEOF disajikan pada Tabel 4.8.


Tabel 4.8 Deskripsi Data setelah Rekonstruksi *Missing Value*

Variabel	chlor_a (mg/m ³)	sst (°C)
Rata-rata	0,214	29,795
Std Deviasi	0,678	1,251
Min	0	19,525
25% (Q1)	0,088	29,082
Median	0,119	29,86
75% (Q3)	0,177	30,64
Max	1.212,85	37,445
Range	1.212,85	17,92
Skewness	296,86	-0,57

Berdasarkan perbandingan Tabel 4.2 dan Tabel 4.8, rata-rata dan median klorofil-a relatif tetap, yaitu dari 0,216 menjadi 0,214 dan dari 0,117 menjadi 0,119. Namun, nilai maksimum meningkat dari 85,862 menjadi 1.212,850 mg/m³, sedangkan *skewness* meningkat dari 33,331 menjadi 296,860. Hasil tersebut menunjukkan bahwa rekonstruksi mempertahankan kecenderungan pusat data, tetapi menghasilkan nilai ekstrem yang memperkuat kemencengan distribusi ke kanan. Pada SST, rata-rata menurun dari 29,886 menjadi 29,795 °C dan median dari 30,010 menjadi 29,860 °C, sedangkan nilai maksimum tetap sebesar 37,445 °C. Nilai *skewness* berubah dari -0,716 menjadi -0,570, yang menunjukkan bahwa distribusi SST setelah rekonstruksi tetap menceng ke kiri, tetapi sedikit lebih mendekati distribusi simetris.

Menurut penelitian García-Peña dkk. (2021) dan M. Yu dkk. (2026), penerapan dekomposisi *Singular Value Decomposition* (SVD) pada metode 3D-DINEOF memiliki keterbatasan karena sifatnya yang tidak *robust* terhadap *outlier* atau nilai ekstrem. Ketidakseimbangan distribusi data dapat mendistorsi komponen hasil dekomposisi, yang berimplikasi pada penyimpangan nilai rekonstruksi di sebagian kecil titik, sehingga hal ini menjelaskan terjadinya lonjakan drastis pada nilai maksimum klorofil-a. Walaupun terdapat anomali pada nilai ekstrem tersebut, metode ini secara keseluruhan tetap bekerja efektif dalam menginterpolasi kekosongan informasi spasial. Perbandingan visual kelengkapan cakupan data, di

mana area yang sebelumnya kosong menjadi terisi setelah proses rekonstruksi, dapat diamati pada Gambar 4.4.




Gambar 4.4 Sampel Data Sebelum dan Sesudah Proses 3D DINEOF

4.3 *Exploratory Data Analysis*

4.3.1 *Linechart Data Klorofil-a dan SST*

Visualisasi *line chart* digunakan untuk melihat pola perubahan temporal klorofil-a dan SST di WPP-NRI 572 setelah proses rekonstruksi data. Grafik ini bertujuan untuk memberikan gambaran awal mengenai dinamika kedua variabel sepanjang periode pengamatan, khususnya dalam melihat kecenderungan fluktuasi, periode peningkatan, dan hubungan umum antara perubahan klorofil-a dan SST. Hasil visualisasi *line chart* klorofil-a dan SST disajikan pada Gambar 4.5.




Gambar 4.5 *Linechart* Data Klorofil-a dan SST pada 2014–2024

Berdasarkan Gambar 4.5, nilai klorofil-a secara umum berada pada kisaran rendah dan relatif stabil pada sebagian besar periode pengamatan, yaitu sekitar 0,1–0,3 mg/m³. Namun, terdapat beberapa periode dengan peningkatan yang cukup menonjol, terutama pada akhir 2019 hingga awal 2020 dan akhir 2023 hingga awal 2024. Pada periode tersebut, konsentrasi klorofil-a meningkat tajam dibandingkan periode lainnya, dengan puncak tertinggi mendekati 1,4 mg/m³ pada akhir 2023 hingga awal 2024. Pola ini menunjukkan bahwa konsentrasi klorofil-a di WPP-NRI 572 tidak bersifat konstan, melainkan mengalami fluktuasi temporal yang pada periode tertentu dapat meningkat secara jelas.

Sementara itu, SST menunjukkan pola fluktuasi yang lebih teratur dibandingkan klorofil-a, dengan nilai yang sebagian besar berada pada kisaran 29–31 °C. Beberapa periode menunjukkan penurunan SST yang cukup jelas, terutama sekitar akhir 2019 hingga awal 2020 dan akhir 2023 hingga awal 2024. Pada waktu yang relatif berdekatan, grafik klorofil-a justru menunjukkan peningkatan. Pola berlawanan ini mengindikasikan adanya hubungan temporal antara penurunan SST dan peningkatan klorofil-a pada periode tertentu. Dalam konteks analisis *upwelling*, kondisi tersebut menjadi indikasi awal bahwa periode dengan suhu permukaan laut yang lebih rendah dapat berkaitan dengan meningkatnya konsentrasi klorofil-a. Namun, pola ini masih perlu dikaji lebih lanjut melalui perhitungan UISST agar interpretasi intensitas *upwelling* dapat dilakukan secara lebih terukur.

4.3.2 Distribusi Data Klorofil-a dan SST

Visualisasi distribusi data dilakukan untuk melihat pola sebaran nilai klorofil-a dan SST secara keseluruhan setelah proses rekonstruksi data. Pada tahap ini, distribusi diamati melalui *histogram* dan *boxplot* agar dapat diketahui kecenderungan pusat data, bentuk sebaran, serta indikasi nilai ekstrem. Khusus pada klorofil-a, visualisasi dibatasi menggunakan persentil 99,5% karena pada Tabel 4.4 masih terdapat anomali *outlier* yang cukup tinggi setelah proses rekonstruksi. Hasil visualisasi distribusi klorofil-a dan SST disajikan pada Gambar 4.6.



Gambar 4.6 Distribusi Data Klorofil-a dan SST


Berdasarkan Gambar 4.6, distribusi klorofil-a cenderung miring ke kanan (*right-skewed*). Sebagian besar nilai terkonsentrasi pada rentang rendah, terutama di sekitar 0,1–0,2 mg/m^3 , sedangkan frekuensi semakin menurun pada nilai yang lebih tinggi. Pola ini menunjukkan bahwa konsentrasi klorofil-a di WPP-NRI 572 umumnya berada pada nilai rendah hingga sedang, tetapi masih terdapat sebagian kecil data dengan nilai lebih tinggi. Hasil *boxplot* juga menunjukkan bahwa median klorofil-a berada di sekitar 0,12 mg/m^3 , dengan rentang antarkuartil yang relatif sempit. Hal ini mengindikasikan bahwa sebagian besar data berada pada rentang yang dekat, sementara nilai tinggi hanya muncul pada sebagian kecil observasi.

Sementara itu, distribusi SST menunjukkan pola yang lebih terpusat dibandingkan klorofil-a. Sebagian besar nilai SST berada pada kisaran 29–31 $^{\circ}\text{C}$, dengan puncak frekuensi di sekitar 30 $^{\circ}\text{C}$. Hasil *boxplot* memperlihatkan median SST yang berada mendekati 30 $^{\circ}\text{C}$, dengan rentang antarkuartil yang tidak terlalu lebar. Pola ini menunjukkan bahwa SST memiliki sebaran yang lebih stabil dan tidak didominasi oleh nilai ekstrem seperti pada klorofil-a. Perbedaan bentuk

distribusi antara kedua variabel ini menunjukkan bahwa klorofil-a memiliki variasi yang lebih tidak merata, sedangkan SST cenderung membentuk distribusi yang lebih terkonsentrasi pada nilai tengah. Kondisi tersebut menjadi dasar penting dalam tahap analisis berikutnya, terutama karena klorofil-a digunakan sebagai variabel utama dalam pemodelan ConvLSTM, sedangkan SST digunakan untuk perhitungan UISST.

4.3.3 Scatter Plot

Visualisasi *scatter plot* digunakan untuk melihat hubungan antara rata-rata SST dan rata-rata klorofil-a pada waktu yang sinkron di wilayah WPP-NRI 572. Plot ini bertujuan untuk mengamati arah dan kekuatan hubungan kedua variabel, terutama karena SST dan klorofil-a merupakan parameter utama yang digunakan dalam analisis indikasi *upwelling*. Hasil visualisasi hubungan antara SST dan klorofil-a disajikan pada Gambar 4.7.




Gambar 4.7 Scatter Plot Korelasi Rata-rata SST dan Klorofil-a

Berdasarkan Gambar 4.7, hubungan antara SST dan klorofil-a menunjukkan korelasi negatif dengan nilai Pearson sebesar -0,594. Nilai tersebut menunjukkan bahwa ketika SST cenderung menurun, konsentrasi klorofil-a cenderung meningkat. Pola ini terlihat dari arah garis regresi yang menurun dari kiri ke kanan. Secara oseanografis, hubungan negatif ini dapat dikaitkan dengan proses *upwelling*, yaitu ketika massa air bersuhu lebih rendah dari lapisan bawah naik ke permukaan

dan membawa nutrisi yang mendukung peningkatan produktivitas primer. Dengan demikian, hasil korelasi ini selaras dengan penelitian Utama dkk. (2024) dan Sari dkk. (2022) yang menyatakan bahwa kejadian *upwelling* umumnya ditandai oleh peningkatan konsentrasi klorofil-a serta penurunan suhu permukaan laut atau SST.

4.3.4 Distribusi dan Sebaran Bulanan Klorofil-a

Analisis distribusi dan sebaran bulanan klorofil-a dilakukan untuk melihat variasi konsentrasi klorofil-a berdasarkan bulan serta pola spasialnya di wilayah WPP-NRI 572. Visualisasi ini disajikan dalam dua bentuk, yaitu *boxplot* bulanan untuk melihat sebaran nilai setiap bulan dan peta sebaran bulanan untuk mengetahui lokasi dengan konsentrasi klorofil-a yang relatif lebih tinggi. Hasil distribusi dan sebaran bulanan klorofil-a ditunjukkan pada Gambar 4.8 dan Gambar 4.9.




Gambar 4.8 *Boxplot* Distribusi Bulanan Klorofil-a

Berdasarkan Gambar 4.8, distribusi klorofil-a bulanan menunjukkan bahwa sebagian besar nilai berada pada rentang rendah, sementara beberapa bulan memiliki nilai ekstrem yang cukup tinggi. Nilai ekstrem paling menonjol terlihat pada bulan November dan Desember, dengan nilai maksimum yang jauh lebih tinggi dibandingkan bulan lainnya. Pola ini menunjukkan bahwa terdapat sebagian kecil *pixel* dengan konsentrasi klorofil-a sangat tinggi, sehingga skala *boxplot* menjadi melebar dan distribusi utama data tampak terkonsentrasi di bagian bawah grafik. Kondisi tersebut sejalan dengan hasil deskripsi data setelah rekonstruksi 3D DINEOF pada Tabel 4.8, yang menunjukkan adanya nilai maksimum klorofil-a

yang sangat tinggi setelah proses rekonstruksi. Oleh karena itu, perlu dilakukan penanganan lebih lanjut untuk nilai *outlier* ekstrem ini.

Sebaran Bulanan Klorofil-a WPP 572 (2014-2024)




Gambar 4.9 Heatmap Sebaran Bulanan Klorofil-a

Secara spasial, pada Gambar 4.9 terlihat bahwa konsentrasi klorofil-a yang lebih tinggi cenderung muncul di area pesisir, terutama di sepanjang sisi timur domain WPP-NRI 572 yang berdekatan dengan pantai barat Sumatra dan sekitar Selat Sunda. Pada bulan Januari hingga Juni, konsentrasi klorofil-a relatif lebih rendah dan sebagian besar area lepas pantai didominasi nilai rendah, meskipun konsentrasi lebih tinggi tetap terlihat tipis di sepanjang wilayah pesisir. Peningkatan mulai tampak pada Juli dan Agustus, terutama di bagian selatan WPP-NRI 572 pada kisaran lintang sekitar 6°LS hingga 8°LS dan bujur sekitar 102°BT hingga 106°BT . Sebaran yang lebih luas terlihat pada September hingga November, ketika

konsentrasi klorofil-a meningkat pada wilayah selatan hingga tengah WPP-NRI 572, terutama pada kisaran 2°LS hingga 7°LS dan 99°BT hingga 106°BT . Pada Desember, konsentrasi yang relatif tinggi masih terlihat di sepanjang pesisir dan bagian selatan, tetapi sebarannya tampak lebih terbatas dibandingkan November. Pola ini menunjukkan bahwa peningkatan klorofil-a bulanan lebih dominan terjadi pada paruh kedua tahun, khususnya sekitar September hingga November, dengan konsentrasi yang lebih kuat pada wilayah pesisir barat Sumatra bagian tengah-selatan hingga sekitar Selat Sunda.

4.3.5 Distribusi dan Sebaran Bulanan SST

Analisis distribusi dan sebaran bulanan SST dilakukan untuk melihat perubahan suhu permukaan laut berdasarkan bulan serta pola spasialnya di WPP-NRI 572. Visualisasi disajikan dalam bentuk *boxplot* untuk melihat variasi statistik bulanan dan *heatmap* untuk mengamati sebaran suhu secara spasial. Hasil distribusi bulanan SST disajikan pada Gambar 4.10, sedangkan sebaran spasial bulannya disajikan pada Gambar 4.11.




Gambar 4.10 *Boxplot* Distribusi Bulanan SST

Berdasarkan Gambar 4.10, distribusi SST menunjukkan adanya variasi bulanan yang cukup jelas. Median SST cenderung lebih tinggi pada Februari hingga Mei, dengan nilai yang berada di sekitar $30\text{--}31^{\circ}\text{C}$. Kondisi ini menunjukkan bahwa pada periode tersebut sebagian besar wilayah WPP-NRI 572 memiliki suhu permukaan laut yang relatif hangat. Sebaliknya, median SST mulai menurun pada Agustus hingga November, terutama pada September dan Oktober yang menunjukkan banyak nilai rendah di bawah 26°C . Penurunan ini mengindikasikan

adanya periode pendinginan suhu permukaan laut pada sebagian wilayah WPP-NRI 572. Selain itu, keberadaan *outlier* pada hampir seluruh bulan menunjukkan bahwa variasi suhu tidak terjadi secara seragam di seluruh area, tetapi dipengaruhi oleh perbedaan lokasi spasial dan waktu pengamatan.

Sebaran Bulanan SST WPP 572 (2014-2024)



Gambar 4.11 *Heatmap* Sebaran Bulanan SST

Pada Gambar 4.11, pola spasial SST memperlihatkan bahwa suhu permukaan laut yang lebih hangat umumnya muncul pada bagian utara hingga tengah WPP-NRI 572, terutama pada kisaran lintang sekitar 0° hingga 6° LU dan bujur sekitar 94° BT hingga 100° BT. Pada bulan Maret hingga Mei, warna peta didominasi oleh nilai SST yang lebih tinggi, sehingga menunjukkan pemanasan yang relatif merata di sebagian besar wilayah. Sementara itu, suhu yang lebih rendah mulai tampak jelas pada Juli dan semakin kuat pada Agustus hingga Oktober, terutama di bagian selatan WPP-NRI 572 pada kisaran lintang sekitar 5° LS hingga 9° LS dan bujur sekitar 100° BT hingga 105° BT. Pola pendinginan di

bagian selatan ini berdekatan dengan periode peningkatan klorofil-a yang telah ditunjukkan pada Gambar 4.8, sehingga dapat menjadi indikasi awal adanya dinamika oseanografi yang berkaitan dengan proses *upwelling*. Namun, interpretasi tersebut tetap perlu dikonfirmasi melalui perhitungan UISST pada tahap analisis berikutnya.

4.4 *Outlier Handling* pada Klorofil-a

Berdasarkan hasil rekonstruksi pada Tabel 4.8 dan visualisasi distribusi bulanan klorofil-a pada Gambar 4.8, ditemukan adanya nilai ekstrem yang sangat tinggi pada variabel klorofil-a setelah proses rekonstruksi menggunakan 3D-DINEOF. Nilai ekstrem tersebut berpotensi mengganggu proses normalisasi serta menurunkan kinerja model, mengingat bahwa variabel klorofil-a digunakan sebagai input utama dalam proses pemodelan ConvLSTM. Oleh karena itu, diperlukan tahap *outlier handling* untuk membatasi pengaruh nilai ekstrem tersebut agar data menjadi lebih stabil dan representatif untuk proses pelatihan model.

Untuk mengatasi permasalahan tersebut, dilakukan tahap *outlier handling* menggunakan metode *winsorizing* dengan batas persentil 99,5%. Melalui pendekatan ini, nilai klorofil-a yang berada di atas batas persentil 99,5% tidak dihapus, tetapi dibatasi pada nilai ambang persentil tersebut. Berikut adalah ringkasan proses dan hasil *outlier handling* yang tertera pada Tabel 4.9 dan Tabel 4.10.

Tabel 4.9 Ringkasan Proses *Winsorizing* Klorofil-a

Komponen	Nilai
Nilai batas persentil 99.5%	2,866913 mg/m ³
Total data valid	22.247.270
Jumlah data di atas persentil	111.237
Persentase dari data valid	0,500003%

Tabel 4.10 Perbandingan Statistik Klorofil-a Sebelum dan Sesudah *Outlier Handling*

	Sebelum	Sesudah
Minimum	0,000020	0,000020
Maksimum	1212,85	2,867
Rata-rata	0,21444	0,19907
Std Deviasi	0,67756	0,30765

Berdasarkan Tabel 4.9, proses *winsorizing* dilakukan dengan batas persentil 99,5% pada nilai 2,866913 mg/m³. Dari total 22.247.270 data valid, terdapat 111.237 data atau sebesar 0,500003% yang berada di atas batas tersebut. Hal ini

menunjukkan bahwa hanya sebagian kecil data yang mengalami penyesuaian, sehingga proses *winsorizing* tidak mengubah karakteristik utama data, melainkan hanya membatasi nilai-nilai ekstrem pada bagian atas distribusi.

Kemudian pada Tabel 4.10, nilai maksimum klorofil-a mengalami penurunan yang sangat signifikan dari 1212,845 menjadi 2.867 setelah dilakukan *outlier handling*. Penurunan ini menunjukkan bahwa nilai ekstrem hasil rekonstruksi berhasil dikendalikan. Selain itu, nilai rata-rata menurun dari 0,21444 menjadi 0,19907, dan standar deviasi juga menurun dari 0,67756 menjadi 0,30765. Penurunan standar deviasi mengindikasikan bahwa sebaran data menjadi lebih homogen dan tidak lagi dipengaruhi oleh nilai ekstrem. Sementara itu, nilai minimum tetap sama, sehingga dapat disimpulkan bahwa proses *winsorizing* hanya memengaruhi nilai pada batas atas distribusi. Dengan demikian, data klorofil-a menjadi lebih stabil dan siap digunakan pada tahap normalisasi serta pemodelan ConvLSTM.

4.5 *Upwelling Detection*

Deteksi *upwelling* dilakukan menggunakan *SST-Based Upwelling Index* (UISST) berdasarkan perbedaan suhu permukaan laut pada setiap lintang dan *timestep*. Nilai SST pada titik paling barat ditetapkan sebagai SST_{max} , kemudian dikurangi dengan nilai SST pada setiap titik di sebelah timurnya. Tahapan analisis meliputi penentuan SST_{max} , perhitungan UISST, identifikasi titik *upwelling* berdasarkan nilai UISST, serta pengelompokan intensitas *upwelling* melalui proses *binning*.

4.5.1 Penentuan Nilai SST_{max}

Penentuan SST_{max} dilakukan untuk memperoleh suhu referensi dalam perhitungan UISST. Pada setiap *timestep* dan lintang, nilai SST pada titik paling barat (*west*) ditetapkan sebagai SST_{max} . Nilai tersebut kemudian digunakan sebagai pembanding terhadap SST pada setiap titik di sebelah timurnya pada lintang dan *timestep* yang sama. Statistik deskriptif SST_{max} disajikan pada Tabel 4.11.

Tabel 4.11 Statistik Deskriptif SST_{max}

Statistik	SST_{max} (°C)
Count	182.032
Rata-rata	29,621

Statistik	SST _{max} (°C)
Std Deviasi	1,147
Min	24,055
25% (Q1)	28,955
Median	29,635
75% (Q3)	30,370
Max	34,895
Range	10,840

Berdasarkan Tabel 4.11, SST_{max} memiliki rata-rata sebesar 29,621 °C dan median sebesar 29,635 °C. Sebanyak 50% nilai SST_{max} berada pada rentang 28,955–30,370 °C, sedangkan nilai minimum dan maksimum masing-masing sebesar 24,055 °C dan 34,895 °C. Rentang sebesar 10,840 °C menunjukkan adanya variasi suhu referensi antar-*timestep* dan lintang yang selanjutnya digunakan dalam perhitungan UISST.

4.5.2 Perhitungan Nilai UISST

Perhitungan nilai UISST dilakukan menggunakan Persamaan (2.1), yaitu selisih antara SST_{max} yang sudah ditentukan sebelumnya dan SST_{min}. Pada penelitian ini, SST_{min} direpresentasikan oleh seluruh nilai SST pada titik-titik *di* sebelah timur menuju ke garis pantai (*coastal*) yang berada pada lintang yang sama. Perhitungan ini dilakukan pada seluruh *grid* valid WPP-NRI 572 sehingga menghasilkan nilai UISST yang merepresentasikan perbedaan suhu antara titik referensi paling barat dan setiap titik di sebelah timurnya. Statistik deskriptif hasil perhitungan UISST disajikan pada Tabel 4.12.

Tabel 4.12 Statistik Deskriptif UISST


Statistik	UISST (°C)
Count	21.850.784
Rata-rata	-0,140
Std Deviasi	0,830
Min	-7,041
25% (Q1)	-0,610
Median	-0,100
75% (Q3)	0,335
Max	6,880
Range	13,921

Berdasarkan Tabel 4.12, nilai UISST memiliki rata-rata sebesar -0,140 °C dan median sebesar -0,100 °C, yang menunjukkan bahwa sebagian besar perbedaan suhu berada di sekitar nol dengan kecenderungan sedikit negatif. Nilai UISST

negatif menunjukkan bahwa SST pada titik di sebelah timur lebih tinggi daripada SST_{max} sehingga tidak dikategorikan sebagai indikasi *upwelling*. Sebaliknya, nilai UISST positif menunjukkan adanya penurunan suhu terhadap titik referensi dan selanjutnya digunakan untuk mengidentifikasi indikasi *upwelling*. Rentang nilai sebesar 13,921 °C menunjukkan adanya variasi perbedaan suhu yang cukup luas pada setiap *grid*, lintang, dan *timestep*.

4.5.3 Validasi *Upwelling Valid*

Validasi *upwelling* valid dilakukan untuk memisahkan titik yang menunjukkan indikasi *upwelling* berdasarkan nilai UISST yang telah dihitung sebelumnya. Pada tahap ini, suatu titik dikategorikan sebagai *upwelling* valid apabila memiliki nilai UISST lebih besar dari 0, yang menunjukkan bahwa suhu pada area *coastal* lebih rendah dibandingkan suhu referensi *offshore* pada lintang yang sama. Persentase *upwelling* valid dan *non-valid* disajikan pada Gambar 4.13.



Gambar 4.12 Barplot Persentase *Upwelling Valid* dan *non-Valid*

Berdasarkan Gambar 4.12, dari total 21.850.784 observasi sebagaimana tercantum pada Tabel 4.12, sebanyak 42,89% dikategorikan sebagai *upwelling valid*, sedangkan 57,11% termasuk kategori *non-valid*. Proporsi *non-valid* yang lebih besar menunjukkan bahwa sebagian besar observasi memiliki nilai UISST kurang dari atau sama dengan nol. Sementara itu, observasi dengan nilai UISST lebih dari nol menunjukkan adanya penurunan suhu pada titik sebelah timur terhadap SST_{max} dan selanjutnya digunakan dalam penentuan intensitas *upwelling*.

4.5.4 *Binning Intensitas Upwelling*


Setelah nilai *upwelling* valid diperoleh, tahap selanjutnya adalah melakukan *binning* intensitas *upwelling* menggunakan pendekatan Interquartile Range (IQR).

Proses ini dilakukan untuk mengelompokkan nilai UISST valid ke dalam beberapa kelas intensitas seperti yang telah dijelaskan pada Tabel 3.2. Dalam penelitian ini, kelas 0 merepresentasikan *non-upwelling*, kelas 1 merepresentasikan *weak upwelling*, kelas 2 merepresentasikan *intermediate upwelling*, dan kelas 3 merepresentasikan *strong upwelling*. Statistik deskriptif nilai UISST valid yang digunakan sebagai dasar *binning* disajikan pada Tabel 4.13.

Tabel 4.13 Statistik Deskriptif *upwelling* valid

Statistik	UISST Valid (°C)
Count	9.372.243
Rata-rata	0,568
Std Deviasi	0,516
Min	0,000
25% (Q1)	0,185
Median	0,420
75% (Q3)	0,800
Max	6,880
Range	6,880

Berdasarkan Tabel 4.13, dari total 21.850.784 observasi, sebanyak 9.372.243 observasi merupakan *upwelling valid*, dimana memiliki nilai UISST positif dengan rata-rata sebesar 0,568 °C dan median sebesar 0,420 °C. Rata-rata tersebut lebih tinggi daripada rata-rata UISST keseluruhan pada Tabel 4.9 sebesar -0,140 °C karena hanya observasi positif yang digunakan dalam klasifikasi. Nilai Q1 sebesar 0,185 °C dan Q3 sebesar 0,800 °C digunakan sebagai batas kelas intensitas. Distribusi setiap kelas intensitas disajikan pada Gambar 4.13.



Gambar 4.13 Barplot Persentase Kelas *Upwelling Intensity*


Berdasarkan Gambar 4.13, dari total 9.372.243 observasi *upwelling valid* sebagaimana tercantum pada Tabel 4.13. Observasi tersebut tersebar pada kelas *weak upwelling* sebesar 16,78%, *intermediate upwelling* sebesar 15,95%, dan

strong upwelling sebesar 10,17%. Sementara itu, kelas *non-upwelling* memiliki proporsi terbesar, yaitu 57,11%. Hasil ini menunjukkan bahwa kejadian *upwelling* di WPP-NRI 572 lebih banyak berada pada intensitas lemah hingga menengah, sedangkan intensitas kuat memiliki proporsi paling kecil.

4.6 Analisis Intensitas *Upwelling*

4.6.1 Sebaran Spasial Akumulatif *Upwelling Valid*

Sebaran spasial akumulatif *upwelling* valid digunakan untuk mengidentifikasi lokasi yang paling sering mengalami indikasi *upwelling* selama periode 2014–2024. Nilai pada setiap *grid* menunjukkan jumlah kejadian *upwelling* valid sepanjang periode pengamatan. Warna yang semakin pekat menunjukkan frekuensi kejadian yang semakin tinggi. Hasil sebaran spasial akumulatif *upwelling* valid disajikan pada Gambar 4.14.




Gambar 4.14 Sebaran Spasial Akumulatif *Upwelling* Valid Tahun 2014-2024

Berdasarkan Gambar 4.14, kejadian *upwelling* valid tersebar di sebagian besar wilayah WPP-NRI 572, tetapi frekuensinya tidak merata. Akumulasi kejadian yang tinggi terutama terlihat pada area *offshore* atau laut lepas di sebelah barat Sumatra, khususnya pada kisaran 92°BT–103°BT dan 8°LS–4°LU. Frekuensi yang relatif tinggi juga tampak pada bagian tengah hingga selatan wilayah kajian, terutama sekitar 96°BT–103°BT dan 8°LS–2°LS. Sebaliknya, akumulasi kejadian cenderung lebih rendah pada bagian timur yang lebih dekat dengan daratan serta

pada ujung utara dan tenggara wilayah penelitian. Pola tersebut menunjukkan bahwa indikasi *upwelling* selama 2014–2024 lebih sering terjadi di area laut lepas dibandingkan area yang berada lebih dekat dengan pesisir.

4.6.2 Variasi Temporal *Upwelling* Valid Bulanan dan Tahunan

Variasi temporal *upwelling* valid dianalisis berdasarkan jumlah kejadian pada setiap bulan dan tahun selama periode 2014–2024. Analisis ini bertujuan untuk mengidentifikasi periode dengan frekuensi kejadian *upwelling* tertinggi. Hasil akumulasi bulanan dan tahunan disajikan pada Gambar 4.15.



Gambar 4.15 Barplot *Upwelling* Valid Bulanan dan Tahunan

Berdasarkan Gambar 4.15, jumlah kejadian *upwelling* valid bulanan tertinggi terjadi pada September, yaitu sebanyak 875.519 kejadian. Secara umum, frekuensi kejadian relatif tinggi pada periode September–Desember, terutama pada September, November, dan Desember, meskipun terjadi penurunan pada Oktober. Pola tersebut menunjukkan bahwa akhir tahun merupakan periode dengan akumulasi kejadian *upwelling* yang relatif lebih tinggi. Pada skala tahunan, jumlah kejadian tertinggi tercatat pada 2019, yaitu sebanyak 986.401 kejadian. Secara umum, hasil ini menunjukkan bahwa variasi *upwelling* valid lebih tampak pada skala bulanan, sedangkan pada skala tahunan tidak menunjukkan pola peningkatan atau penurunan yang konsisten selama periode 2014–2024.

4.6.3 Karakteristik Klorofil-a dan SST Berdasarkan Kelas Intensitas *Upwelling*

Analisis karakteristik klorofil-a dan SST berdasarkan kelas intensitas *upwelling* dilakukan untuk melihat perbedaan kondisi oseanografi pada setiap kategori hasil *binning*. Melalui analisis ini, dapat diketahui bagaimana nilai minimum, rata-rata, dan maksimum SST serta klorofil-a berubah pada kelas *non-upwelling*, *weak upwelling*, *intermediate upwelling*, dan *strong upwelling*. Ringkasan karakteristik klorofil-a dan SST berdasarkan kelas intensitas *upwelling* disajikan pada Tabel 4.14.

Tabel 4.14 Karakteristik Klorofil-a dan SST Berdasarkan Kelas Intensitas *Upwelling*

Kelas	Label	Klorofil-a			SST		
		<i>Min</i>	<i>Mean</i>	<i>Max</i>	<i>Min</i>	<i>Mean</i>	<i>Max</i>
0	<i>Non-Upwelling</i>	0,0000	0,1603	2,8669	24,055	30,1665	37,445
1	<i>Weak Upwelling</i>	0,0010	0,1696	2,8669	24,155	29,5004	34,840
2	<i>Intermediate Upwelling</i>	0,0007	0,1930	2,8669	23,785	29,2911	34,585
3	<i>Strong Upwelling</i>	0,0003	0,2516	2,8669	19,525	28,9807	33,245


Berdasarkan Tabel 4.14, rata-rata klorofil-a meningkat seiring dengan bertambahnya intensitas *upwelling*, yaitu dari 0,1603 mg/m³ pada kelas *non-upwelling* menjadi 0,2516 mg/m³ pada kelas *strong upwelling*. Sebaliknya, rata-rata SST menurun dari 30,1665 °C menjadi 28,9807 °C. Pola tersebut menunjukkan bahwa kelas *upwelling* yang lebih kuat memiliki karakteristik konsentrasi klorofil-a yang lebih tinggi dan suhu permukaan laut yang lebih rendah.

Secara umum, peningkatan intensitas *upwelling* berkaitan dengan penurunan SST dan peningkatan konsentrasi klorofil-a. Kondisi ini mengindikasikan adanya pengangkatan massa air yang lebih dingin dan kaya nutrisi ke permukaan sehingga mendukung peningkatan produktivitas primer. Hasil tersebut sejalan dengan penelitian Utama dkk. (2024) dan Sari dkk. (2022), serta konsisten dengan pola hubungan negatif antara SST dan klorofil-a yang ditampilkan pada Gambar 4.7 (*scatterplot*).

4.6.4 Variasi Temporal Kelas Intensitas *Upwelling*

Variasi temporal kelas intensitas *upwelling* dianalisis dengan fokus pada kejadian *upwelling* yang telah teridentifikasi, sehingga kelas *non-upwelling* tidak

diperhitungkan dalam analisis ini. Pengelompokan dilakukan berdasarkan kelas *weak upwelling*, *intermediate upwelling*, dan *strong upwelling* untuk melihat distribusi jumlah kejadian pada masing-masing kelas berdasarkan bulan dan tahun. Analisis ini bertujuan untuk menggambarkan dominasi relatif antar kelas intensitas *upwelling* secara temporal, khususnya pada skala bulanan yang mencerminkan pola musiman. Hasil variasi temporal kelas intensitas *upwelling* bulanan dan tahunan disajikan pada Gambar 4.16.



Gambar 4.16 Barplot Intensitas Upwelling Bulanan dan Tahunan

Berdasarkan Gambar 4.16, pada skala bulanan kelas *weak upwelling* mencapai jumlah kejadian tertinggi pada Juni, sedangkan *intermediate upwelling* paling banyak terjadi pada Desember. Kelas *strong upwelling* mencapai jumlah tertinggi pada Maret dan September. Perbedaan waktu puncak tersebut menunjukkan bahwa setiap kelas intensitas memiliki variasi bulanan yang berbeda dan tidak selalu meningkat secara bersamaan. Pada skala tahunan, kejadian *weak upwelling* tertinggi tercatat pada 2015. Sementara itu, kelas *intermediate upwelling* dan *strong upwelling* sama-sama mencapai jumlah tertinggi pada 2019. Secara umum, kelas *weak upwelling* dan *intermediate upwelling* memiliki jumlah kejadian yang lebih tinggi dibandingkan *strong upwelling*. Hasil ini menunjukkan bahwa variasi intensitas *upwelling* lebih terlihat pada skala bulanan, sedangkan pada skala

tahunan ketiga kelas tetap muncul secara konsisten tanpa menunjukkan pola peningkatan atau penurunan yang seragam selama periode 2014–2024.

4.7 *Preprocessing Lanjutan*

Setelah analisis intensitas *upwelling* dilakukan, tahap berikutnya adalah *preprocessing* lanjutan untuk menyiapkan data klorofil-a sebelum masuk ke proses *training* model ConvLSTM. Tahap ini bertujuan agar data memiliki bentuk spasial yang lebih efisien, skala nilai yang sesuai, serta struktur input yang konsisten untuk kebutuhan pemodelan. *Preprocessing* lanjutan dalam penelitian ini meliputi *bounding box cutting*, *data scaling*, integrasi *mask* spasial, dan pembentukan *sequence data*.

4.7.1 *Bounding Box Cutting*

Tahap *bounding box cutting* dilakukan untuk memotong area spasial yang tidak diperlukan dalam proses pemodelan. Pemotongan ini dilakukan berdasarkan batas terluar wilayah WPP-NRI 572, sehingga area di luar cakupan valid dapat dikurangi tanpa mengubah wilayah utama analisis. Dengan cara ini, ukuran data spasial menjadi lebih ringkas dan proses *training* ConvLSTM dapat dilakukan dengan lebih efisien karena model tidak perlu memproses *pixel* kosong atau area luar WPP-NRI 572 yang tidak digunakan. Perbandingan dimensi data sebelum dan sesudah proses *bounding box cutting* disajikan pada Tabel 4.15.

Tabel 4.15 Perbandingan Dimensi Data Sebelum dan Sesudah *Bounding Box Cutting*

Bentuk Data	Dimensi Spasial
Bentuk asli	408×432
Bentuk <i>cropped</i>	367×346


Berdasarkan Tabel 4.15, dimensi spasial data mengalami pengurangan dari 408×432 menjadi 367×346 setelah proses *bounding box cutting*. Pengurangan dimensi ini menunjukkan bahwa sebagian area di luar batas terluar WPP-NRI 572 berhasil dipotong, sehingga data yang digunakan untuk pemodelan menjadi lebih padat. Tahap ini penting karena ConvLSTM memproses data dalam bentuk citra spasio-temporal, sehingga ukuran grid yang lebih kecil dapat membantu mengurangi beban komputasi dan mempercepat proses *training* tanpa menghilangkan area valid utama di dalam WPP-NRI 572.

4.7.2 Normalisasi Data

Tahap *data scaling* dilakukan hanya pada variabel klorofil-a karena variabel ini digunakan sebagai input utama dalam pemodelan ConvLSTM. Pada tahap ini, nilai klorofil-a yang telah melalui proses *outlier handling* dinormalisasi menggunakan metode *Min-Max Scaling*, sebagaimana telah dijelaskan pada subbab 3.4.10 dan dirumuskan pada Persamaan (2.5). Proses ini bertujuan untuk mengubah rentang nilai klorofil-a ke dalam skala yang lebih seragam agar lebih sesuai untuk proses *training* model. Dengan skala data yang lebih terkendali, model dapat mempelajari pola spasial dan temporal klorofil-a secara lebih stabil tanpa dipengaruhi oleh perbedaan rentang nilai yang terlalu besar.

4.7.3 Penanganan Area *Non-Valid* pada Input Model ConvLSTM

Setelah proses *bounding box cutting* dan *data scaling* dilakukan, area di luar batas WPP-NRI 572 masih memiliki nilai *NaN* karena tidak termasuk dalam wilayah analisis. Nilai *NaN* tersebut perlu ditangani sebelum data masuk ke model ConvLSTM, karena model tidak dapat memproses input yang mengandung nilai kosong. Oleh karena itu, nilai *NaN* pada area *non-valid* di luar WPP-NRI 572 diisi dengan nilai 0. Dengan cara ini, struktur spasial data tetap utuh dan dapat diproses oleh ConvLSTM, sementara area valid WPP-NRI 572 tetap mempertahankan nilai klorofil-a hasil *scaling*. Contoh sampel data setelah penanganan area *non-valid* ditunjukkan pada Gambar 4.17.



Gambar 4.17 Sampel Data Training setelah Penanganan Area *Non-Valid*

4.8 Pembentukan Sequence Data

Tahap pembentukan *sequence data* dilakukan untuk menyusun data klorofil-a menjadi pasangan input dan target yang sesuai dengan kebutuhan model ConvLSTM. Berdasarkan konfigurasi model awal pada Tabel 3.3, panjang *timestep* yang digunakan adalah 3, sehingga model menerima tiga periode pengamatan

sebelumnya sebagai input untuk memprediksi satu periode berikutnya. Setelah proses ini dilakukan, diperoleh bentuk data yang tertera pada Tabel 4.16.

Tabel 4.16 Bentuk *Data Sequence*

Variabel	Dimensi	Bentuk Data	Keterangan
X_seq	5D	(502, 3, 367, 346, 1)	Input model berupa urutan 3 waktu sebelumnya.
y_seq	4D	(502, 367, 346, 1)	Target prediksi pada waktu berikutnya.

Pada Tabel 4.16, terlihat bahwa nilai 502 menunjukkan jumlah pasangan *sequence* yang terbentuk dari total 505 periode waktu setelah dikurangi tiga periode awal sebagai input. Pada *X_seq*, angka 3 menunjukkan panjang urutan waktu yang digunakan model, 367×346 menunjukkan dimensi spasial hasil *bounding box cutting*, dan angka 1 menunjukkan jumlah *channel* klorofil-a. Sementara itu, *y_seq* merepresentasikan peta klorofil-a pada periode berikutnya yang menjadi target prediksi model. Dengan bentuk data tersebut, ConvLSTM dapat mempelajari perubahan spasial dan temporal klorofil-a secara berurutan sebelum digunakan dalam proses *training*.

4.9 Data Splitting

Tahap *data splitting* dilakukan setelah data klorofil-a dibentuk menjadi *sequence data*. Metode pembagian data yang digunakan adalah *time-ordered splitting*, sebagaimana telah dijelaskan pada subbab 3.4.12, yaitu pembagian data berdasarkan urutan waktu tanpa melakukan pengacakan. Pendekatan ini digunakan agar struktur temporal data tetap terjaga dan tidak terjadi *data leakage* antara data latih, data evaluasi, dan data uji. Hasil pembagian data disajikan pada Tabel 4.17.

Tabel 4.17 Hasil *Data Splitting*

Data	Jumlah Sequence	Bentuk X	Bentuk y
Train	455	(455, 3, 367, 346, 1)	(455, 367, 346, 1)
Evaluation	23	(23, 3, 367, 346, 1)	(23, 367, 346, 1)
Test	23	(23, 3, 367, 346, 1)	(23, 367, 346, 1)


Berdasarkan Tabel 4.17, total data yang terbentuk setelah proses pembentukan *sequence* adalah 502 pasangan input dan target. Dari jumlah tersebut, 455 *sequence* digunakan sebagai data latih, 23 *sequence* digunakan sebagai data evaluasi, dan 23 *sequence* digunakan sebagai data uji. Bentuk *X_train*, *X_eval*, dan *X_test* tetap mempertahankan struktur input 5D, yaitu jumlah *sequence*, panjang

timestep sebesar 3, dimensi spasial 367×346 , dan satu *channel* klorofil-a. Sementara itu, bentuk y_{train} , y_{eval} , dan y_{test} berupa target 4D yang merepresentasikan peta klorofil-a pada periode berikutnya. Hasil ini menunjukkan bahwa pembagian data telah mempertahankan format spasio-temporal yang dibutuhkan oleh ConvLSTM.

4.10 Eksperimen Konfigurasi Awal ConvLSTM

4.10.1 Model *Baseline* ConvLSTM

Model *baseline* ConvLSTM digunakan sebagai model awal sebelum dilakukan percobaan variasi *timestep*, penambahan *mask* spasial, dan *hyperparameter tuning*. Konfigurasi model *baseline* mengacu pada Tabel 3.4 dengan data input yang digunakan mengikuti hasil *data splitting* pada Tabel 4.17. Hasil pelatihan model *baseline* berdasarkan kurva *loss* dan MAE ditunjukkan pada Gambar 4.18.



Gambar 4.18 Kurva *Training* dan *Validation Loss* serta MAE Model *Baseline* ConvLSTM

Berdasarkan Gambar 4.18, nilai *training loss* dan *validation loss* mengalami penurunan tajam pada *epoch* awal, kemudian cenderung stabil pada nilai yang

rendah setelah beberapa epoch, dengan pola yang sama juga terlihat pada grafik MAE di mana *training MAE* dan *validation MAE* turun cukup cepat pada awal pelatihan lalu bergerak relatif stabil hingga akhir *epoch*, serta selisih antara kurva *training* dan *validation* tidak terlihat terlalu jauh setelah model memasuki fase stabil sehingga model *baseline* dapat dikatakan mampu mempelajari pola dasar data tanpa menunjukkan perbedaan galat yang besar antara data latih dan data evaluasi, meskipun demikian kurva validasi masih menunjukkan beberapa fluktuasi kecil pada sejumlah *epoch* terutama pada grafik MAE yang mengindikasikan bahwa model *baseline* masih memiliki ruang perbaikan khususnya dalam menentukan konfigurasi input yang lebih sesuai dengan karakteristik data spasio-temporal klorofil-a.

Setelah proses pelatihan dianalisis melalui kurva *loss* dan MAE, evaluasi model *baseline* dilakukan untuk mengetahui performa prediksi pada data uji. Evaluasi ini dihitung pada dua cakupan area, yaitu seluruh grid (*all grid*) dan area valid di dalam WPP-NRI 572 (*inside WPP*). Pemisahan evaluasi ini dilakukan karena area di luar WPP-NRI 572 memiliki nilai 0 setelah proses penanganan area non-valid, sehingga evaluasi pada *inside WPP* diperlukan untuk melihat performa model secara lebih sesuai dengan wilayah analisis utama. Hasil evaluasi model *baseline* disajikan pada Tabel 4.18.

Tabel 4.18 Hasil Evaluasi Model *Baseline* ConvLSTM

Area	Jumlah Data	MAE	RMSE	R ²	Korelasi
<i>All grid</i>	2.920.586	0,008731	0,019499	0,997012	0,998551
<i>Inside WPP</i>	1.013.242	0,023325	0,032748	0,655592	0,818440


Berdasarkan Tabel 4.18, evaluasi pada area *all grid* menunjukkan nilai MAE sebesar 0,008731, RMSE sebesar 0,019499, R² sebesar 99,85%, dan korelasi sebesar 99,85%. Nilai tersebut menunjukkan bahwa secara keseluruhan model mampu menghasilkan prediksi dengan galat rendah dan hubungan yang sangat kuat terhadap data aktual. Namun, hasil ini perlu dibaca secara hati-hati karena area *all grid* mencakup area non-valid di luar WPP-NRI 572 yang telah diisi dengan nilai 0.

Evaluasi pada area *inside WPP*, nilai MAE meningkat menjadi 0,023325 dan RMSE menjadi 0,032748, sedangkan R² menurun menjadi 65,55% dengan

korelasi sebesar 81,84%. Hasil ini menunjukkan bahwa performa model pada area valid WPP-NRI 572 lebih rendah dibandingkan evaluasi *all grid*, tetapi masih menunjukkan hubungan prediksi yang cukup baik terhadap data aktual. Perbedaan ini mengindikasikan bahwa evaluasi *inside WPP* lebih representatif untuk menilai kemampuan model dalam memprediksi klorofil-a pada wilayah analisis utama. Oleh karena itu, hasil *baseline* ini digunakan sebagai acuan dasar untuk percobaan berikutnya.

4.10.2 Percobaan Variasi *Timestep*

Percobaan variasi *timestep* dilakukan untuk mengetahui panjang urutan waktu yang paling sesuai dalam memodelkan perubahan pola spasio-temporal klorofil-a. Pada percobaan ini, bagian yang diubah hanya panjang *timestep* pada proses pembentukan *sequence data*, sedangkan konfigurasi arsitektur model tetap mengikuti Tabel 3.3. Nilai *timestep* yang diuji dipilih berdasarkan hasil pengamatan pola autokorelasi melalui plot ACF dan PACF yang ditunjukkan pada Gambar 4.19.



Gambar 4.19 Plot ACF dan PACF Klorofil-a

Berdasarkan Gambar 4.19, plot ACF menunjukkan bahwa nilai autokorelasi klorofil-a masih tinggi pada beberapa *lag* awal, kemudian menurun secara bertahap hingga mendekati nol setelah sekitar *lag* 8–10. Pola ini menunjukkan bahwa data klorofil-a masih memiliki keterkaitan temporal pada periode-periode awal, sehingga informasi dari waktu sebelumnya relevan untuk digunakan sebagai input model. Sementara itu, plot PACF memperlihatkan pengaruh parsial yang paling kuat pada *lag* awal, terutama *lag* 1, sedangkan *lag* setelahnya cenderung berada di sekitar nol dengan beberapa fluktuasi kecil. Berdasarkan pola tersebut, percobaan variasi *timestep* dilakukan pada nilai 2, 3, 4, 6, dan 8 untuk membandingkan kemampuan model dalam menangkap konteks temporal jangka pendek hingga menengah. Pemilihan batas maksimum *timestep* 8 juga mempertimbangkan

keterbatasan komputasi, karena penggunaan urutan waktu yang lebih panjang meningkatkan ukuran input dan berisiko menyebabkan *out of memory*. Berikut hasil evaluasi setiap variasi *timestep* disajikan pada Tabel 4.19.

Tabel 4.19 Hasil Evaluasi Percobaan Variasi *Timestep*


Time	Area	MAE	RMSE	R ²	Korelasi
Time 2	All Grid	0,010624	0,02013	0,996815	0,998507
	Inside WPP	0,024711	0,033438	0,640913	0,813775
Time 3	All Grid	0,008731	0,019499	0,997012	0,998551
	Inside WPP	0,023325	0,032748	0,655592	0,81844
Time 4	All Grid	0,008808	0,019796	0,99692	0,998531
	Inside WPP	0,023677	0,033181	0,646407	0,817932
Time 6	All Grid	0,014982	0,02252	0,996014	0,998402
	Inside WPP	0,025549	0,035331	0,599108	0,813026
Time 8	All Grid	0,012069	0,021831	0,996255	0,998299
	Inside WPP	0,024923	0,035135	0,603537	0,802369

Berdasarkan Tabel 4.19, variasi *timestep* 3 memberikan performa terbaik dibandingkan variasi lainnya. Pada area *all grid*, *timestep* 3 menghasilkan MAE sebesar 0,008731, RMSE sebesar 0,019499, R² sebesar 99,7%, dan korelasi sebesar 99,85%. Nilai ini menunjukkan performa terbaik pada seluruh metrik evaluasi dibandingkan *timestep* 2, 4, 6, dan 8. Hasil yang sama juga terlihat pada area *inside WPP*, di mana *timestep* 3 menghasilkan MAE terendah sebesar 0,023325, RMSE terendah sebesar 0,032748, R² tertinggi sebesar 65,55%, dan korelasi tertinggi sebesar 81,84%.

Jika dibandingkan dengan *timestep* 2, penggunaan *timestep* 3 memberikan tambahan konteks temporal yang lebih baik sehingga model mampu menangkap perubahan klorofil-a dengan lebih stabil. Sementara itu, peningkatan *timestep* menjadi 4, 6, dan 8 tidak menghasilkan perbaikan performa. Bahkan, pada *timestep* 6 dan 8, nilai RMSE meningkat dan R² pada area *inside WPP* menurun cukup jelas. Hal ini menunjukkan bahwa penambahan urutan waktu yang terlalu panjang tidak selalu meningkatkan performa model, kemungkinan karena informasi temporal yang ditambahkan menjadi kurang relevan atau menambah kompleksitas input. Dengan demikian, *timestep* 3 dipilih sebagai konfigurasi temporal terbaik untuk digunakan pada percobaan berikutnya.

4.10.3 Integrasi *Mask* Spasial sebagai *Channel* Tambahan

Integrasi *mask* spasial dilakukan dengan menambahkan satu *channel* tambahan pada input model ConvLSTM. *Channel* tambahan ini berisi nilai biner, yaitu 1 untuk area valid di dalam WPP-NRI 572 dan 0 untuk area non-valid di luar WPP-NRI 572. Dengan penambahan *mask* spasial, bentuk input X_{train} berubah dari (455, 3, 367, 346, 1) menjadi (455, 3, 367, 346, 2). Visualisasi kedua *channel* masukan ditampilkan pada Gambar 4.20.



Gambar 4.20 Visualisasi *Channel* Klorofil-a dan *Channel Mask* Spasial WPP-NRI 572

Berdasarkan Gambar 4.20, *channel* pertama merepresentasikan distribusi spasial klorofil-a pada setiap *grid*, sedangkan *channel* kedua memberikan informasi mengenai batas area valid WPP-NRI 572. Informasi tambahan tersebut membantu model membedakan wilayah yang digunakan dalam pembelajaran dengan area di luar wilayah kajian. Hasil evaluasi model pada *testing set* setelah integrasi *mask* spasial disajikan pada Tabel 4.20.

Tabel 4.20 Hasil Evaluasi Variasi *Timestep* dengan *Mask* Spasial Pada *Testing Set*

Time	Area	MAE	RMSE	R ²	Korelasi
Time 2 (Mask)	All Grid	0,008563	0,019186	0,997107	0,998586
	Inside WPP	0,023026	0,032325	0,664413	0,821198
Time 3 (Mask)	All Grid	0,011534	0,019273	0,997081	0,99861
	Inside WPP	0,022973	0,031717	0,676935	0,824106
Time 4 (Mask)	All Grid	0,012647	0,023057	0,995822	0,998551
	Inside WPP	0,028904	0,038518	0,523517	0,820241
Time 6 (Mask)	All Grid	0,010872	0,020966	0,996545	0,998533
	Inside WPP	0,025041	0,034757	0,612031	0,818604
Time 8 (Mask)	All Grid	0,013046	0,021213	0,996463	0,998512
	Inside WPP	0,024251	0,034191	0,624558	0,816265

Berdasarkan Tabel 4.20, performa model pada area *all grid* menunjukkan nilai yang sangat tinggi untuk seluruh variasi *timestep*, dengan nilai R^2 mendekati 1 dan korelasi di atas 0,998. Hal ini menunjukkan bahwa model mampu merepresentasikan pola data secara sangat baik pada keseluruhan grid. Namun, evaluasi pada area *inside WPP* memberikan gambaran yang lebih realistis terhadap kemampuan model dalam memprediksi wilayah valid penelitian.

Pada area *inside WPP*, konfigurasi *timestep* 3 dengan *mask* spasial menghasilkan performa terbaik. Model ini memperoleh MAE sebesar 0,022973, RMSE sebesar 0,031717, R^2 sebesar 0,676935, dan korelasi sebesar 0,824106. Nilai tersebut menunjukkan bahwa *timestep* 3 tetap menjadi konfigurasi temporal paling sesuai setelah penambahan *mask* spasial. Jika dibandingkan dengan hasil tanpa *mask* pada Tabel 4.16, *timestep* 3 mengalami perbaikan pada seluruh metrik evaluasi area *inside WPP*, yaitu MAE menurun dari 0,023325 menjadi 0,022973, RMSE menurun dari 0,032748 menjadi 0,031717, R^2 meningkat dari 0,655592 menjadi 0,676935, dan korelasi meningkat dari 0,818440 menjadi 0,824106.

Secara umum, penambahan *mask* spasial memberikan perbaikan pada beberapa konfigurasi *timestep*, terutama *timestep* 2, 3, 6, dan 8 pada area *inside WPP*. Hal ini menunjukkan bahwa informasi area valid dan non-valid dapat membantu model membedakan wilayah yang benar-benar menjadi domain analisis dari area luar WPP-NRI 572. Namun, peningkatan tersebut tidak terjadi secara seragam pada seluruh variasi, karena pada *timestep* 4 performa model justru menurun setelah penambahan *mask*. Dengan demikian, pengaruh *mask* spasial tetap bergantung pada panjang urutan temporal yang digunakan. Berdasarkan hasil evaluasi, konfigurasi *timestep* dan penggunaan *mask* spasial, *timestep* 3 dengan penggunaan *mask* spasial dipilih sebagai konfigurasi input terbaik untuk tahap analisis berikutnya.

4.11 *Hyperparameter Tuning*

Tahap *hyperparameter tuning* dilakukan setelah percobaan pada konfigurasi *baseline* model, yaitu menggunakan *timestep* 3 dengan *mask* spasial sebagai *channel* tambahan. Pada tahap ini, proses pencarian kombinasi *hyperparameter* mengacu pada ruang pencarian yang telah dijelaskan pada Tabel 3.5 dengan

penggunaan *batch size* ditetapkan tetap sebesar 2. Penggunaan nilai tetap ini karena keterbatasan perangkat komputasi dimana berisiko mengalami *out of memory* (OMM). Selain itu, jumlah *layer* ConvLSTM juga ditetapkan tetap sebanyak tiga *layers*. Keputusan ini didasarkan pada hasil pelatihan model *baseline* pada Gambar 4.19, yang menunjukkan bahwa model dengan tiga lapisan masih mampu mengikuti pola data dengan baik tanpa indikasi *overfitting* maupun *underfitting* yang jelas.

4.11.1 Ringkasan Hasil Trial dan Pemilihan Konfigurasi Terbaik

Ringkasan hasil *trial* digunakan untuk melihat kombinasi *hyperparameter* yang memberikan performa terbaik selama proses *tuning*. Pemilihan konfigurasi terbaik dilakukan berdasarkan nilai *validation loss* terendah, karena nilai tersebut merepresentasikan tingkat kesalahan model pada data evaluasi selama proses pelatihan. Lima *trial* dengan performa terbaik disajikan pada Tabel 4.21.

Tabel 4.21 Lima *Trial* Terbaik Hasil *Hyperparameter Tuning*

<i>Trial</i>	<i>Epoch Terbaik</i>	Train		Validation		<i>Kernel Size</i>
		<i>Loss</i>	<i>MAE</i>	<i>Loss</i>	<i>MAE</i>	
24	21	0,0003749	0,0100741	0,0002726	0,0086408	5
27	17	0,0004397	0,0102224	0,0002910	0,0084739	5
2	20	0,0004539	0,0103737	0,0002929	0,0080227	3
30	11	0,0004742	0,0115731	0,0002958	0,0099510	5
39	19	0,0004323	0,0101449	0,0002965	0,0080714	5


<i>Trial</i>	<i>Optimizer</i>	<i>Learning Rate</i>	Filters		
			<i>L1</i>	<i>L2</i>	<i>L3</i>
24	Nadam	0,0004879	48	48	8
27	Nadam	0,0003573	48	48	8
2	Nadam	0,0006433	64	48	16
30	Nadam	0,0003143	48	48	8
39	Nadam	0,0003355	48	16	8

Berdasarkan Tabel 4.21, *trial* 24 menjadi konfigurasi terbaik karena menghasilkan *validation loss* terendah, yaitu 0,0002726, dengan *validation MAE* sebesar 0,0086408. Konfigurasi pada *trial* ini menggunakan *kernel size* 5, *optimizer* Nadam, *learning rate* 0,0004879, serta jumlah *filter* berturut-turut 48, 48, dan 8 pada tiga lapisan ConvLSTM. Meskipun *trial* 2 menghasilkan *validation MAE* yang lebih rendah, yaitu 0,0080227, nilai *validation loss*-nya masih lebih tinggi dibandingkan *trial* 24. Oleh karena itu, *trial* 24 dipilih sebagai konfigurasi terbaik karena kriteria utama pemilihan model didasarkan pada *validation loss*.

Secara umum, lima *trial* terbaik menunjukkan bahwa *optimizer* Nadam mendominasi konfigurasi dengan performa terbaik. Selain itu, sebagian besar *trial* terbaik menggunakan *kernel size* 5 dan kombinasi *filter* yang relatif seimbang pada dua lapisan awal, khususnya 48 dan 48. Hasil ini menunjukkan bahwa model cenderung memperoleh performa validasi yang lebih baik ketika menggunakan ukuran *kernel* yang lebih besar dan jumlah *filter* menengah, sehingga model tetap mampu menangkap pola spasial tanpa meningkatkan kompleksitas secara berlebihan. Konfigurasi terbaik dari tahap ini selanjutnya digunakan sebagai dasar untuk pelatihan dan evaluasi model ConvLSTM terbaik.

4.11.2 Dinamika *Training* pada Proses *Tuning*

Dinamika *training* pada proses *tuning* dianalisis untuk melihat perbandingan antara *train loss* dan *validation loss* pada setiap *trial*. Analisis ini bertujuan untuk mengetahui stabilitas performa model selama proses pencarian *hyperparameter*, sekaligus melihat apakah terdapat perbedaan galat yang besar antara data latih dan data validasi. Perbandingan *train loss* dan *validation loss* pada setiap *trial* ditunjukkan pada Gambar 4.21.



Gambar 4.21 Perbandingan *Train Loss* dan *Validation Loss* pada Setiap *Trial*

Berdasarkan Gambar 4.21, nilai *train loss* dan *validation loss* pada sebagian besar *trial* berada pada rentang yang relatif rendah dan memiliki pola perubahan yang cukup sejalan. Hal ini menunjukkan bahwa sebagian besar kombinasi *hyperparameter* yang diuji masih mampu menghasilkan proses pelatihan yang stabil. *Trial* terbaik ditunjukkan oleh garis vertikal pada *trial* 24, dengan nilai *validation loss* terendah dibandingkan *trial* lainnya. Pada *trial* tersebut, nilai *validation loss* lebih rendah dibandingkan *train loss*, yang menunjukkan bahwa model mampu memberikan performa yang baik pada data validasi.

Meskipun mayoritas *trial* mencatatkan nilai *loss* yang rendah, terdapat anomali berupa lonjakan *loss* pada beberapa percobaan, khususnya pada *trial* ke-47 dibagian akhir pelatihan. Fenomena ini mengindikasikan bahwa penggunaan kombinasi *hyperparameter* tertentu dapat memicu ketidakstabilan dalam proses pelatihan model. Dengan demikian, pemilihan *trial* 24 sebagai konfigurasi terbaik didukung oleh nilai *validation loss* yang paling rendah serta pola galat yang masih berada pada rentang stabil dibandingkan sebagian besar *trial* lainnya.

4.11.3 Perbandingan Pengaruh *Optimizer*

Perbandingan pengaruh *optimizer* dilakukan untuk melihat perbedaan performa model berdasarkan jenis algoritma optimasi yang digunakan selama proses *hyperparameter tuning*. Pada tahap ini, tiga *optimizer* yang dibandingkan adalah Adam, Adamax, dan Nadam. Ringkasan hasil perbandingan *optimizer* dari 50 *trial* disajikan pada Tabel 4.22.

Tabel 4.22 Perbandingan Pengaruh *Optimizer* pada Proses *Hyperparameter Tuning*

<i>Optimizer</i>	Jumlah <i>Trial</i>	Rata-rata <i>Val Loss</i>	<i>Train Loss</i> Terbaik	<i>Val Loss</i> Terbaik	<i>Train MAE</i> Terbaik	<i>Val MAE</i> Terbaik
Nadam	34	0,00035204	0,00037490	0,00027257	0,01007412	0,00864081
Adam	9	0,0004033	0,0004709	0,00030211	0,01167973	0,01020724
Adamax	7	0,0005642	0,0004774	0,00034259	0,01000173	0,00889372

Berdasarkan Tabel 4.22, *optimizer* Nadam menunjukkan performa terbaik dibandingkan Adam dan Adamax. Hal ini terlihat dari rata-rata *validation loss* Nadam sebesar 0,000352036, yang lebih rendah dibandingkan Adam sebesar 0,000403226 dan Adamax sebesar 0,000564190. Selain itu, Nadam juga menghasilkan *validation loss* terbaik paling rendah, yaitu 0,000272571. Nilai ini menunjukkan bahwa konfigurasi terbaik yang menggunakan Nadam mampu memberikan galat validasi paling kecil selama proses *hyperparameter tuning*.

Dari sisi jumlah *trial*, Nadam memiliki jumlah percobaan paling banyak, yaitu 34 *trial*, sedangkan Adam hanya 9 *trial* dan Adamax 7 *trial*. Perbedaan jumlah *trial* ini dapat terjadi karena proses pencarian *hyperparameter* cenderung mengeksplorasi area konfigurasi yang memberikan hasil lebih baik. Meskipun Nadam diuji lebih banyak, rata-rata *validation loss* yang dihasilkan tetap paling rendah, sehingga performanya tidak hanya unggul pada satu percobaan terbaik,


tetapi juga relatif stabil secara keseluruhan. Sementara itu, Adam berada pada posisi kedua dengan rata-rata *validation loss* yang masih cukup rendah, sedangkan Adamax menunjukkan rata-rata *validation loss* paling tinggi.

4.12 Evaluasi *Best Model Hasil Tuning*

Evaluasi *best model* dilakukan terhadap model ConvLSTM terbaik yang diperoleh dari proses *hyperparameter tuning*, yaitu model pada *trial* 24. Evaluasi ini bertujuan untuk menilai kestabilan proses pelatihan dan kemampuan model dalam menghasilkan prediksi klorofil-a setelah menggunakan konfigurasi *hyperparameter* terbaik.

4.12.1 Kurva *Training Model Terbaik*

Kurva *training* model terbaik digunakan untuk melihat pola perubahan *loss* dan MAE selama proses pelatihan pada *trial* 24. Bagian ini bukan lagi merupakan proses pemilihan *hyperparameter*, melainkan digunakan untuk memastikan bahwa model terpilih memiliki proses pelatihan yang stabil dan tidak menunjukkan indikasi *overfitting* atau *underfitting* yang jelas. Kurva *training loss*, *validation loss*, *training MAE*, dan *validation MAE* model terbaik disajikan pada Gambar 4.22.



Gambar 4.22 Kurva *Training* dan *Validation Loss* serta MAE pada Model Terbaik pada *Tuning*

Berdasarkan Gambar 4.22, kurva *training loss* dan *validation loss* pada *trial* 24 menunjukkan penurunan yang cepat pada *epoch* awal, kemudian bergerak stabil pada nilai yang rendah setelah beberapa *epoch*. Pada grafik *loss*, model terbaik mencapai *epoch* terbaik pada *epoch* ke-21, sedangkan pada grafik MAE, nilai *validation MAE* terbaik berada pada *epoch* ke-25. Pola ini menunjukkan bahwa model mampu menyesuaikan parameter secara efektif pada awal pelatihan dan tetap mempertahankan nilai galat yang rendah hingga akhir proses pelatihan. Meskipun terdapat lonjakan *validation loss* dan *validation MAE* pada *epoch* awal, kondisi tersebut hanya terjadi pada fase awal pelatihan dan tidak berlanjut pada *epoch* berikutnya. Lalu, jika dibandingkan dengan model *baseline* pada Gambar 4.19, model terbaik menunjukkan pola pelatihan yang relatif serupa, yaitu nilai *loss* dan MAE turun tajam pada awal *epoch* lalu stabil pada nilai rendah.

4.12.2 Evaluasi Model Terbaik pada Data *Testing*

Evaluasi model terbaik dilakukan menggunakan data *testing* untuk mengetahui kemampuan generalisasi model ConvLSTM pada data yang tidak digunakan selama proses *training* maupun *hyperparameter tuning*. Model yang dievaluasi merupakan model terbaik dari *trial* 24, yang dipilih berdasarkan nilai *validation loss* terendah pada proses *tuning*. Evaluasi dilakukan pada dua cakupan area, yaitu *all grid* dan *inside WPP*, agar performa model dapat diamati baik pada keseluruhan domain data maupun pada wilayah valid WPP-NRI 572. Hasil evaluasi model terbaik pada data *testing* disajikan pada Tabel 4.23

Tabel 4.23 Hasil Evaluasi Model Terbaik pada Data *Testing*

Area	MAE	RMSE	R ²	Korelasi
<i>All grid</i>	0,009779	0,019411	0,997039	0,998599
<i>Inside WPP</i>	0,023164	0,032464	0,661530	0,823477

Berdasarkan Tabel 4.23, evaluasi pada area *all grid* menunjukkan nilai MAE sebesar 0,009779, RMSE sebesar 0,019411, R² sebesar 99,7%, dan korelasi sebesar 99,85%. Nilai R² dan korelasi yang tinggi menunjukkan bahwa model terbaik mampu mengikuti pola umum data pada keseluruhan grid dengan baik. Namun, seperti pada evaluasi sebelumnya, hasil *all grid* perlu dibaca secara hati-hati karena masih mencakup area *non-valid* di luar WPP-NRI 572 yang telah diberi nilai 0.

Pada area *inside WPP*, model terbaik menghasilkan MAE sebesar 0,023164, RMSE sebesar 0,032464, R^2 sebesar 66,15%, dan korelasi sebesar 82,34%. Hasil ini menunjukkan bahwa performa model pada wilayah valid WPP-NRI 572 tetap berada pada tingkat yang cukup baik, meskipun lebih rendah dibandingkan evaluasi *all grid*. Jika dibandingkan dengan konfigurasi *baseline* terbaik sebelumnya pada Tabel 4.17, performa model terbaik hasil *tuning* tidak menunjukkan peningkatan yang konsisten pada data *testing*. Pada area *inside WPP*, *baseline timestep 3* dengan *mask* memiliki MAE sebesar 0,022973, RMSE sebesar 0,031717, R^2 sebesar 67,69%, dan korelasi sebesar 82,41%, sedangkan model hasil *tuning* memiliki MAE dan RMSE yang sedikit lebih tinggi serta R^2 dan korelasi yang sedikit lebih rendah.

Dengan demikian, model hasil *hyperparameter tuning* tetap menunjukkan performa prediksi yang stabil, tetapi pada data *testing* belum mampu melampaui konfigurasi *baseline* terbaik *timestep 3* dengan *mask* spasial pada area *inside WPP*. Kondisi ini menunjukkan bahwa konfigurasi terbaik berdasarkan *validation loss* tidak selalu menghasilkan performa paling tinggi pada data *testing*. Implikasi ini nantinya akan dibahas pada diskusi.

4.13 Forecasting


Tahap *forecasting* dilakukan setelah model terbaik berdasarkan evaluasi sebelumnya diperoleh, yaitu konfigurasi *baseline* dengan *timestep 3* dan *mask* spasial sebagai *channel* tambahan. Model tersebut kemudian dilakukan *refit* dengan menggunakan seluruh dataset historis agar informasi temporal yang tersedia dapat dimanfaatkan secara lebih lengkap sebelum proses prediksi. Setelah proses *refit*, model digunakan untuk memprediksi klorofil-a selama satu tahun ke depan sebanyak 46-*timestep* ke depan, sesuai dengan resolusi data komposit 8 harian. Hasil prediksi tersebut kemudian diringkas ke dalam statistik deskriptif untuk melihat karakteristik umum nilai klorofil-a hasil *forecasting*. Ringkasan statistik hasil prediksi disajikan pada Tabel 4.24.

Tabel 4.24 Statistik Deskriptif Hasil *Forecasting* Klorofil-a

Statistik	chlor_a (mg/m ³)
Rata-rata	0,032632
Std Deviasi	0,087488

Statistik	chlor_a (mg/m ³)
Min	0,000002
25% (Q1)	0,027753
Median	0,027899
75% (Q3)	0,031059
Max	22,862197
Range	22,862195


Berdasarkan Tabel 4.24, nilai rata-rata hasil *forecasting* klorofil-a sebesar 0,032632 dengan median sebesar 0,027899. Nilai Q1 sebesar 0,027753 dan Q3 sebesar 0,031059 menunjukkan bahwa sebagian besar hasil prediksi berada pada rentang yang relatif sempit. Namun, nilai maksimum mencapai 22,862197 sehingga *range* menjadi cukup besar. Kondisi ini menunjukkan bahwa secara umum hasil prediksi berada pada konsentrasi rendah, tetapi masih terdapat sebagian kecil nilai prediksi yang jauh lebih tinggi dibandingkan pusat distribusi data. Oleh karena itu, selain statistik deskriptif, pola hasil prediksi juga dianalisis melalui rata-rata bulanan dan sebaran spasial agar interpretasi tidak hanya bergantung pada nilai maksimum. Rata-rata prediksi klorofil-a bulanan ditunjukkan pada Gambar 4.23.



Gambar 4.23 *Linechart* Rata-rata Prediksi Klorofil-a Bulanan

Berdasarkan Gambar 4.23, rata-rata prediksi klorofil-a tertinggi terjadi pada awal periode prediksi, yaitu Januari 2025. Setelah itu, nilai rata-rata mengalami penurunan cukup jelas pada Februari 2025 dan kembali menurun pada Maret 2025. Mulai April hingga akhir periode prediksi, nilai rata-rata klorofil-a cenderung stabil pada kisaran yang rendah, yaitu sekitar 0,029-0,030. Pola ini menunjukkan bahwa model memprediksi adanya konsentrasi klorofil-a yang lebih tinggi pada awal periode prediksi, kemudian bergerak menuju kondisi yang lebih stabil pada bulan-

bulan berikutnya. Untuk melihat pola tersebut secara spasial, hasil prediksi bulanan divisualisasikan dalam bentuk peta sebaran pada Gambar 4.24.



Gambar 4.24 Sebaran Spasial Prediksi Klorofil-a Bulanan

Berdasarkan Gambar 4.24, sebaran spasial prediksi klorofil-a pada Januari 2025 menunjukkan nilai yang relatif lebih tinggi dan tersebar lebih luas dibandingkan bulan-bulan berikutnya. Pada bulan tersebut, konsentrasi klorofil-a yang lebih tinggi tampak muncul pada sebagian besar wilayah WPP-NRI 572, terutama di sepanjang area pesisir dan bagian tengah hingga selatan domain. Pola sebaran spasial yang jelas dan kontras antara wilayah dengan konsentrasi tinggi dan rendah terutama hanya terlihat pada bulan Januari, sedangkan pada bulan-bulan

berikutnya pola tersebut menjadi kurang tegas. Memasuki Februari dan Maret 2025, nilai prediksi mulai menurun dan sebarannya menjadi lebih terbatas. Pada April hingga Desember 2025, pola spasial terlihat relatif stabil dengan dominasi nilai rendah hingga sedang, sedangkan area dengan nilai lebih tinggi cenderung berada di sekitar wilayah pesisir, sekitar gugusan pulau, dan bagian tepi domain WPP-NRI 572.

Secara keseluruhan, hasil *forecasting* menunjukkan bahwa model mampu menghasilkan prediksi klorofil-a dengan pola temporal yang relatif stabil setelah bulan-bulan awal prediksi. Nilai rata-rata bulanan yang menurun setelah Januari 2025 menunjukkan bahwa model tidak mempertahankan nilai tinggi secara berlebihan sepanjang periode prediksi. Secara spasial, pola prediksi masih mempertahankan perbedaan antara area pesisir dan area lepas pantai, di mana nilai klorofil-a yang relatif lebih tinggi lebih sering muncul di sekitar wilayah pesisir dan tepi WPP-NRI 572, meskipun pola sebaran spasial yang terlihat jelas hanya dominan pada bulan Januari. Selain itu, dari hasil prediksi yang diperoleh, model menunjukkan indikasi performa yang baik untuk prediksi hingga 4 *timestep* ke depan. Oleh karena itu, untuk menjaga akurasi prediksi dalam jangka waktu yang lebih panjang, direkomendasikan untuk melakukan proses *refit* model secara berkala setiap satu bulan. Hasil ini dapat digunakan sebagai dasar untuk tahap berikutnya, yaitu integrasi dengan hasil intensitas *upwelling* dalam pemetaan *fishing ground* optimal.

4.14 Analisis Pemetaan *Fishing Ground* Optimal

Pemetaan *fishing ground* optimal pada penelitian ini disusun berdasarkan integrasi tiga kelompok hasil, yaitu sebaran bulanan klorofil-a dan SST, analisis intensitas *upwelling*, serta hasil *forecasting* klorofil-a. Dalam konteks penelitian ini, istilah *fishing ground* optimal dimaknai sebagai wilayah dan periode yang memiliki kondisi oseanografis paling mendukung berdasarkan parameter klorofil-a, SST, dan *upwelling*, bukan berdasarkan data tangkapan ikan secara langsung. Oleh karena itu, penentuan zona ini dilakukan dengan melihat irisan antara wilayah dengan konsentrasi klorofil-a relatif tinggi, SST relatif rendah, kejadian *upwelling* valid

yang tinggi, serta area yang masih menunjukkan potensi produktivitas pada hasil prediksi.

Berdasarkan hasil *heatmap* pada Gambar 4.9 dan Gambar 4.11, wilayah yang paling relevan untuk diarahkan sebagai *fishing ground potensial* berada pada bagian pesisir barat Sumatra bagian tengah hingga selatan dan sekitar Selat Sunda. Gambar 4.9 menunjukkan bahwa konsentrasi klorofil-a yang lebih tinggi cenderung muncul di wilayah pesisir, terutama di sepanjang sisi timur domain WPP-NRI 572 yang berdekatan dengan pantai barat Sumatra dan sekitar Selat Sunda. Secara temporal, peningkatan klorofil-a mulai tampak pada Juli–Agustus dan menjadi lebih luas pada September–November, terutama pada wilayah selatan hingga tengah WPP-NRI 572. Sementara itu, Gambar 4.11 menunjukkan bahwa SST yang lebih rendah mulai terlihat pada Juli dan semakin kuat pada Agustus–Oktober, khususnya di bagian selatan WPP-NRI 572. Kesesuaian antara peningkatan klorofil-a dan penurunan SST tersebut menunjukkan bahwa periode Juli–November, terutama September–November, merupakan fase historis yang paling kuat untuk mendukung identifikasi *fishing ground* potensial.

Hasil tersebut diperkuat oleh analisis intensitas *upwelling* pada subbab 4.6. Berdasarkan Gambar 4.14, akumulasi kejadian *upwelling* valid lebih tinggi di area *offshore* atau laut lepas di sebelah barat Sumatra, terutama pada kisaran 92°BT–103°BT dan 8°LS–4°LU. Frekuensi yang relatif tinggi juga terlihat pada bagian tengah hingga selatan wilayah kajian, khususnya sekitar 96°BT–103°BT dan 8°LS–2°LS. Secara spasial, wilayah tersebut beririsan dengan area yang pada *heatmap* menunjukkan peningkatan konsentrasi klorofil-a dan penurunan SST. Oleh karena itu, area *offshore* di bagian tengah hingga selatan WPP-NRI 572 dapat diprioritaskan sebagai zona *fishing ground* potensial karena menunjukkan kesesuaian antara produktivitas perairan, kondisi termal, dan frekuensi kejadian *upwelling* valid.

Secara temporal, hasil *upwelling* valid menunjukkan kesesuaian dengan pola pada *heatmap* klorofil-a. Berdasarkan Gambar 4.15, frekuensi kejadian *upwelling* valid relatif tinggi pada September–Desember, dengan jumlah tertinggi terjadi pada September sebanyak 875.519 kejadian. Sementara itu, Gambar 4.9

menunjukkan peningkatan konsentrasi klorofil-a yang lebih luas pada September–November. Kesesuaian periode tersebut menunjukkan bahwa September–November merupakan waktu yang paling potensial untuk identifikasi *fishing ground* karena ditandai oleh tingginya kejadian *upwelling*, peningkatan klorofil-a, dan penurunan SST. Pada skala tahunan, jumlah kejadian tertinggi tercatat pada 2019, tetapi tidak menunjukkan tren yang konsisten selama periode 2014–2024. Oleh karena itu, penentuan waktu potensial *fishing ground* lebih tepat didasarkan pada pola bulanan.

Hasil *forecasting* pada Subbab 4.13 memberikan dasar prediktif dalam pemetaan *fishing ground*. Berdasarkan Tabel 4.24, nilai prediksi klorofil-a cenderung berada pada rentang yang rendah dan relatif sempit, dengan rata-rata sebesar 0,032632 mg/m³ dan median sebesar 0,027899 mg/m³. Gambar 4.23 menunjukkan bahwa rata-rata klorofil-a tertinggi diprediksi terjadi pada Januari 2025, kemudian menurun pada Februari dan Maret, serta relatif stabil pada April–Desember 2025. Secara spasial, Gambar 4.24 memperlihatkan bahwa sebaran klorofil-a pada Januari 2025 lebih tinggi dan luas dibandingkan bulan-bulan berikutnya, terutama di wilayah pesisir serta bagian tengah hingga selatan WPP-NRI 572. Berdasarkan hasil tersebut, Januari 2025 dapat dipertimbangkan sebagai periode prospektif awal untuk *fishing ground*, khususnya di pesisir barat Sumatra bagian tengah–selatan dan sekitar Selat Sunda.

Berdasarkan integrasi seluruh hasil, zona *fishing ground* potensial di WPP-NRI 572 terkonsentrasi pada bagian tengah hingga selatan wilayah kajian. Area pesisir barat Sumatra bagian tengah–selatan dan sekitar Selat Sunda menunjukkan peningkatan klorofil-a serta penurunan SST berdasarkan Gambar 4.9 dan Gambar 4.11. Sementara itu, area *offshore* pada kisaran 96°BT–103°BT dan 8°LS–2°LS menunjukkan akumulasi kejadian *upwelling* valid yang relatif tinggi berdasarkan Gambar 4.14. Secara temporal, periode historis paling potensial terjadi pada September–November karena memperlihatkan kesesuaian antara peningkatan klorofil-a, penurunan SST, dan tingginya frekuensi *upwelling* valid. Berdasarkan hasil *forecasting*, Januari 2025 menjadi periode prediktif yang paling menonjol

karena memiliki rata-rata dan sebaran klorofil-a yang lebih tinggi dibandingkan bulan-bulan berikutnya.

Dengan demikian, penelitian ini menghasilkan dua penekanan utama. Secara historis, zona *fishing ground* potensial berada di bagian tengah hingga selatan WPP-NRI 572, mencakup area pesisir barat Sumatra, sekitar Selat Sunda, dan wilayah *offshore* di sebelah baratnya, dengan periode utama pada September–November. Secara prediktif, Januari 2025 menjadi periode awal yang perlu diperhatikan berdasarkan nilai klorofil-a hasil *forecasting*. Namun, karena prediksi hanya menggunakan klorofil-a dan belum melibatkan data tangkapan maupun keberadaan ikan, hasil pemetaan ini perlu dipahami sebagai zona potensial berbasis kondisi oseanografis. Akurasi pemetaan selanjutnya dapat diperkuat melalui pembaruan model secara berkala serta integrasi data perikanan aktual.

4.15 Diskusi

Secara keseluruhan, dinamika klorofil-a dan SST di WPP-NRI 572 berkaitan dengan kejadian *upwelling* serta dapat dimodelkan secara spasio-temporal menggunakan ConvLSTM. *Upwelling* valid lebih sering terakumulasi di area *offshore* sebelah barat Sumatra, terutama pada bagian tengah hingga selatan, dengan variasi yang lebih jelas secara bulanan. Peningkatan intensitas *upwelling* juga diikuti oleh kenaikan rata-rata klorofil-a dan penurunan rata-rata SST. Pada tahap pemodelan, konfigurasi *baseline* dengan *timestep* 3 dan *mask* spasial sebagai *channel* tambahan memberikan hasil terbaik sebagaimana ditunjukkan pada Tabel 4.20. Namun, masih terdapat beberapa keterbatasan, yaitu munculnya nilai ekstrem setelah rekonstruksi *missing value*, terbatasnya eksplorasi konfigurasi model, hasil *hyperparameter tuning* yang belum melampaui *baseline*, serta menurunnya kestabilan *forecasting* pada horizon yang lebih panjang.

Temuan pertama yang perlu diperhatikan adalah munculnya nilai ekstrem pada hasil rekonstruksi *missing value* klorofil-a menggunakan 3D-DINEOF. Berdasarkan Tabel 4.2, data asal klorofil-a memiliki rata-rata sebesar 0,216 mg/m³, median sebesar 0,117 mg/m³, dan nilai maksimum sebesar 85,862 mg/m³. Nilai maksimum yang jauh melampaui Q1 sebesar 0,086 mg/m³ dan Q3 sebesar 0,177 mg/m³ mengindikasikan adanya nilai ekstrem. Kondisi tersebut diperkuat oleh nilai

skewness sebesar 33,331 yang menunjukkan distribusi sangat menceng ke kanan. Hasil ini juga berbeda dengan kisaran klorofil-a sebesar 0,04–2 mg/m³ yang dilaporkan oleh Madriyanti (2025) pada wilayah WPP-NRI 572. Setelah rekonstruksi, sebagaimana ditunjukkan pada Tabel 4.8, rata-rata dan median klorofil-a relatif tetap, yaitu masing-masing sebesar 0,214 mg/m³ dan 0,119 mg/m³. Namun, nilai maksimum meningkat menjadi 1.212,850 mg/m³ dan *skewness* meningkat menjadi 296,860. Hasil tersebut menunjukkan bahwa proses rekonstruksi mampu mempertahankan kecenderungan pusat data, tetapi menghasilkan sejumlah nilai ekstrem yang semakin memperkuat kemencengan distribusi ke kanan. Kondisi ini diduga berkaitan dengan penggunaan dekomposisi berbasis *Singular Value Decomposition* (SVD), yang sensitif terhadap keberadaan nilai ekstrem sehingga dapat memengaruhi hasil rekonstruksi (García-Peña dkk., 2021; M. Yu dkk., 2026). Oleh karena itu, nilai maksimum hasil rekonstruksi tidak langsung diinterpretasikan sebagai kondisi oseanografis aktual, tetapi perlu dikendalikan melalui penanganan *outlier* sebelum data digunakan dalam pemodelan.

Temuan berikutnya berkaitan dengan keterbatasan eksplorasi konfigurasi model, khususnya *batch size* dan jumlah *layer*. Dalam penelitian ini, *batch size* ditetapkan sebesar 2 karena dimensi spasial data yang besar menyebabkan penggunaan nilai yang lebih tinggi berisiko menimbulkan *out of memory* (OOM). Ukuran *batch* dapat memengaruhi kestabilan pelatihan, kecepatan konvergensi, dan kemampuan generalisasi model (Kandel & Castelli, 2020). Piao dkk. (2023) menjelaskan bahwa pemilihan *batch size* perlu disesuaikan dengan kapasitas memori perangkat dan ukuran setiap sampel masukan. Semakin besar dimensi data dan ukuran *batch*, semakin besar pula kebutuhan memori selama proses pelatihan. Oleh karena itu, penetapan *batch size* sebesar 2 merupakan penyesuaian terhadap karakteristik data dan keterbatasan sumber daya komputasi.

Selain *batch size*, jumlah *layer* memengaruhi kapasitas model dalam mempelajari pola data. Arsitektur yang terlalu sederhana berisiko mengalami *underfitting*, sedangkan arsitektur yang terlalu kompleks dapat meningkatkan risiko *overfitting* (Gavrilov dkk., 2018). Pada penelitian ini, penggunaan tiga *layer*

ConvLSTM menghasilkan proses pelatihan yang relatif stabil (Rashid Durrani dkk., 2023). Berdasarkan Gambar 4.18 dan Gambar 4.22, nilai *loss* dan MAE pada data *training* dan *validation* menurun pada beberapa *epoch* awal, kemudian stabil pada nilai yang relatif rendah tanpa kesenjangan yang terus melebar. Pola tersebut tidak menunjukkan indikasi *overfitting* yang kuat. Selain itu, kemampuan model dalam menghasilkan nilai evaluasi yang cukup baik pada data *testing* menunjukkan bahwa model tidak mengalami *underfitting* secara dominan. Meskipun demikian, eksplorasi lebih lanjut terhadap *batch size* dan kedalaman arsitektur masih diperlukan untuk memperoleh konfigurasi yang lebih optimal.

Temuan ketiga berkaitan dengan integrasi *mask* spasial sebagai *channel* tambahan pada masukan model. *Mask* tersebut memberikan informasi eksplisit mengenai batas area valid sehingga model dapat membedakan *grid* di dalam WPP-NRI 572 dari area di luar wilayah kajian. Berdasarkan Tabel 4.20, konfigurasi *timestep* 3 memberikan kinerja terbaik pada area *inside WPP* di antara seluruh variasi model dengan *mask* spasial, dengan MAE sebesar 0,022973, RMSE sebesar 0,031717, R^2 sebesar 0,676935, dan korelasi sebesar 0,824106. Dibandingkan dengan konfigurasi tanpa *mask* spasial pada Tabel 4.19, hasil tersebut menunjukkan penurunan kesalahan prediksi serta peningkatan kemampuan model dalam menjelaskan variasi klorofil-a di dalam WPP-NRI 572.

Temuan keempat menunjukkan bahwa model hasil *hyperparameter tuning* belum mampu melampaui performa *baseline* terbaik pada data *testing*, meskipun perbedaannya relatif kecil. Model hasil *tuning* dipilih dari *trial* 24 berdasarkan nilai *validation loss* terendah. Pada area *inside WPP*, konfigurasi *baseline timestep* 3 dengan *mask* spasial menghasilkan MAE sebesar 0,022973, RMSE sebesar 0,031717, R^2 sebesar 0,676935, dan korelasi sebesar 0,824106. Sementara itu, model hasil *tuning* menghasilkan MAE sebesar 0,023164, RMSE sebesar 0,032464, R^2 sebesar 0,661530, dan korelasi sebesar 0,823477. Hasil tersebut menunjukkan bahwa model hasil *tuning* memiliki kesalahan prediksi yang sedikit lebih tinggi serta kemampuan menjelaskan variasi data yang sedikit lebih rendah dibandingkan model *baseline*.

Kondisi tersebut diduga dipengaruhi oleh beberapa faktor. Pertama, jumlah *trial* yang terbatas dapat menyebabkan proses optimasi belum mengeksplorasi kombinasi *hyperparameter* secara menyeluruh (Montero dkk., 2018). Kedua, *search space* yang digunakan belum mencakup seluruh kemungkinan konfigurasi model karena parameter seperti *batch size* dan jumlah *layer* ditetapkan tetap akibat keterbatasan komputasi (Filipovič dkk., 2026; Vrskova dkk., 2021). Ketiga, rasio pembagian data yang ekstrem, yaitu sebesar 90:5:5 menghasilkan data validasi dan *testing* yang relatif kecil, sehingga estimasi performa berpotensi kurang stabil dan kurang representatif terhadap keseluruhan data (An dkk., 2021; Mashuri dkk., 2022). Oleh karena itu, konfigurasi *baseline timestep* 3 dengan *mask* spasial dipilih sebagai model akhir karena memberikan performa yang lebih baik pada data *testing*. Namun, hasil ini tidak menunjukkan bahwa proses *tuning* tidak efektif, melainkan mengindikasikan perlunya penambahan jumlah *trial*, perluasan *search space*, dan penggunaan rasio pembagian data yang lebih proporsional.

Temuan kelima berkaitan dengan keterbatasan hasil *forecasting* setelah model *baseline* terbaik dilakukan *refit* menggunakan seluruh data historis. Prediksi masih menunjukkan variasi pada empat *timestep* awal yang merepresentasikan Januari 2025, tetapi cenderung menurun dan stabil pada Februari–Desember 2025. Kondisi ini diduga berkaitan dengan penggunaan data komposit 8 harian. Frekuensi temporal yang relatif tinggi memberikan informasi lebih rinci untuk prediksi jangka pendek, tetapi menghasilkan jumlah langkah prediksi yang lebih banyak ketika digunakan untuk horizon jangka Panjang. Pada skema *recursive forecasting*, setiap hasil prediksi digunakan kembali sebagai masukan pada periode berikutnya sehingga galat dapat terakumulasi dan pola prediksi semakin mendatar seiring bertambahnya horizon (B. Zhou dkk., 2023).

Selain itu, model menggunakan *timestep* 3 atau sekitar 24 hari historis untuk memprediksi periode berikutnya. Konfigurasi tersebut memberikan performa terbaik pada pengujian jangka pendek, tetapi berpotensi belum memadai untuk menangkap pola musiman dan dependensi temporal jangka panjang klorofil-a. Penelitian Na dkk., 2022 menguji *timestep* 10–1.000 pada data periode 2002–2020 dan memperoleh *timestep* 30 dan 70 sebagai konfigurasi optimal berdasarkan nilai

MAE dan MSE terendah. Sementara itu, penelitian ini hanya menggunakan data periode 2014–2024 dan menguji *timestep* 2, 3, 4, 6, serta 8. Sebagaimana dijelaskan pada subbab 4.10.2, pembatasan maksimum *timestep* 8 juga mempertimbangkan kemampuan perangkat komputasi karena urutan waktu yang lebih panjang meningkatkan ukuran masukan dan risiko *out of memory*. Oleh karena itu, pola prediksi yang cenderung stabil pada Februari–Desember tidak menunjukkan bahwa konsentrasi klorofil-a aktual tidak mengalami perubahan, tetapi mengindikasikan keterbatasan konteks temporal model serta akumulasi galat pada proses prediksi berantai.

Berdasarkan seluruh pembahasan, tahapan analisis dalam penelitian ini telah mampu menggambarkan dinamika klorofil-a, SST, dan intensitas *upwelling* di WPP-NRI 572, meskipun masih memiliki sejumlah keterbatasan metodologis. Rekonstruksi *missing value* menggunakan 3D-DINEOF mampu mempertahankan kecenderungan pusat data, tetapi menghasilkan nilai ekstrem pada klorofil-a sehingga memerlukan penanganan *outlier*. Model ConvLSTM menunjukkan proses pelatihan yang relatif stabil, sedangkan integrasi *mask* spasial sebagai *channel* tambahan membantu model mempelajari pola pada area valid WPP-NRI 572. Namun, eksplorasi *batch size*, jumlah *layer*, *timestep*, dan *hyperparameter* masih dibatasi oleh kapasitas komputasi. Model hasil *hyperparameter tuning* juga belum melampaui *baseline*, meskipun selisih performanya relatif kecil, sehingga pemilihan model akhir perlu didasarkan pada hasil evaluasi data *testing*, bukan hanya *validation loss*. Pada tahap *forecasting*, penggunaan *timestep* 3 cukup efektif untuk prediksi jangka pendek, tetapi menghasilkan pola yang cenderung stabil pada horizon lebih panjang akibat keterbatasan konteks temporal dan akumulasi galat pada prediksi *recursive*. Dengan demikian, hasil penelitian ini dapat digunakan sebagai dasar pemetaan *fishing ground* potensial berbasis kondisi oseanografis, tetapi penerapannya untuk prediksi jangka panjang dan keputusan operasional tetap memerlukan pembaruan model serta validasi menggunakan data perikanan aktual.

BAB V

KESIMPULAN DAN SARAN

5.1 Kesimpulan

Berdasarkan hasil analisis spasio-temporal intensitas upwelling, pemodelan prediksi klorofil-a menggunakan ConvLSTM, serta integrasi keduanya untuk penentuan fishing ground optimal di WPP-NRI 572, diperoleh kesimpulan sebagai berikut :

- a. Intensitas *upwelling* di WPP-NRI 572 menunjukkan variasi spasial dan temporal yang jelas. Dari 9.372.243 observasi *upwelling valid*, nilai UISST memiliki rata-rata sebesar 0,568 °C, dengan Q1 sebesar 0,185 °C dan Q3 sebesar 0,800 °C sebagai batas klasifikasi intensitas. Secara keseluruhan, kelas *non-upwelling* memiliki proporsi terbesar, yaitu 57,11%, sedangkan kelas *upwelling* terdiri atas *weak upwelling* sebesar 16,78%, *intermediate upwelling* sebesar 15,95%, dan *strong upwelling* sebesar 10,17%. Secara spasial, kejadian *upwelling* valid lebih sering terakumulasi di area *offshore* sebelah barat Sumatra, terutama pada bagian tengah hingga selatan WPP-NRI 572. Secara temporal, jumlah kejadian tertinggi terjadi pada September sebanyak 875.519 kejadian dan relatif tinggi pada periode September–Desember, sedangkan pada skala tahunan jumlah tertinggi tercatat pada 2019. Variasi intensitas *upwelling* lebih tampak pada skala bulanan, sementara pola tahunan tidak menunjukkan tren peningkatan atau penurunan yang konsisten selama periode 2014–2024.
- b. Model ConvLSTM mampu digunakan untuk memprediksi konsentrasi klorofil-a dengan mempertimbangkan pola spasial dan temporal di WPP-NRI 572. Berdasarkan percobaan variasi *timestep*, konfigurasi *timestep* 3 dengan *mask* spasial memberikan kinerja terbaik pada area *inside WPP*, dengan MAE sebesar 0,022973, RMSE sebesar 0,031717, R² sebesar 0,676935, dan korelasi sebesar 0,824106. Penambahan *mask* spasial sebagai *channel* tambahan membantu model membedakan area valid di dalam WPP-NRI 572 dari area di luar wilayah kajian. Model hasil *hyperparameter tuning* belum mampu melampaui performa *baseline* pada data *testing*, meskipun selisih hasil

evaluasinya relatif kecil. Oleh karena itu, konfigurasi *baseline* dengan *timestep* 3 dan *mask* spasial dipilih sebagai model akhir karena memberikan kinerja terbaik dalam memprediksi klorofil-a pada area valid WPP-NRI 572.

- c. Integrasi hasil deteksi intensitas *upwelling*, sebaran bulanan klorofil-a dan SST, serta hasil *forecasting* klorofil-a dapat digunakan untuk mengidentifikasi zona *fishing ground* potensial di WPP-NRI 572. Secara spasial, zona tersebut terkonsentrasi pada bagian tengah hingga selatan wilayah kajian, mencakup pesisir barat Sumatra bagian tengah–selatan, sekitar Selat Sunda, serta area *offshore* di sebelah baratnya, terutama pada kisaran 96°BT–103°BT dan 8°LS–2°LS. Secara historis, periode paling potensial terjadi pada September–November karena menunjukkan kesesuaian antara peningkatan klorofil-a, penurunan SST, dan tingginya frekuensi *upwelling* valid. Berdasarkan hasil *forecasting*, Januari 2025 menjadi periode prediktif yang paling menonjol karena memiliki rata-rata dan sebaran klorofil-a yang relatif lebih tinggi dibandingkan bulan-bulan berikutnya. Dengan demikian, zona *fishing ground* potensial dalam penelitian ini merupakan wilayah dengan kondisi oseanografis yang mendukung berdasarkan kombinasi klorofil-a, SST, kejadian *upwelling* valid, dan hasil prediksi klorofil-a, serta belum didasarkan pada data tangkapan atau keberadaan ikan secara langsung.

5.2 Saran

Berdasarkan hasil penelitian yang telah dilakukan, beberapa saran yang dapat diberikan untuk pengembangan penelitian selanjutnya adalah sebagai berikut :

- a. Penanganan *outlier* pada data klorofil-a sebaiknya dilakukan sebelum rekonstruksi *missing value* menggunakan 3D-DINEOF. Nilai ekstrem perlu dihapus atau dibatasi terlebih dahulu agar tidak memengaruhi proses dekomposisi dan menghasilkan nilai rekonstruksi yang terlalu tinggi. Dengan demikian, hasil rekonstruksi dapat lebih stabil dan sesuai dengan karakteristik data oseanografi.
- b. Pengujian 3D-DINEOF perlu dilakukan dengan jumlah mode EOF yang lebih banyak karena mode terbaik dalam penelitian ini diperoleh pada batas maksimum pengujian, yaitu mode 30. Kondisi tersebut mengindikasikan

bahwa mode optimal mungkin berada di luar rentang yang telah diuji. Penelitian selanjutnya juga dapat mengevaluasi nilai toleransi konvergensi agar proses rekonstruksi mencapai hasil yang lebih stabil dan efisien.

- c. Proses *hyperparameter tuning* perlu dikembangkan dengan menambah jumlah *trial* dan memperluas *search space*. Parameter yang dapat dieksplorasi meliputi jumlah *filter*, ukuran *kernel*, *learning rate*, *optimizer*, *batch size*, jumlah *layer*, dan *timestep*. Eksplorasi yang lebih luas diperlukan karena model hasil *tuning* dalam penelitian ini belum mampu melampaui performa *baseline*, meskipun perbedaannya relatif kecil.
- d. Penelitian selanjutnya disarankan menggunakan perangkat komputasi dengan kapasitas memori yang lebih memadai agar pengujian *batch size*, *timestep*, dan kedalaman arsitektur dapat dilakukan secara lebih luas. Pengujian *timestep* yang lebih panjang diperlukan untuk mengevaluasi kemampuan model dalam menangkap pola musiman dan dependensi temporal jangka panjang.
- e. Penggunaan model untuk prediksi jangka panjang, model sebaiknya dilakukan *refit* secara berkala menggunakan data observasi terbaru. Pembaruan model dapat dilakukan setiap satu bulan atau setelah sejumlah *timestep* tertentu untuk mengurangi akumulasi galat pada proses *recursive forecasting* dan mempertahankan relevansi hasil prediksi.
- f. Bagi masyarakat dan pelaku perikanan di WPP-NRI 572, informasi zona dan waktu *fishing ground* potensial dapat digunakan sebagai pertimbangan awal dalam merencanakan kegiatan penangkapan. Namun, hasil tersebut tidak sebaiknya digunakan sebagai satu-satunya dasar operasional karena belum divalidasi menggunakan data tangkapan atau keberadaan ikan secara langsung. Pemanfaatannya perlu dipadukan dengan kondisi cuaca, informasi keselamatan pelayaran, data perikanan aktual, dan ketentuan pengelolaan sumber daya laut.

DAFTAR PUSTAKA

- Ahmad, S. (2012). On Efficient Monitoring of Process Dispersion using Interquartile Range. *Open Journal of Applied Sciences*, 02(04), 39–43. <https://doi.org/10.4236/ojapps.2012.24b010>
- An, C., Park, Y. W., Ahn, S. S., Han, K., Kim, H., & Lee, S. K. (2021). Radiomics machine learning study with a small sample size: Single random training-test set split may lead to unreliable results. *PLoS ONE*, 16(8 August). <https://doi.org/10.1371/journal.pone.0256152>
- Anugrah, A. N., & Alfarizi, A. (2021). Literature Review Potensi Dan Pengelolaan Sumber Daya Perikanan Laut Di Indonesia. *Jurnal Sains Edukatika Indonesia (JSEI)*, 3(2), 31–36.
- Barzegar, R., Aalami, M. T., & Adamowski, J. (2020). Short-term water quality variable prediction using a hybrid CNN–LSTM deep learning model. *Stochastic Environmental Research and Risk Assessment*, 34(2), 415–433. <https://doi.org/10.1007/s00477-020-01776-2>
- Benazzouz, A., Mordane, S., Orbi, A., Chagdali, M., Hilmi, K., Atillah, A., Lluís Pelegrí, J., & Hervé, D. (2014). An improved coastal upwelling index from sea surface temperature using satellite-based approach - The case of the Canary Current upwelling system. *Continental Shelf Research*, 81, 38–54. <https://doi.org/10.1016/j.csr.2014.03.012>
- Budiman, A. S., Bengen, D. G., Nurjaya, I. W., Arifin, Z., & Ismail, M. F. A. (2022). A Comparison of the Three Upwelling Indices in the South Java Sea Shelf. *Chiang Mai University Journal of Natural Sciences*, 21(3). <https://doi.org/10.12982/CMUJNS.2022.044>
- Chen, C., Hu, M., Chen, Q., Zhang, J., Feng, T., & Cui, Z. (2024). Long-term trend forecast of chlorophyll-a concentration over eutrophic lakes based on time series decomposition and deep learning algorithm. *Science of the Total Environment*, 951(July). <https://doi.org/10.1016/j.scitotenv.2024.175451>
- Chicco, D., Warrens, M. J., & Jurman, G. (2021). The coefficient of determination R-squared is more informative than SMAPE, MAE, MAPE, MSE and RMSE in regression analysis evaluation. *PeerJ Computer Science*, 7, 1–24. <https://doi.org/10.7717/PEERJ-CS.623>
- Dash, P., Saha, K., Digiaco, P., Miller, S. D., Zhang, H. M., Lazzaro, R., & Son, S. (2025). Trends in Satellite-Based Ocean Parameters through Integrated Time Series Decomposition and Spectral Analysis. Part I: Chlorophyll, Sea Surface Temperature, and Sea Level Anomaly. *Journal of Atmospheric and Oceanic Technology*, 42(1), 91–123. <https://doi.org/10.1175/JTECH-D-24-0007.1>

- Du, L., Gao, R., Suganthan, P. N., & Wang, D. Z. W. (2022). Bayesian optimization based dynamic ensemble for time series forecasting. *Information Sciences*, 591, 155–175. <https://doi.org/10.1016/j.ins.2022.01.010>
- Dubey, S. R., Singh, S. K., & Chaudhuri, B. B. (2022). Activation functions in deep learning: A comprehensive survey and benchmark. *Neurocomputing*, 503, 92–108. <https://doi.org/10.1016/j.neucom.2022.06.111>
- Fang, X., Zhang, X., Chen, X., & Yu, W. (2025). The Impact of Ekman Pumping and Transport on Dosidicus gigas (Jumbo Flying Squid) Fishing Ground by Chinese Jiggers off the Coast of Peru. *Journal of Marine Science and Engineering*, 13(2), 1–17. <https://doi.org/10.3390/jmse13020280>
- Filipovič, J., Harutyunyan Gevorgyan, S., César, E., & Sikora, A. (2026). *Towards analysis and refinement of auto-tuning spaces*. <https://doi.org/10.1016/j.dib.202>
- Fredyan, R. (2020). *Prediksi Suhu Maksimum Permukaan Darat Di Jawa Timur Menggunakan Metode Convolutional Long Short-Term Memory* (Vol. 2).
- García-Peña, M., Arciniegas-Alarcón, S., Krzanowski, W. J., & Duarte, D. (2021). Missing-value imputation using the robust singular-value decomposition: Proposals and numerical evaluation. *Crop Science*, 61(5), 3288–3300. <https://doi.org/10.1002/csc2.20508>
- García-Seoane, R., Viana, I. G., & Bode, A. (2023). Seasonal upwelling influence on trophic indices of mesozooplankton in a coastal food web estimated from $\delta^{15}\text{N}$ in amino acids. *Progress in Oceanography*, 219(September). <https://doi.org/10.1016/j.pocean.2023.103149>
- Gavrilov, Andrei., Jordache, A., Vasdani, M., & Deng, J. (2018). *Convolutional Neural Networks: Estimating Relations in the Ising Model on Overfitting*. IEEE Computer Society.
- Hammond, M. L., Jebri, F., Srokosz, M., & Popova, E. (2022). Automated detection of coastal upwelling in the Western Indian Ocean: Towards an operational “Upwelling Watch” system. *Frontiers in Marine Science*, 9(August), 1–13. <https://doi.org/10.3389/fmars.2022.950733>
- Harthik, & Raju, M. (2021). *A Study on Deep Learning*. (November), 167–186.
- Huynh, H. N. T., Alvera-Azcárate, A., & Beckers, J. M. (2020). Analysis of surface chlorophyll a associated with sea surface temperature and surface wind in the South China Sea. *Ocean Dynamics*, 70(1), 139–161. <https://doi.org/10.1007/s10236-019-01308-9>
- Ilemobayo, J. A., Durodola, O., Alade, O., J Awotunde, O., T Olanrewaju, A., Falana, O., Ogungbire, A., Osinuga, A., Ogunbiyi, D., Ifeanyi, A., E Odezuligbo, I., & E Edu, O. (2024). Hyperparameter Tuning in Machine Learning: A Comprehensive Review. *Journal of Engineering Research and Reports*, 26(6), 388–395. <https://doi.org/10.9734/jerr/2024/v26i61188>

- Kandel, I., & Castelli, M. (2020). The effect of batch size on the generalizability of the convolutional neural networks on a histopathology dataset. *ICT Express*, 6(4), 312–315. <https://doi.org/10.1016/j.ict.2020.04.010>
- Kawada, M., Kobayashi, T., Stewart, H., Irie, R., Takahashi, M., & Hisada, M. (2024). Performance of Clustering for Upwelling Area Detection Combining Ocean Reanalysis Data and Bathymetric Data Sets. *International Geoscience and Remote Sensing Symposium (IGARSS)*, 1639–1642. <https://doi.org/10.1109/IGARSS53475.2024.10642228>
- Kementerian Kelautan dan Perikanan Republik Indonesia. (2014). *Peraturan Menteri Kelautan dan Perikanan Republik Indonesia Nomor 18/PERMEN-KP/2014 tentang wilayah pengelolaan perikanan Negara Republik Indonesia*. Retrieved November 18, 2025, from <https://peraturan.bpk.go.id/Home/Download/150792/Permen%20KKP%20Nomor%2018%20Tahun%202014.pdf>
- Kementerian Kelautan dan Perikanan Republik Indonesia. (2022). *Keputusan Menteri Kelautan dan Perikanan Republik Indonesia Nomor 19 Tahun 2022 tentang estimasi potensi sumber daya ikan, jumlah tangkapan ikan yang diperbolehkan, dan tingkat pemanfaatan sumber daya ikan di wilayah pengelolaan perikanan Negara Republik Indonesia*. Retrieved November 18, 2025, from <https://ppid.riau.go.id/download/30/1670571648kepmen-kp-no.pdf>
- Kementerian Kelautan dan Perikanan Republik Indonesia. (2025). *Potensi sumber daya ikan Indonesia*. Retrieved November 19, 2025, from <https://portaldata.kkp.go.id/portals/data-statistik/jtb-potensi-sdi/tbl-dinamis>
- Kim, S. J., & Cho, Y. (2025). Enhancing environmental monitoring of harmful algal blooms with ConvLSTM image prediction. *Environmental Research Communications*, 7(2). <https://doi.org/10.1088/2515-7620/adae5d>
- Kingma, D. P., & Ba, J. L. (2015). Adam: A Method For Stochastic Optimization. *arXiv preprint arXiv:1412.6980*.
- Koeshendrajana, S., Rusastra, I. I. W., & Sukadi, M. F. (2019). *Potensi sumber daya kelautan dan perikanan WPPNRI 572*. Pusat Penelitian Sosial Ekonomi Kelautan dan Perikanan.
- Kunarso, Hadi, S., Sari Ningsih, N., Baskoro, M. S., Wirasatriya, A., & Kuswardani, A. R. T. D. (2020). The classification of upwelling indicators base on sea surface temperature, chlorophyll-a and upwelling index, the case study in Southern Java to Timor Waters. *IOP Conference Series: Earth and Environmental Science*, 530(1). <https://doi.org/10.1088/1755-1315/530/1/012020>
- Li, J., Sun, W., & Zhang, J. (2022). Infrared Sea Surface Temperature Data Reconstruction Using Dineof Method. *International Geoscience and Remote*

- Sensing Symposium (IGARSS)*, 2022-July, 7107–7110.
<https://doi.org/10.1109/IGARSS46834.2022.9883843>
- Llugsi, R., Yacoubi, S. El, Fontaine, A., & Lupera, P. (2021). Comparison between Adam, AdaMax and Adam W optimizers to implement a Weather Forecast based on Neural Networks for the Andean city of Quito. *ETCM 2021 - 5th Ecuador Technical Chapters Meeting*, 1–6.
<https://doi.org/10.1109/ETCM53643.2021.9590681>
- Madriyanti, T. (2025). *Analisis Pola Upwelling Dan Penerapan Model Lstm Untuk Deteksi Di WPP-NRI 572 Menggunakan Data SST Dan Chl-a* (hlm. 73).
- Mashuri, A., Adenan, N. H., Karim, N. S. A., Adenan, M. S., & Rani, N. C. A. (2022). Performance of Water Level Forecasting Based on Chaos Approach Using Data Splitting. *Environment and Ecology Research*, 10(2), 218–224.
<https://doi.org/10.13189/eer.2022.100211>
- Millenia, Y. W., & Helmi, M. (2022). *Analisis Mekanisme Pengaruh IOD , ENSO dan Monsun terhadap Suhu Permukaan Laut dan Curah Hujan di Perairan Kepulauan Mentawai , Sumatera Barat*. 04(04), 87–98.
- Montero, E., Riff, M. C., & Rojas-Morales, N. (2018). Tuners review: How crucial are set-up values to find effective parameter values? *Engineering Applications of Artificial Intelligence*, 76, 108–118.
<https://doi.org/10.1016/j.engappai.2018.09.001>
- Muskananfolo, M. R., Jumsar, & Wirasatriya, A. (2021). Spatio-temporal distribution of chlorophyll-a concentration, sea surface temperature and wind speed using aqua-modis satellite imagery over the Savu Sea, Indonesia. *Remote Sensing Applications: Society and Environment*, 22(January), 100483.
<https://doi.org/10.1016/j.rsase.2021.100483>
- Na, L., Shaoyang, C., Zhenyan, C., Xing, W., Yun, X., Li, X., Yanwei, G., Tingting, W., Xuefeng, Z., & Siqi, L. (2022). Long-term prediction of sea surface chlorophyll- A concentration based on the combination of spatio-temporal features. *Water Research*, 211(January), 118040.
<https://doi.org/10.1016/j.watres.2022.118040>
- Nababan, B., Nirmawan, A. D., & Panjaitan, J. P. (2023). Variabilitas Suhu Permukaan Laut Dan Konsentrasi Klorofil-a Di Perairan Palabuhanratu Dan Sekitarnya. *Jurnal Teknologi Perikanan dan Kelautan*, 13(2), 145–162.
<https://doi.org/10.24319/jtpk.13.145-162>
- Naulita, Y., Arhatin, R. E., & Nabil. (2020). Upwelling index along the South Coast of Java from satellite imagery of wind stress and sea surface temperature. *IOP Conference Series: Earth and Environmental Science*, 429(1).
<https://doi.org/10.1088/1755-1315/429/1/012025>

- Neha, & Pasari, S. (2022). A review of empirical orthogonal function (EOF) with an emphasis on the co-seismic crustal deformation analysis. *Natural Hazards*, 110(1), 29–56. <https://doi.org/10.1007/s11069-021-04967-4>
- Ningrum, D., & Zainuri, M. (2022). Variabilitas Bulanan Klorofil-A Dan Suhu Permukaan Laut pada Perairan Teluk Rembang Dengan Menggunakan Citra Sentinel-3. *Indonesian Journal of Oceanography*, 04(02), 88–96.
- Nurdiati, S., Najib, M. K., Bukhari, F., Revina, R., & Salsabila, F. N. (2022). Performance Comparison of Gradient-Based Convolutional Neural Network Optimizers for Facial Expression Recognition. *Barekeng*, 16(3), 927–938. <https://doi.org/10.30598/barekengvol16iss3pp927-938>
- Paillin, J. B., Dominggas, D., Matruty, P., & Siahainenia, S. R. (2020). Daerah Penangkapan Potensial Tuna Madidihang *Thunnus albacares*, Bonnaterre, 1788 (Teleostei : Scombridae) di Laut Seram. *Jurnal Kelautan Tropis*, 23(2), 207–216.
- Piao, X., Synn, D., Park, J., & Kim, J. K. (2023). Enabling Large Batch Size Training for DNN Models Beyond the Memory Limit While Maintaining Performance. *IEEE Access*, 11, 102981–102990. <https://doi.org/10.1109/ACCESS.2023.3312572>
- Rashid Durrani, A. ur, Minallah, N., Aziz, N., Frnda, J., Khan, W., & Nedoma, J. (2023). Effect of hyper-parameters on the performance of ConvLSTM based deep neural network in crop classification. *PLoS ONE*, 18(2 February), 1–18. <https://doi.org/10.1371/journal.pone.0275653>
- Reyad, M., Sarhan, A. M., & Arafa, M. (2023). A modified Adam algorithm for deep neural network optimization. *Neural Computing and Applications*, 35(23), 17095–17112. <https://doi.org/10.1007/s00521-023-08568-z>
- Rokhman, M. T. N., Nastiti, R. D., & Prahoro, A. P. (2025). *The mediating role of financial behavior on business performance with human and spiritual capital*. 9(1), 200–221.
- Rosari, A., & Yasniwati, Y. (2023). Pengaturan Kegiatan Usaha Perikanan Tangkap Di Laut Territorial Dan Zona Ekonomi Eksklusif Indonesia (Zeei) Dan Kapal Tangkap Ikan Nelayan Di Provinsi Sumatera Barat. *UNES Law Review*, 5(4), 2033–2054. <https://doi.org/10.31933/unesrev.v5i4.580>
- Ruan, Q., Pan, D., Wang, D., He, X., Gong, F., & Tian, Q. (2025). Prediction of Sea Surface Chlorophyll-a Concentrations by Remote Sensing and Deep Learning. *Remote Sensing*, 17(10). <https://doi.org/10.3390/rs17101755>
- Sari Q.W., Siswanto Eko, Utari Putri Adia, Saputra Fajar Okta, Lestiana Hilda, Holidi, Subiyanto, Yuniarti, & Iskandar Iskhaq. (2022). Seasonal Driven Mechanism of the Surface Chlorophyll-A Distribution along the Western Coast of Sumatra. *Journal of Ecological Engineering*, 23(11), 273–280.

- Shi, X., Chen, Z., Wang, H., Yeung, D. Y., Wong, W. K., & Woo, W. C. (2015). *Convolutional LSTM Network: A Machine Learning Approach for Precipitation Nowcasting Xingjian*. <https://doi.org/10.1155/2018/6184713>
- Simanjuntak, F., & Lin, T. H. (2022). Monsoon Effects on Chlorophyll-a, Sea Surface Temperature, and Ekman Dynamics Variability along the Southern Coast of Lesser Sunda Islands and Its Relation to ENSO and IOD Based on Satellite Observations. *Remote Sensing*, 14(7). <https://doi.org/10.3390/rs14071682>
- Singh, D. K., & Rawat, N. (2023). Decoding Optimization Algorithms for Convolutional Neural Networks in Time Series Regression Tasks. *International Journal of Information Technology and Computer Science*, 15(6), 37–49. <https://doi.org/10.5815/ijitcs.2023.06.04>
- Stal, C., De Sloover, L., Verbeurgt, J., & De Wulf, A. (2022). On Finding a Projected Coordinate Reference System. *Geographies*, 2(2), 245–257. <https://doi.org/10.3390/geographies2020017>
- Supriyadi, E., & Hidayat, R. (2020). Identification of upwelling area of the western territorial waters of Indonesia from 2000 to 2017. *Indonesian Journal of Geography*, 52(1), 105–111. <https://doi.org/10.22146/ijg.50641>
- Tükenmez, E., & Altıok, H. (2022). Upwelling Index Calculations in the Aegean Sea. *Turkish Journal of Fisheries and Aquatic Sciences*, 22(12). <https://doi.org/10.4194/TRJFAS21621>
- Ulhaq, M. Z., Farid, M., Aziza, Z. I., Nuzullah, T. M. F., Syakir, F., & Sasmita, N. R. (2024). Forecasting Upwelling Phenomena in Lake Laut Tawar: A Semi-Supervised Learning Approach. *Infolitika Journal of Data Science*, 2(2), 53–61. <https://doi.org/10.60084/ijds.v2i2.211>
- Utama, A. F., Maulana, A., Alfany, D., Dharma, C. S., & Harsono, G. (2024). Pemetaan Kriteria Upwelling di Wilayah Kepulauan Karimata Menggunakan Parameter Suhu Permukaan Laut dan Klorofil-A pada Bulan Mei 2023. *Jurnal Hidrografi Indonesia*, 5(2), 99–104. <https://doi.org/10.62703/jhi.v5i2.26>
- Vargas, R., Mosavi, A., & Ruiz, R. (2017). Deep Learning : a Review. *Advances in Intelligent Systems and Computing*, (July). <https://doi.org/10.20944/preprints201810.0218.v1>
- Vrskova, R., Sykora, P., Kamencay, P., Hudec, R., & Radil, R. (2021). Hyperparameter Tuning of ConvLSTM Network Models. *2021 44th International Conference on Telecommunications and Signal Processing, TSP 2021*, 15–18. <https://doi.org/10.1109/TSP52935.2021.9522683>
- Watanabe, S., & Hutter, F. (2023). *c-TPE: Tree-Structured Parzen Estimator with Inequality Constraints for Expensive Hyperparameter Optimization*. <https://arxiv.org/abs/2211.14411>

- Xiao, C., Chen, N., Hu, C., Wang, K., Gong, J., & Chen, Z. (2019). Short and mid-term sea surface temperature prediction using time-series satellite data and LSTM-AdaBoost combination approach. *Remote Sensing of Environment*, 233(July), 111358. <https://doi.org/10.1016/j.rse.2019.111358>
- Yang, M., Khan, F. A., Tian, H., & Liu, Q. (2021). Analysis of the monthly and spring-neap tidal variability of satellite chlorophyll-a and total suspended matter in a turbid coastal ocean using the dineof method. *Remote Sensing*, 13(4), 1–20. <https://doi.org/10.3390/rs13040632>
- Yao, L., Wang, X., Zhang, J., Yu, X., Zhang, S., & Li, Q. (2023). Prediction of Sea Surface Chlorophyll-a Concentrations Based on Deep Learning and Time-Series Remote Sensing Data. *Remote Sensing*, 15(18). <https://doi.org/10.3390/rs15184486>
- Yu, M., Zhao, E., & Jiang, H. (2026). 3D-DINEOF: Extension of Decomposition Dimensions of Data Interpolating Empirical Orthogonal Functions. *IEEE Transactions on Geoscience and Remote Sensing*. <https://doi.org/10.1109/TGRS.2026.3668373>
- Yu, Z., Yang, K., Luo, Y., & Shang, C. (2020). Spatial-temporal process simulation and prediction of chlorophyll-a concentration in Dianchi Lake based on wavelet analysis and long-short term memory network. *Journal of Hydrology*, 582(November 2019), 124488. <https://doi.org/10.1016/j.jhydrol.2019.124488>
- Zarei, A. R. (2026). Hybrid Conv-LSTM architecture with pelican-based hyperparameter tuning for precision spatiotemporal forecasting of environmental indicators. *Applied Computing and Geosciences*, 31. <https://doi.org/10.1016/j.acags.2026.100367>
- Zhou, B., Song, Y., & Ai, J. (2023). Time-frequency analysis of non-stationary signals based on short-time Fourier transform. *ACM International Conference Proceeding Series*, 245–248. <https://doi.org/10.1145/3654446.3654490>
- Zhou, G., Chen, J., Liu, M., & Ma, L. (2024). A spatiotemporal attention-augmented ConvLSTM model for ocean remote sensing reflectance prediction. *International Journal of Applied Earth Observation and Geoinformation*, 129(March), 103815. <https://doi.org/10.1016/j.jag.2024.103815>
- Zhou, S., Xie, W., Lu, Y., Wang, Y., Zhou, Y., Hui, N., & Dong, C. (2021). *ConvLSTM-Based Wave Forecasts in the South and East China Seas*. 8(June), 1–10. <https://doi.org/10.3389/fmars.2021.680079>